

Problem Set 1: Fundamentos, RCT, IV y RD

Inferencia, Causalidad y Políticas Públicas — ECO-60116

Universidad Icesi — Departamento de Economía
Prof. Eduard Fernando Martínez González

Información general

Este Problem Set es de trabajo **individual** y cubre las Semanas 1 a 5 del curso (Fundamentos, RCT, IV y RD nítida); su peso en la nota final es del **15 %**. La entrega consiste en un único archivo `.pdf` con el desarrollo completo, acompañado de un script `.R` reproducible que cargue los tres archivos de datos provistos (`datos_1_observacional.csv`, `datos_2_piloto.csv` y `datos_3_sisben.csv`) y produzca todos los resultados numéricos reportados. El documento se divide en tres componentes con pesos internos de 40 % para el Componente 1 (sesgo por variable omitida), 30 % para el Componente 2 (variables instrumentales) y 30 % para el Componente 3 (regresión discontinua nítida). El uso de herramientas de IA está permitido siempre que se declare explícitamente qué se usó y para qué.

Hilo conductor: Familias en Acción

A lo largo de este Problem Set trabajaremos sobre el mismo programa social: **Familias en Acción**, la transferencia monetaria condicionada operada por el gobierno colombiano. El programa entrega un subsidio mensual a hogares en situación de pobreza, condicionado a la asistencia escolar y a controles médicos de los menores.

Queremos estimar el efecto causal del programa sobre el ingreso mensual del hogar cinco años después de su inicio. Para ello, dispondremos de tres evaluaciones distintas del programa, cada una con un mecanismo de asignación diferente:

1. Una evaluación retrospectiva basada en hogares que voluntariamente se inscribieron al programa.
2. Un piloto del programa en el que la elegibilidad se sorteó por lotería.
3. Una expansión nacional en la que la elegibilidad se determinó por el puntaje SISBEN.

El mismo programa, tres mecanismos de asignación, tres métodos econométricos distintos. Una idea central de este Problem Set es que el método correcto depende del diseño institucional, no del programa.

1 Componente 1 — Sesgo por variable omitida (40 %)

Contexto

Evaluación retrospectiva. Cinco años después del inicio del programa, una consultora levanta una encuesta sobre hogares elegibles. Como no hubo ningún mecanismo formal de asignación —los hogares se inscribieron voluntariamente cuando supieron del programa— se decide estimar el impacto comparando, vía OLS, el ingreso de hogares inscritos vs. no inscritos.

La consultora dispone de una variable adicional, W_i , que mide la motivación parental (índice construido a partir de un cuestionario sobre expectativas, planificación familiar y participación en reuniones escolares). El verdadero proceso generador de los datos, no observado por la consultora, es:

$$Y_i = \beta_0 + \beta_1 D_i + \beta_2 W_i + \varepsilon_i, \quad \mathbb{E}[\varepsilon_i \mid D_i, W_i] = 0,$$

donde Y_i es el ingreso mensual del hogar (miles COP), $D_i \in \{0, 1\}$ indica inscripción al programa, y W_i es la motivación parental (estandarizada).

La consultora, por simplicidad, decide estimar el modelo *omitiendo* W :

$$Y_i = \alpha_0 + \alpha_1 D_i + u_i.$$

Parte teórica

Pregunta 1.1 (Descomposición del sesgo). Demuestre paso a paso que, en muestras grandes,

$$\mathbb{E}[\hat{\alpha}_1] = \beta_1 + \beta_2 \cdot \frac{\text{Cov}(D, W)}{\text{Var}(D)}.$$

Sugerencia: parta de la fórmula de OLS en regresión simple, $\hat{\alpha}_1 = \text{Cov}(D, Y)/\text{Var}(D)$, y sustituya el verdadero Y_i del DGP. Indique en qué paso usa $\mathbb{E}[\varepsilon \mid D] = 0$.

Pregunta 1.2 (Dirección del sesgo). Complete la siguiente tabla. Para cada combinación de signos, indique si el estimador naíve $\hat{\alpha}_1$ **sobreestima** o **subestima** β_1 , y argumente brevemente la intuición económica de cada caso.

signo(β_2)	signo(Cov(D, W))	¿Sobre/sub?	Intuición de un caso económico donde ocurre
+	+		
+	−		
−	+		
−	−		

Pregunta 1.3 (Aplicación al contexto). Asuma $\beta_2 > 0$ (más motivación parental se asocia con mayor ingreso del hogar). Considere el siguiente escenario, plausible en evaluaciones retrospectivas de programas con inscripción voluntaria:

Auto-selección positiva. Los padres más motivados se inscriben más al programa, porque conocen mejor cómo funciona el trámite y están más conectados a la oferta institucional.

- (a) ¿Cuál es el signo esperado de $\text{Cov}(D, W)$ en este escenario?
- (b) ¿ $\hat{\alpha}_1$ sobreestima o subestima β_1 ?
- (c) En este escenario, ¿la consultora tendería a **sobrevender** el programa (reportar un efecto mayor del verdadero) o a subvenderlo? ¿Por qué este es el patrón típicamente preocupante en evaluaciones retrospectivas de programas sociales?

Parte aplicada

Use el archivo `datos_1_observacional.csv`.

Pregunta 1.4.

- (a) Cargue los datos. Reporte el tamaño de muestra y la proporción de hogares con $D = 1$.
- (b) Estime el modelo *naive* $Y_i = \alpha_0 + \alpha_1 D_i + u_i$ por OLS y reporte $\hat{\alpha}_1$ con su error estándar.
- (c) Estime el modelo completo $Y_i = \beta_0 + \beta_1 D_i + \beta_2 W_i + \varepsilon_i$ y reporte $\hat{\beta}_1, \hat{\beta}_2$.
- (d) Calcule directamente $\widehat{\text{Cov}}(D, W)$ y $\widehat{\text{Var}}(D)$ a partir de los datos. Verifique numéricamente la descomposición de la Pregunta 1.1: ¿se cumple $\hat{\alpha}_1 \approx \hat{\beta}_1 + \hat{\beta}_2 \cdot \widehat{\text{Cov}}(D, W) / \widehat{\text{Var}}(D)$?
- (e) A la luz de sus resultados: ¿los datos son consistentes con el escenario de auto-selección positiva descrito en la Pregunta 1.3? Justifique.

2 Componente 2 — Variables instrumentales (30 %)

Contexto

Piloto con lotería. Conscientes de las limitaciones de la evaluación retrospectiva, el gobierno decide hacer una nueva evaluación a través de un *piloto* del programa en 100 municipios. La elegibilidad se sortea por lotería: cada hogar elegible recibe un ticket numerado, y el gobierno sortea aleatoriamente cuáles tickets son ganadores. Sin embargo:

- **Solo los ganadores** pueden inscribirse al programa (no hay manera de inscribirse sin ticket ganador).
- **No todos los ganadores se inscriben:** algunos rechazan el programa, otros nunca completan el trámite.

Variables observadas: Y_i (ingreso mensual), $D_i \in \{0, 1\}$ (inscrito efectivamente al programa), $Z_i \in \{0, 1\}$ (ganador de la lotería).

Parte teórica

Pregunta 2.1 (Por qué OLS falla aquí). Argumente, usando notación de resultados potenciales, por qué la simple diferencia de medias $\mathbb{E}[Y \mid D = 1] - \mathbb{E}[Y \mid D = 0]$ no identifica el efecto causal del programa en este contexto. ¿Quiénes son los hogares con $D = 1$ y quiénes los hogares con $D = 0$, dada la estructura del piloto? ¿Cómo se compara este sesgo con el del Componente 1?

Pregunta 2.2 (Estimador de Wald). Defina el estimador de Wald como

$$\beta^{\text{Wald}} = \frac{\mathbb{E}[Y \mid Z = 1] - \mathbb{E}[Y \mid Z = 0]}{\mathbb{E}[D \mid Z = 1] - \mathbb{E}[D \mid Z = 0]}.$$

- (a) Interprete *en palabras* qué representa el numerador y qué representa el denominador en el contexto del piloto.
- (b) ¿Por qué tiene sentido que el numerador esté libre de sesgo (a pesar de que D es endógeno)?
- (c) ¿Cuál es la interpretación económica del cociente?

Pregunta 2.3 (Equivalencia Wald = 2SLS con Z, D binarios). El estimador de Mínimos Cuadrados en Dos Etapas (2SLS) procede así:

- **Primera etapa:** regresar D contra Z por OLS para obtener $\hat{D}_i = \hat{\pi}_0 + \hat{\pi}_1 Z_i$.
- **Segunda etapa:** regresar Y contra $\hat{D}$ por OLS para obtener $\hat{\beta}_{2\text{SLS}}$.

Demuestre algebraicamente, *sin usar matrices*, que cuando $Z, D \in \{0, 1\}$:

$$\hat{\beta}_{2\text{SLS}} = \hat{\beta}^{\text{Wald}}.$$

Sugerencia paso a paso:

- (I) Primero muestre que, con $Z \in \{0, 1\}$, los coeficientes de la primera etapa satisfacen $\hat{\pi}_0 = \bar{D}_{Z=0}$ y $\hat{\pi}_0 + \hat{\pi}_1 = \bar{D}_{Z=1}$, donde $\bar{D}_{Z=z}$ es la media muestral de D en el grupo $Z = z$.
- (II) Concluya que $\hat{D}_i$ toma solo dos valores: $\bar{D}_{Z=0}$ cuando $Z_i = 0$, y $\bar{D}_{Z=1}$ cuando $Z_i = 1$.
- (III) Aplique la fórmula de OLS simple $\hat{\beta}_{2\text{SLS}} = \widehat{\text{Cov}}(Y, \hat{D}) / \widehat{\text{Var}}(\hat{D})$ y muestre que se reduce algebraicamente al estimador de Wald.

Pregunta 2.4 (Intuición de la primera etapa). En 2–3 párrafos, **con sus propias palabras** (sin reproducir fórmulas), explique por qué la segunda etapa, al reemplazar D_i por $\hat{D}_i$, produce un estimador insesgado del efecto causal aunque D sea endógeno. Su respuesta debe (i) decir qué representa $\hat{D}_i$ y por qué se le suele llamar “la parte exógena de D ”, y (ii) precisar qué tipo de variación en D está usando 2SLS y qué tipo está descartando.

Parte aplicada

Use el archivo `datos_2_piloto.csv`.

Pregunta 2.5.

- (a) Reporte: n , $\Pr(Z = 1)$, $\Pr(D = 1)$, $\Pr(D = 1 \mid Z = 1)$ (tasa de cumplimiento entre ganadores), $\Pr(D = 1 \mid Z = 0)$.
- (b) Estime por OLS $Y = \alpha_0 + \alpha_1 D + u$ y reporte $\hat{\alpha}_1$. ¿Cuál es el problema de este estimador?
- (c) Estime la **primera etapa** $D = \pi_0 + \pi_1 Z + v$ y reporte $\hat{\pi}_1$. ¿Es relevante el instrumento? ¿Cómo lo interpreta?
- (d) Estime la **forma reducida** $Y = \rho_0 + \rho_1 Z + \nu$ y reporte $\hat{\rho}_1$. ¿Qué efecto está estimando (use el lenguaje correcto: ITT, ATT, etc.)?
- (e) Calcule a mano el estimador de Wald usando *únicamente* las medias condicionales $\bar{Y}_{Z=z}$ y $\bar{D}_{Z=z}$. Verifique numéricamente que $\hat{\beta}^{\text{Wald}} = \hat{\rho}_1 / \hat{\pi}_1$.
- (f) Estime 2SLS con `fixest::feols(Y ~ 1 | 0 | D ~ Z, data = d2)` y verifique numéricamente que el coeficiente coincide con el Wald de (e).
- (g) Compare el OLS naive de (b) con el 2SLS de (f). ¿En qué dirección está el sesgo de OLS? ¿Es consistente con su intuición de la Pregunta 2.1?

3 Componente 3 — Regresión discontinua nítida (30 %)

Contexto

Expansión nacional con umbral SISBEN. Tras los resultados positivos del piloto, el gobierno decide expandir el programa a nivel nacional. Para racionalizar el gasto, la elegibilidad se determina mediante el **puntaje SISBEN**: hogares con puntaje $X_i \leq 50$ son elegibles y reciben el programa ($D_i = 1$); hogares con $X_i > 50$ no son elegibles ($D_i = 0$). El cumplimiento es *perfecto*.

Variables observadas: Y_i (ingreso mensual del hogar), D_i (recibió programa), X_i (puntaje SISBEN, entre 0 y 100). El umbral es $c = 50$.

Parte teórica

Pregunta 3.1 (Identificación bajo continuidad). Suponga que las funciones $x \mapsto \mathbb{E}[Y(0) \mid X = x]$ y $x \mapsto \mathbb{E}[Y(1) \mid X = x]$ son continuas en $x = c$. Demuestre que

$$\lim_{x \uparrow c} \mathbb{E}[Y \mid X = x] - \lim_{x \downarrow c} \mathbb{E}[Y \mid X = x] = \mathbb{E}[Y(1) - Y(0) \mid X = c].$$

Sugerencias:

- (I) Recuerde que $Y_i = D_i \cdot Y_i(1) + (1 - D_i) \cdot Y_i(0)$ (consistencia / SUTVA).
- (II) Para $x > c$, $D = 0$, así que $\mathbb{E}[Y \mid X = x] = \mathbb{E}[Y(0) \mid X = x]$.
- (III) Para $x \leq c$, $D = 1$, así que $\mathbb{E}[Y \mid X = x] = \mathbb{E}[Y(1) \mid X = x]$.
- (IV) Aplique la continuidad en cada lado del umbral.

Pregunta 3.2 (Continuidad de $\mathbb{E}[Y(d)|X]$ vs. continuidad de Y). Argumente brevemente por qué el supuesto de identificación requiere continuidad de las *esperanzas*

condicionales de los resultados potenciales, y no continuidad de la función $\mathbb{E}[Y \mid X = x]$ observada. (Pista: si $\mathbb{E}[Y \mid X = x]$ fuera continua en c , ¿qué pasaría con la discontinuidad que queremos estimar?)

Pregunta 3.3 (Conexión con IV: efectos locales). En el Componente 2, el estimador IV identifica un efecto local: el LATE, definido sobre la subpoblación de *compliers*. En este componente, la RD nítida también identifica un efecto local: $\mathbb{E}[Y(1) - Y(0) \mid X = c]$, definido sobre la subpoblación de hogares *con puntaje exactamente igual al umbral*.

En 2–3 párrafos:

- (a) ¿En qué se parecen estos dos efectos locales? Más concretamente: ¿qué tipo de variación en el tratamiento está *aprovechando* cada método?
- (b) ¿Por qué llamamos a estos efectos “locales” en lugar de ATE? ¿En qué situaciones de política pública nos importaría la diferencia entre el LATE/efecto-en-el-umbral y el ATE global?

Parte aplicada

Use el archivo `datos_3_sisben.csv`. El umbral es $c = 50$.

Pregunta 3.4.

- (a) Cargue los datos y haga un **gráfico de dispersión** de Y contra X , coloreando los puntos según D y marcando una línea vertical en $c = 50$. (Si la muestra es grande y los puntos se solapan, considere usar `alpha=0.3` o agrupar por bins de X .) ¿Se observa un salto en el umbral?
- (b) Estime el modelo *naive global* $Y = \alpha_0 + \alpha_1 D + u$ **sin controlar por X** . Reporte $\hat{\alpha}_1$. ¿Qué problema gigante tiene este estimador? Conecte con el Componente 1: ¿qué variable se está omitiendo aquí?
- (c) Implemente **RD local lineal**: restrinja la muestra a una ventana $|X - c| \leq h$ y estime

$$Y_i = \alpha + \tau D_i + \gamma_1(X_i - c) + \gamma_2(X_i - c)D_i + u_i.$$

Reporte $\hat{\tau}$ con su error estándar para dos anchos de banda: $h = 5$ y $h = 15$.

- (d) ¿Es estable la estimación entre los dos anchos de banda? Discuta el trade-off: h pequeño vs. h grande, ¿qué pierde y qué gana en cada caso?
- (e) Compare las dos estimaciones de RD con el OLS naive de (b). ¿Cuál se acerca más a un efecto causal creíble? Justifique con base en los supuestos de identificación de cada estimador.
- (f) Interprete económicamente $\hat{\tau}$: ¿qué nos dice sobre el efecto del programa, y para qué subpoblación de hogares colombianos es válida esa conclusión?