

# Problem Set 2: Datos Panel y Diferencias en Diferencias

Inferencia, Causalidad y Políticas Públicas — ECO-60116

Universidad Icesi — Departamento de Economía  
Prof. Eduard Fernando Martínez González

## Información general

- **Fecha de entrega:** viernes 5 de junio de 2026. Subir al campus virtual un `.zip` con el `.pdf` y el script `.R`.
- **Peso:** 15 % de la nota final. Trabajo **individual**.
- **Componentes:** C1 — Datos panel y efectos fijos (50 %), C2 — Diferencias en diferencias (50 %).
- **Datos:** `datos_jornada_unica.csv`. El script debe ser reproducible de principio a fin.
- **IA:** permitida, siempre que se declare explícitamente qué se usó y para qué.

## Hilo conductor: Jornada Única en colegios oficiales

En 2015, el Ministerio de Educación Nacional (MEN) implementó la primera oleada del programa **Jornada Única**, que extiende la jornada escolar de 6 a 8 horas diarias en colegios oficiales e incluye un componente de alimentación. La intención de política fue clara: más horas de instrucción se traducirían en mejor rendimiento académico, medido por las pruebas SABER 11.

La selección de colegios para la **Cohorte 2015** no fue aleatoria. El MEN priorizó colegios con mayor capacidad administrativa, evaluada con base en indicadores internos (puntualidad de reportes, ejecución presupuestal, baja rotación docente, etc.). Los colegios no seleccionados ingresaron a la **Cohorte 2018**, fuera de nuestra ventana de análisis. Para efectos de este Problem Set, usaremos los colegios de Cohorte 2015 como *grupo tratado* y los de Cohorte 2018 como *grupo de control*.

Disponemos de un panel de 2.000 colegios oficiales observados durante cinco años (2013–2017). Para cada colegio-año observamos:

- **Y:** puntaje promedio del colegio en SABER 11.
- **tratado:** 1 si el colegio pertenece a la Cohorte 2015, 0 si pertenece a la Cohorte 2018. Constante en el tiempo.
- **post:** 1 si el año es 2015 o posterior, 0 si es anterior. Constante por año (igual para todos los colegios).

- D: variable de tratamiento, construida como  $D_{it} = \text{tratado}_i \cdot \text{post}_t$ .

**Una nota sobre la conexión con PS1.** En el Problem Set 1 vimos que el sesgo por variable omitida aparece cuando una variable no observada (motivación parental, puntaje SISBEN, etc.) correlaciona simultáneamente con el tratamiento y con el resultado. La solución allí dependía del diseño institucional: lotería (IV) o umbral (RD). En este Problem Set veremos una alternativa más general: cuando disponemos de varias observaciones por unidad (panel), podemos eliminar todo el efecto de las variables no observadas *que sean constantes en el tiempo*, sin necesidad de medirlas. Esa es la magia de los efectos fijos.

**Una idea central del Problem Set:** mostrar que la regresión DiD con interacción y el modelo de efectos fijos de dos vías producen *exactamente el mismo* estimador. Son dos vistas del mismo objeto matemático.

## 1 Componente 1 — Datos panel y efectos fijos (50%)

### Contexto

Considere el modelo estructural:

$$Y_{it} = \beta D_{it} + \alpha_i + \gamma_t + \varepsilon_{it}, \quad \mathbb{E}[\varepsilon_{it} \mid D_{it}, \alpha_i, \gamma_t] = 0.$$

Aquí  $\alpha_i$  es un efecto fijo del colegio (capacidad administrativa, calidad del rector, etc.),  $\gamma_t$  es un efecto fijo de año (cambios curriculares o económicos nacionales que afectan a todos), y  $\beta$  es el efecto causal del programa que queremos estimar.

El **problema central** es que  $\alpha_i$  no se observa, pero correlaciona con el tratamiento (el MEN seleccionó colegios mejor administrados).

### Parte teórica

**Pregunta 1.1 (Sesgo de pooled OLS).** Suponga que se estima por OLS el modelo simple

$$Y_{it} = \pi_0 + \pi_1 D_{it} + u_{it}$$

ignorando tanto  $\alpha_i$  como  $\gamma_t$  (esto se conoce como *pooled OLS*). Demuestre, partiendo de la fórmula  $\hat{\pi}_1 = \widehat{\text{Cov}}(D, Y) / \widehat{\text{Var}}(D)$ , que en muestras grandes:

$$\mathbb{E}[\hat{\pi}_1] = \beta + \underbrace{\frac{\text{Cov}(D, \alpha)}{\text{Var}(D)}}_{\text{sesgo por } \alpha_i} + \underbrace{\frac{\text{Cov}(D, \gamma)}{\text{Var}(D)}}_{\text{sesgo por } \gamma_t}.$$

Conecte explícitamente con la fórmula de OVB del Problem Set 1: ¿en qué sentido es esta una generalización?

**Pregunta 1.2 (Transformación within).** Defina la transformación *within* (o *demeaning* por unidad) como

$$\tilde{Y}_{it} = Y_{it} - \bar{Y}_i, \quad \bar{Y}_i = \frac{1}{T} \sum_{t=1}^T Y_{it},$$

y análogamente  $\tilde{D}_{it}, \tilde{\gamma}_{it}, \tilde{\varepsilon}_{it}$ .

- (a) Aplique la transformación *within* a la ecuación estructural del modelo de efectos fijos. Muestre paso a paso que el término  $\alpha_i$  se **cancela exactamente**.
- (b) ¿Qué pasa con  $\gamma_t$  tras la transformación *within* por unidad? ¿Se cancela? ¿Por qué sí o por qué no?
- (c) Argumente brevemente (sin demostración formal) por qué el coeficiente OLS de  $\tilde{Y}$  contra  $\tilde{D}$  es idéntico al coeficiente OLS de  $Y$  contra  $D$  cuando se incluyen dummies de unidad (una por cada colegio menos una). Esta equivalencia se conoce como el *teorema de Frisch-Waugh-Lovell*.

**Pregunta 1.3 (¿Qué absorbe FE?).** En 2 párrafos, con sus propias palabras, explique:

- (a) ¿Qué tipos de características de los colegios **absorbe** (deja de sesgar) el efecto fijo de unidad? Dé al menos un ejemplo concreto en el contexto de Jornada Única.
- (b) ¿Qué tipos de características **no** absorbe? Dé al menos un ejemplo concreto en el contexto de Jornada Única. ¿Cómo se podrían atacar esas variables omitidas restantes?

## Parte aplicada

Use el archivo `datos_jornada_unica.csv`.

### Pregunta 1.4.

- (a) Cargue los datos. Reporte: número de colegios, número de años, número total de filas, proporción de colegios tratados (`tratado = 1`), y proporción de filas con  $D = 1$ .
- (b) Verifique numéricamente que  $D_{it} = \text{tratado}_i \cdot \text{post}_t$  en *todas* las filas del panel. (Sugerencia: `all(d$D == d$tratado * d$post)` debería ser TRUE.)
- (c) Estime **pooled OLS**  $Y_{it} = \pi_0 + \pi_1 D_{it} + u_{it}$ , con errores estándar clusterizados a nivel de colegio. Reporte  $\hat{\pi}_1$ .
- (d) Estime **FE de una vía** (solo efecto fijo de colegio):  $Y_{it} = \alpha_i + \beta D_{it} + u_{it}$ . Use `fixest::feols(Y ~ D | colegio_id, data = d, cluster = colegio_id)`. Reporte  $\hat{\beta}$ .
- (e) Estime **FE de dos vías** (efectos fijos de colegio y de año):  $Y_{it} = \alpha_i + \gamma_t + \beta D_{it} + u_{it}$ . Use `feols(Y ~ D | colegio_id + anio, data = d, cluster = colegio_id)`. Reporte  $\hat{\beta}$ .
- (f) Compare las tres estimaciones de (c), (d) y (e). ¿En qué dirección va el sesgo de pooled OLS? Conecte con la Pregunta 1.1 y con el contexto del programa (selección por capacidad administrativa).
- (g) El FE de una vía y el FE de dos vías dan estimaciones *distintas*, a pesar de que ya teníamos efectos fijos de colegio en ambos. ¿Por qué? (Pista: ¿qué pasa con  $D_{it}$  a lo largo del tiempo? Recuerde que  $D_{it} = 0$  para todo colegio antes de 2015 y se “prende” sólo a partir de 2015 para los tratados.)

## 2 Componente 2 — Diferencias en Diferencias (50 %)

### Contexto

En este componente nos enfocamos en el diseño  $2 \times 2$ : dos grupos (tratado y control) observados en dos momentos (pre y post). Define:

- $Y_{it}(1)$ : resultado potencial del colegio  $i$  en el año  $t$  si recibe el tratamiento.
- $Y_{it}(0)$ : resultado potencial si no lo recibe.
- $T_i$ : 1 si el colegio pertenece al grupo tratado, 0 si no.
- $\text{Post}_t$ : 1 si el año es  $t \geq 2015$ , 0 si no.

### Parte teórica

#### Pregunta 2.1 (Tendencias paralelas e identificación).

- (a) Defina formalmente el supuesto de **tendencias paralelas** como una restricción sobre  $\mathbb{E}[Y(0) \mid T, \text{Post}]$ . (Sugerencia: el cambio promedio en  $Y(0)$  entre pre y post debe ser igual en ambos grupos.)
- (b) Bajo tendencias paralelas, demuestre que (usando la notación abreviada  $\mu_{tp} := \mathbb{E}[Y \mid T = t, \text{Post} = p]$ ):

$$\mathbb{E}[Y(1) - Y(0) \mid T = 1, \text{Post} = 1] = (\mu_{11} - \mu_{10}) - (\mu_{01} - \mu_{00}).$$

- (c) ¿Por qué este estimando se llama el **ATT** (efecto promedio sobre los tratados) y no el ATE?

#### Pregunta 2.2 (DiD como coeficiente de regresión). Considere la regresión con interacción:

$$Y_{it} = \beta_0 + \beta_1 T_i + \beta_2 \text{Post}_t + \delta (T_i \cdot \text{Post}_t) + u_{it}.$$

- (a) Calcule  $\mathbb{E}[Y \mid T = t, \text{Post} = p]$  para las cuatro combinaciones de  $(T, \text{Post})$  en términos de los coeficientes.
- (b) Muestre que  $\delta$  es exactamente el estimando DiD de la Pregunta 2.1(b).
- (c) Interprete cada uno de los cuatro coeficientes  $(\beta_0, \beta_1, \beta_2, \delta)$  en el contexto de Jornada Única. ¿Cuál es “el efecto del programa”?

#### Pregunta 2.3 (DiD como FE de dos vías). Demuestre que la regresión DiD de la Pregunta 2.2 es algebraicamente equivalente al modelo de efectos fijos de dos vías

$$Y_{it} = \alpha_i + \gamma_t + \delta D_{it} + u_{it}, \quad \text{donde } D_{it} = T_i \cdot \text{Post}_t.$$

*Sugerencia:* muestre que  $\alpha_i$  absorbe el término  $\beta_0 + \beta_1 T_i$  (depende solo de  $i$ ),  $\gamma_t$  absorbe el término  $\beta_2 \text{Post}_t$  (depende solo de  $t$ ), y lo único que queda como variable de interés es la interacción  $T_i \cdot \text{Post}_t = D_{it}$ . En consecuencia, el coeficiente  $\delta$  es el mismo en ambas especificaciones.

*Este es el punto que cierra el Problem Set:* DiD y FE-2way son **la misma cosa** cuando el tratamiento se prende en una fecha común para los tratados.

## Parte aplicada

Use el archivo `datos_jornada_unica.csv`.

### Pregunta 2.4.

- (a) Calcule las cuatro medias condicionales  $\bar{Y}_{tp} = \bar{Y} \mid \text{tratado} = t, \text{post} = p$ , para  $(t, p) \in \{(0, 0), (0, 1), (1, 0), (1, 1)\}$ . Reporte una tabla  $2 \times 2$ .
- (b) Calcule el **DiD a mano** usando esas cuatro medias.
- (c) Estime el **DiD por regresión con interacción**:

$$Y_{it} = \beta_0 + \beta_1 \text{tratado}_i + \beta_2 \text{post}_t + \delta (\text{tratado}_i \cdot \text{post}_t) + u_{it}.$$

Use `feols(Y ~ tratado * post, data = d, cluster = colegio_id)`. Reporte  $\hat{\delta}$ .

- (d) Estime **DiD como FE-2way**: `feols(Y ~ D | colegio_id + anio, data = d, cluster = colegio_id)`. Reporte  $\hat{\delta}$ .
- (e) Compare los tres estimadores de (b), (c) y (d). ¿Coinciden? Confirme empíricamente lo que probó algebraicamente en la Pregunta 2.3.
- (f) Construya un **gráfico de tendencias**: eje  $X$  = año, eje  $Y$  = promedio de SABER 11. Dibuje dos líneas (tratado y control) y marque una línea vertical en 2015. Comente: ¿son visiblemente paralelas las líneas *antes* de 2015? ¿Hay un quiebre visible en 2015?
- (g) Calcule la diferencia  $\bar{Y}_{T=1, \text{año}=a} - \bar{Y}_{T=0, \text{año}=a}$  para cada año  $a \in \{2013, \dots, 2017\}$ . ¿Qué hubiera implicado para su DiD si esa diferencia hubiera estado *aumentando consistentemente* antes de 2015?
- (h) En 2–3 líneas, describa un fenómeno plausible en el contexto colombiano que *violaría* tendencias paralelas en este caso. ¿Cómo evaluaría empíricamente si está presente?