Inferencia, Causalidad y Políticas Públicas
ECO-60116

Week 01: Fundamentos de la Inferencia Causal

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

April 14, 2026

Acerca de este curso

1. **Al finalizar el curso podrás:**
   - Comprender y aplicar el marco conceptual de la inferencia causal.
   - Usar metodologías: OLS, IV, RCT, DiD, RD, Matching.
   - Diseñar e implementar evaluaciones de impacto con datos reales.
2. **Módulos principales:**
   - Fundamentos de la Inferencia Causal
   - Diseños experimentales y cuasi-experimentales
   - Métodos avanzados y robustez
   - Integración y aplicación
3. **Metodología:**
   - Exposición teórica del profesor.
   - Ejemplos prácticos con R y artículos aplicados.
   - Presentación estudiantil de artículos.
4. **Evaluación:**
   - Presentación de un artículo: 30%.
   - Taller aplicado: 20%.
   - Proyecto final: 50%.

Presentación de un artículo (30%)

- Al inicio de cada sesión, un estudiante presentará un **artículo empírico** vinculado al tema de la clase anterior.
- Duración aproximada: **15 minutos**.
- La presentación debe incluir al menos 4 diapositivas, cubriendo como mínimo:
  1. Pregunta de investigación.
  2. Datos utilizados.
  3. Metodología y estrategia de identificación. (Puede necesitar más de una diapositiva)
  4. Resultados principales.
- El artículo debe seleccionarse de:
  - La bibliografía recomendada, o un paper publicado en uno de los Top 5 journals de economía.
  - O un paper publicado en un journal dentro del Top 50 de Financial Times.
- Durante la presentación, profesor y estudiantes pueden intervenir con preguntas para profundizar en el entendimiento.

Proyecto final (50%)

- Desarrollar una **pregunta de investigación** con un **método de inferencia causal** (RCT, IV, RD, DiD, Matching) aplicado a una **base de datos sintética** construida en R.
- **Estructura mínima:** motivación, datos (generación y caracterización), estrategia de identificación, validación de supuestos, y resultados (al menos una tabla con regresión).
- **Entregables:**
  - Documento PDF (máx. **10** páginas).
  - Paquete de replicación (`.zip`) con código R y `README`.
  - Presentación oral en la **última clase**.
- **Logística:** el detalle paso a paso será cargado la próxima semana en **Intu**.

Talleres extra-clase (20%)

- Se realizarán **2 talleres** para desarrollar en casa (**10% cada uno**).
- **Objetivo:** practicar el **álgebra** detrás de los métodos de inferencia causal vistos en clase.
- **Contenido típico:**
  - Derivaciones formales (OLS, IV, sesgo de selección, etc.).
  - Demostración de propiedades (insesgadez, consistencia).
  - Ejercicios de sesgo por variable omitida y dirección del sesgo.
- **Formato:** entrega individual en PDF. Se valorará claridad, rigor y notación.
- Las fechas de entrega serán anunciadas con al menos **una semana** de anticipación.

1 Motivación

2 DAGs: Visualizando la causalidad

3 Marco conceptual: Rubin Causal Model

4 ¿Qué dice y qué no dice una regresión?

5 Del caso bivariado al multivariado: OLS matricial

6 Sesgo por variable omitida

El riesgo de confundir correlación con causalidad

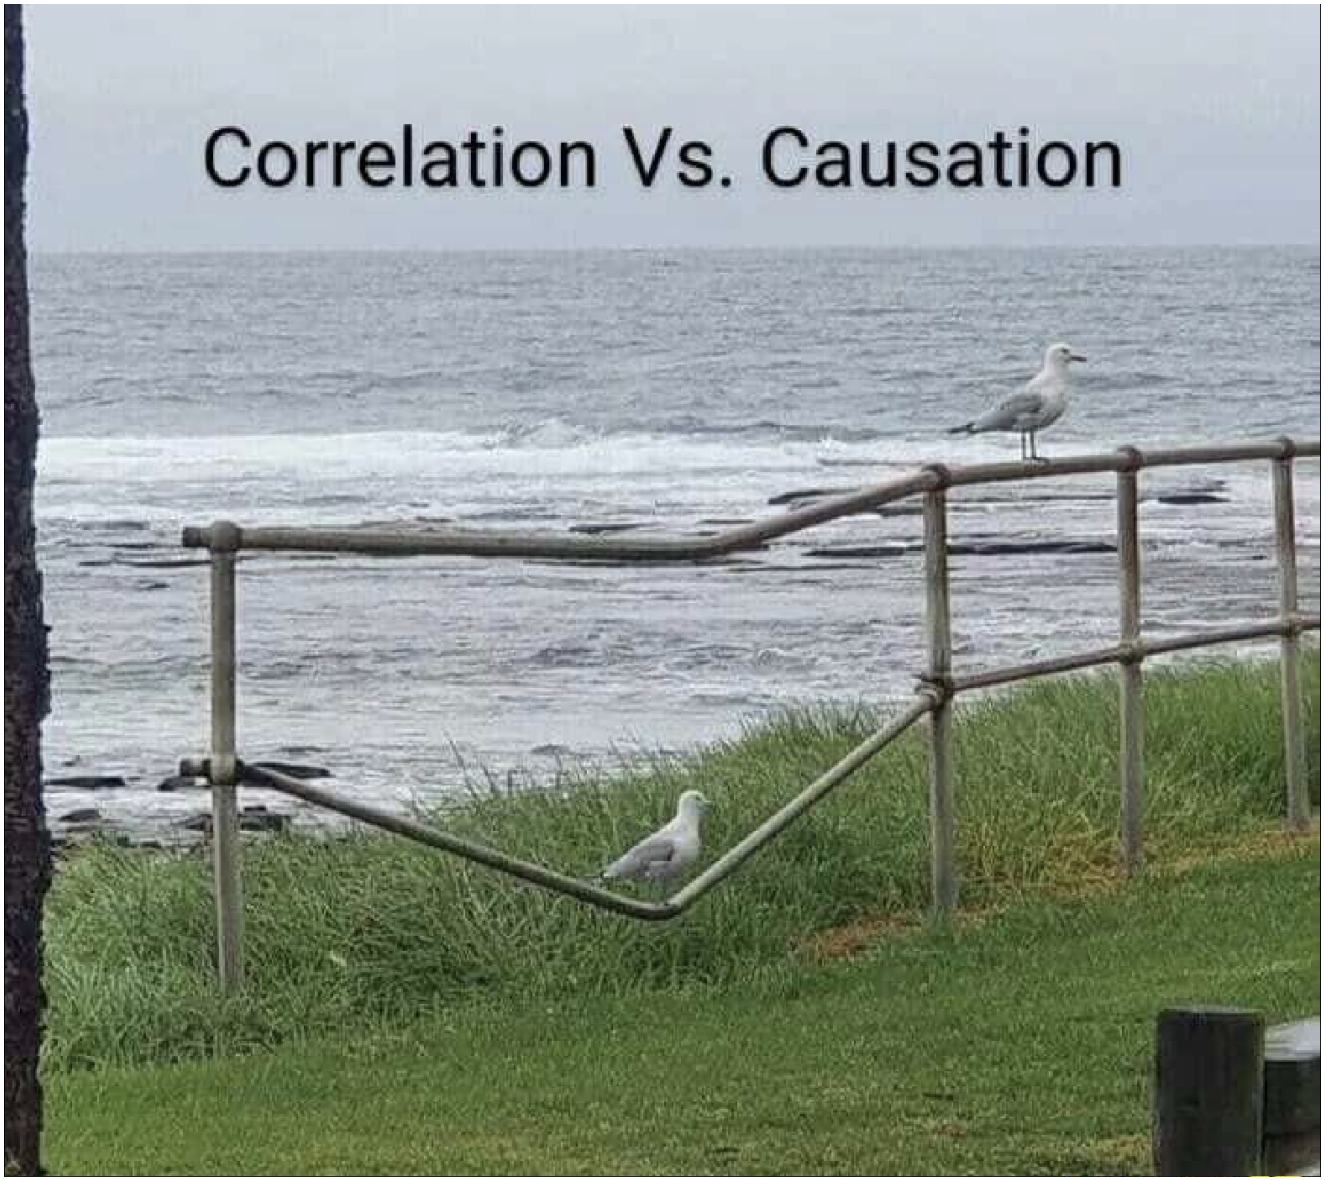

Correlaciones engañosas en la vida real

1. **Helados y ahogamientos:** las ventas de helado y las muertes por ahogamiento están altamente correlacionadas. ¿Prohibimos los helados?

Correlaciones engañosas en la vida real

1. **Helados y ahogamientos:** las ventas de helado y las muertes por ahogamiento están altamente correlacionadas. ¿Prohibimos los helados?

   No — el **calor** aumenta ambas cosas simultáneamente. La temperatura es la variable oculta que impulsa las dos.

Correlaciones engañosas en la vida real

1. **Helados y ahogamientos:** las ventas de helado y las muertes por ahogamiento están altamente correlacionadas. ¿Prohibimos los helados?

   No — el **calor** aumenta ambas cosas simultáneamente. La temperatura es la variable oculta que impulsa las dos.

2. **Más bomberos, más destrucción:** los incendios atendidos por más bomberos presentan mayor daño material. ¿Enviamos menos bomberos?

Correlaciones engañosas en la vida real

1. **Helados y ahogamientos:** las ventas de helado y las muertes por ahogamiento están altamente correlacionadas. ¿Prohibimos los helados?

   No — el **calor** aumenta ambas cosas simultáneamente. La temperatura es la variable oculta que impulsa las dos.

2. **Más bomberos, más destrucción:** los incendios atendidos por más bomberos presentan mayor daño material. ¿Enviamos menos bomberos?

   No — la **severidad del incendio** es lo que atrae más bomberos *y* causa más daño. Ambas variables responden a un mismo factor.

Correlaciones engañosas en la vida real

1. **Helados y ahogamientos:** las ventas de helado y las muertes por ahogamiento están altamente correlacionadas. ¿Prohibimos los helados?

   No — el **calor** aumenta ambas cosas simultáneamente. La temperatura es la variable oculta que impulsa las dos.

2. **Más bomberos, más destrucción:** los incendios atendidos por más bomberos presentan mayor daño material. ¿Enviamos menos bomberos?

   No — la **severidad del incendio** es lo que atrae más bomberos *y* causa más daño. Ambas variables responden a un mismo factor.

3. **Más doctores, más mortalidad:** hospitales con más personal médico reportan tasas de mortalidad más altas. ¿Reducimos personal?

Correlaciones engañosas en la vida real

1. **Helados y ahogamientos:** las ventas de helado y las muertes por ahogamiento están altamente correlacionadas. ¿Prohibimos los helados?

   No — el **calor** aumenta ambas cosas simultáneamente. La temperatura es la variable oculta que impulsa las dos.

2. **Más bomberos, más destrucción:** los incendios atendidos por más bomberos presentan mayor daño material. ¿Enviamos menos bomberos?

   No — la **severidad del incendio** es lo que atrae más bomberos *y* causa más daño. Ambas variables responden a un mismo factor.

3. **Más doctores, más mortalidad:** hospitales con más personal médico reportan tasas de mortalidad más altas. ¿Reducimos personal?

   No — la **gravedad de los pacientes** explica ambas: hospitales grandes y especializados reciben los casos más complejos.

Patrón común: en los tres casos, una **variable oculta** genera la correlación observada. Más adelante formalizaremos esto.

Correlaciones absurdas (Tyler Vigen)

El sitio tylervigen.com busca correlaciones entre series de tiempo no relacionadas:

- **Consumo per cápita de margarina** en EE.UU. $\leftrightarrow$ **Tasa de divorcio** en Maine.
  Correlación: $r \approx 0.99$.

Correlaciones absurdas (Tyler Vigen)

El sitio tylervigen.com busca correlaciones entre series de tiempo no relacionadas:

- **Consumo per cápita de margarina** en EE.UU. $\leftrightarrow$ **Tasa de divorcio** en Maine.
  Correlación: $r \approx 0.99$.
- **Películas de Nicolas Cage** por año $\leftrightarrow$ **Ahogamientos en piscinas**.
  Correlación: $r \approx 0.67$.

Correlaciones absurdas (Tyler Vigen)

El sitio tylervigen.com busca correlaciones entre series de tiempo no relacionadas:

- **Consumo per cápita de margarina** en EE.UU. $\leftrightarrow$ **Tasa de divorcio** en Maine.
  Correlación: $r \approx 0.99$.
- **Películas de Nicolas Cage** por año $\leftrightarrow$ **Ahogamientos en piscinas**.
  Correlación: $r \approx 0.67$.

Lección:

- Con suficientes series de tiempo, *siempre* encontrarás correlaciones altas entre variables sin relación alguna.
- La correlación por sí sola **no prueba nada**.
- Necesitamos un **marco causal** para distinguir relaciones genuinas de coincidencias estadísticas.

¿Por qué estudiar inferencia causal?

Las políticas públicas buscan mejorar el bienestar de la población. En un mundo de recursos limitados, necesitamos saber:

- ¿Qué programas funcionan realmente?
- ¿Cuáles son costo-efectivos?
- ¿Qué intervenciones pueden generar efectos no deseados?
- ¿Qué hubiera pasado si la política no se hubiera implementado?

Si atribuimos efectos sin causalidad, podríamos:

- Implementar políticas costosas que no funcionan.
- O descartar programas efectivos porque la evidencia estaba mal interpretada.
- Terminar con malas asignaciones de recursos públicos.

Algunas preguntas de investigación que podríamos resolver usando inferencia causal:

- ¿El PNIS redujo efectivamente la participación en economías ilegales?
- ¿Familias en Acción incrementa la asistencia escolar y mejora la nutrición infantil?

1 Motivación

2 DAGs: Visualizando la causalidad

3 Marco conceptual: Rubin Causal Model

4 ¿Qué dice y qué no dice una regresión?

5 Del caso bivariado al multivariado: OLS matricial

6 Sesgo por variable omitida

¿Qué es un DAG?

Un **Grafo Acíclico Dirigido** (DAG) es una representación gráfica de relaciones causales entre variables.

- **Nodos** = variables aleatorias.
- **Flechas** ($\rightarrow$) = efectos causales directos, en la dirección de la flecha.
- **Acíclico:** la causalidad fluye en una sola dirección (hacia adelante en el tiempo); no hay ciclos.
- La **ausencia** de una flecha entre dos nodos es un supuesto fuerte: afirmamos que *no* existe relación causal directa.

¿Qué es un DAG?

Un **Grafo Acíclico Dirigido** (DAG) es una representación gráfica de relaciones causales entre variables.

- **Nodos** = variables aleatorias.
- **Flechas** ($\rightarrow$) = efectos causales directos, en la dirección de la flecha.
- **Acíclico:** la causalidad fluye en una sola dirección (hacia adelante en el tiempo); no hay ciclos.
- La **ausencia** de una flecha entre dos nodos es un supuesto fuerte: afirmamos que *no* existe relación causal directa.

¿De dónde sale un DAG?

- Teoría económica, modelos científicos, revisión de literatura.
- Conversaciones con expertos, observaciones propias.
- Es una representación del *estado del arte* del conocimiento sobre el fenómeno estudiado.

Nuestro problema: la beca y el Saber Pro

Contexto: queremos saber si una beca de sostenimiento (D) mejora el puntaje Saber Pro (Y) de estudiantes universitarios.

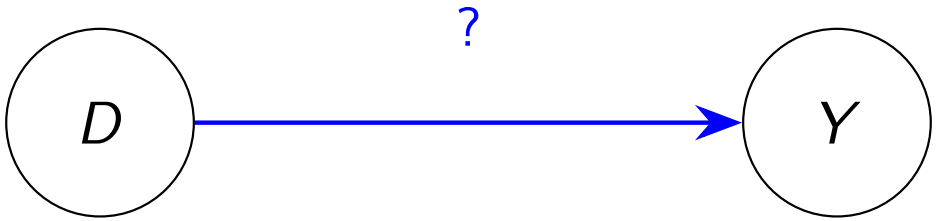

- ¿Es suficiente comparar el puntaje promedio de becados y no becados?
- ¿Qué otros factores podrían estar en juego?

Nuestro problema: la beca y el Saber Pro

Contexto: queremos saber si una beca de sostenimiento (D) mejora el puntaje Saber Pro (Y) de estudiantes universitarios.

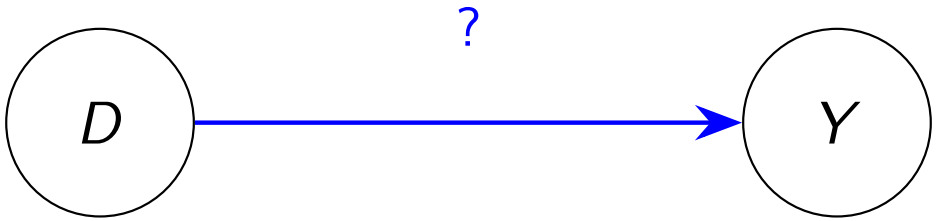

- ¿Es suficiente comparar el puntaje promedio de becados y no becados?
- ¿Qué otros factores podrían estar en juego?
- Los DAGs nos ayudan a **pensar visualmente** sobre qué puede salir mal — y qué debemos hacer para identificar el efecto causal.

Vamos a explorar tres estructuras causales clave usando este mismo ejemplo.

Confounders y backdoor paths

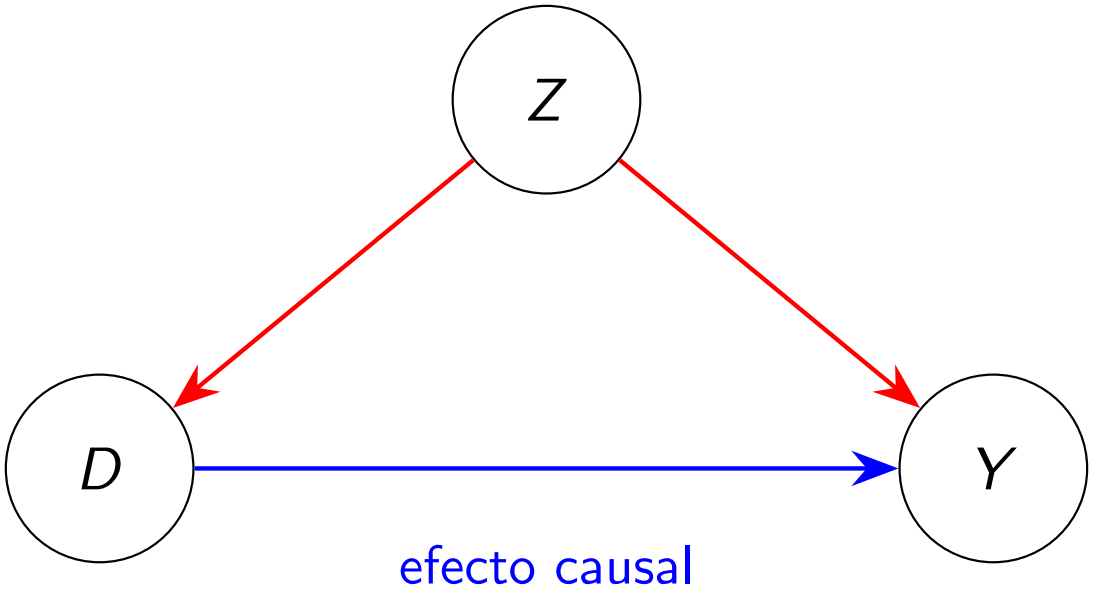

- **Camino directo (causal):** $D \to Y$ (flecha azul).
- **Backdoor path:** $D \leftarrow Z \to Y$. Crea una correlación *espuria* entre D e Y.
- Z se llama **confounder**: causa de D y de Y simultáneamente.

Confounders y backdoor paths

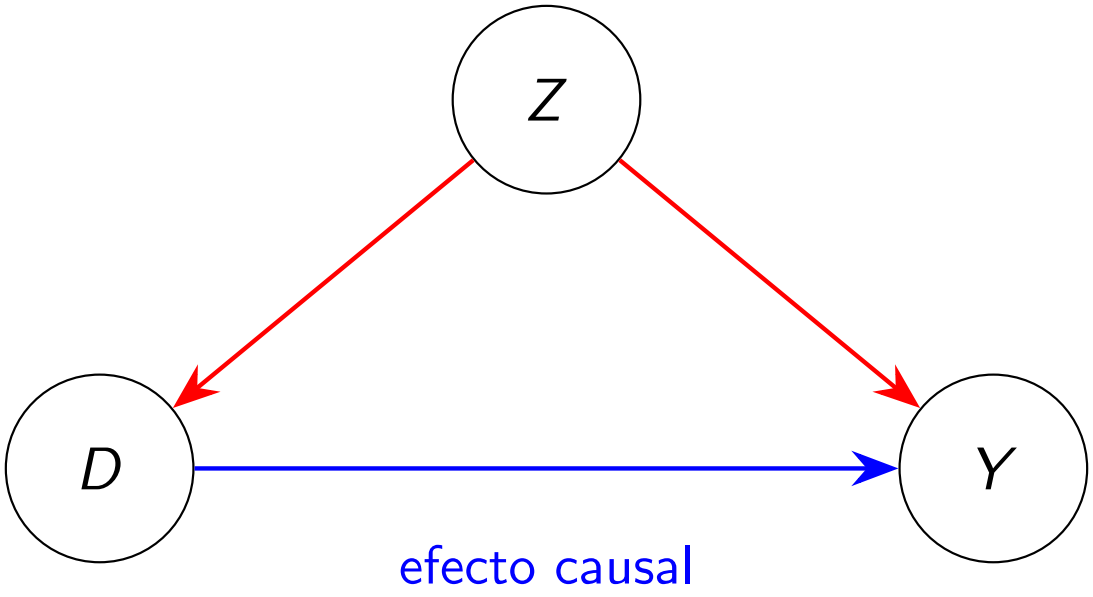

- **Camino directo (causal):** $D \to Y$ (flecha azul).
- **Backdoor path:** $D \leftarrow Z \to Y$. Crea una correlación *espuria* entre D e Y.
- Z se llama **confounder**: causa de D y de Y simultáneamente.
- **Conexión con la econometría:** un backdoor path abierto es exactamente lo que llamamos un problema de **variable omitida**. Si Z no se incluye en la regresión, su efecto se "cuela" en el coeficiente de D.

Confounder en la beca: motivación

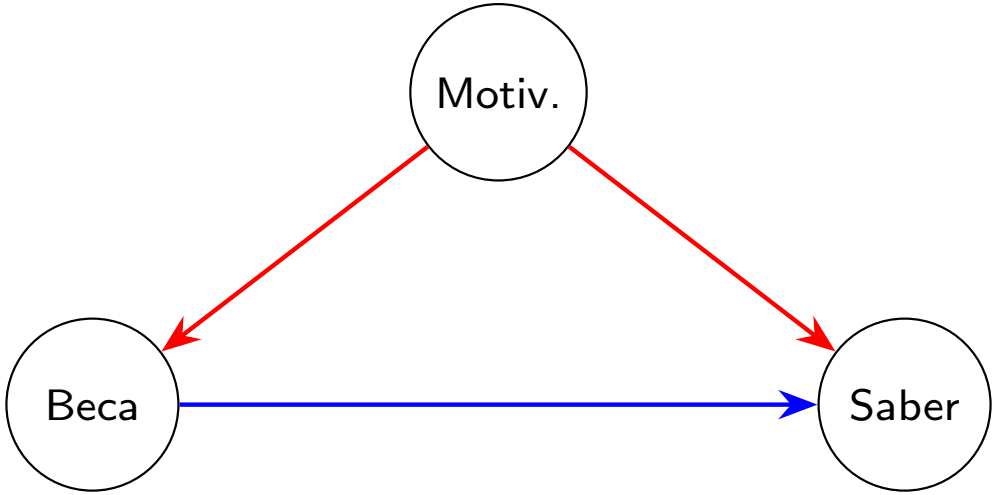

- Z = motivación del estudiante (no observada).
- Los estudiantes más motivados se inscriben **primero** al programa $\Rightarrow$ reciben la beca ($Z \to D$).
- Los estudiantes más motivados también obtienen **mejores puntajes**, con o sin beca ($Z \to Y$).

Confounder en la beca: motivación

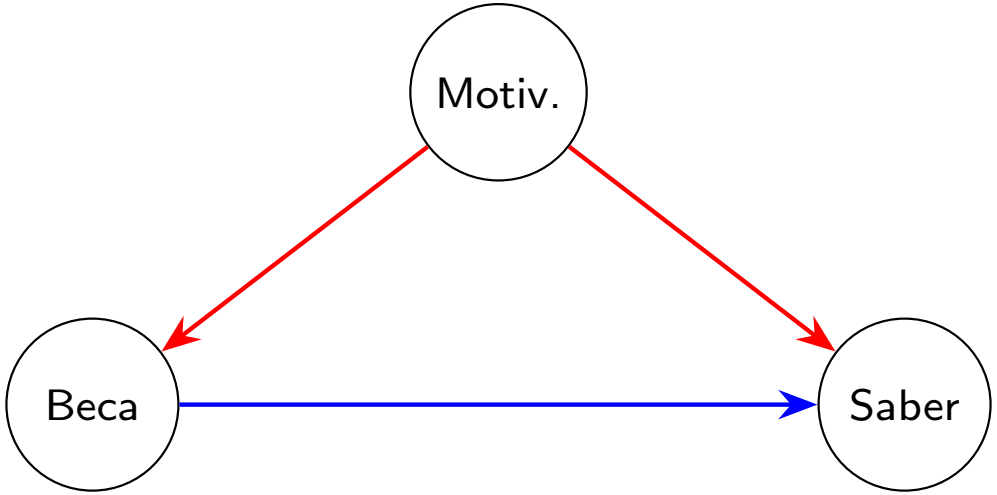

- Z = motivación del estudiante (no observada).
- Los estudiantes más motivados se inscriben **primero** al programa $\Rightarrow$ reciben la beca ($Z \to D$).
- Los estudiantes más motivados también obtienen **mejores puntajes**, con o sin beca ($Z \to Y$).
- **Backdoor path:** $D \leftarrow$ Motiv. $\to Y$. La motivación genera una correlación positiva entre beca y puntaje que *no es* el efecto de la beca.
- Si no controlamos por motivación, **sobreestimamos** el efecto de la beca.

Confounder en la beca: ingreso familiar

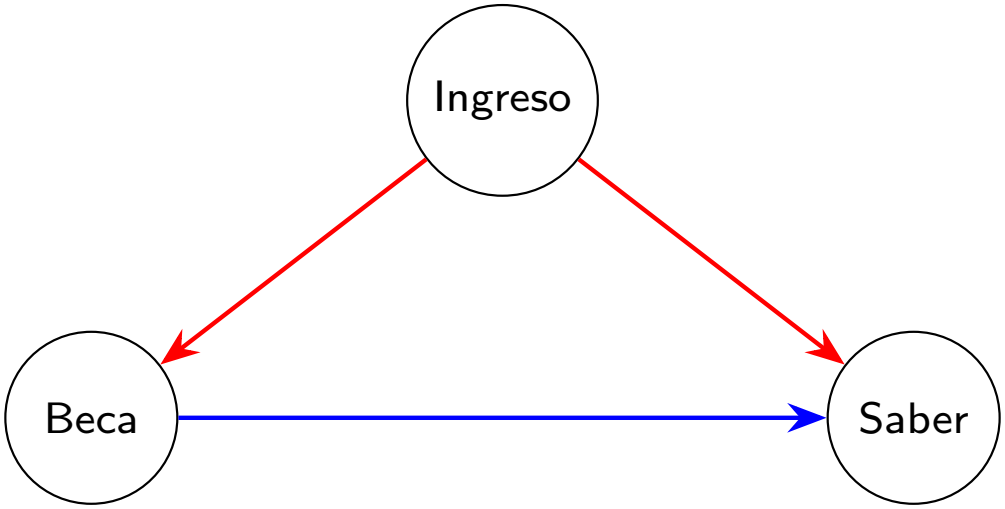

- Ahora Z = ingreso familiar del estudiante.
- Estudiantes de menores ingresos tienen **más necesidad** de la beca y se inscriben activamente.
- Pero el menor ingreso también se asocia con **peores condiciones** de estudio.

Confounder en la beca: ingreso familiar

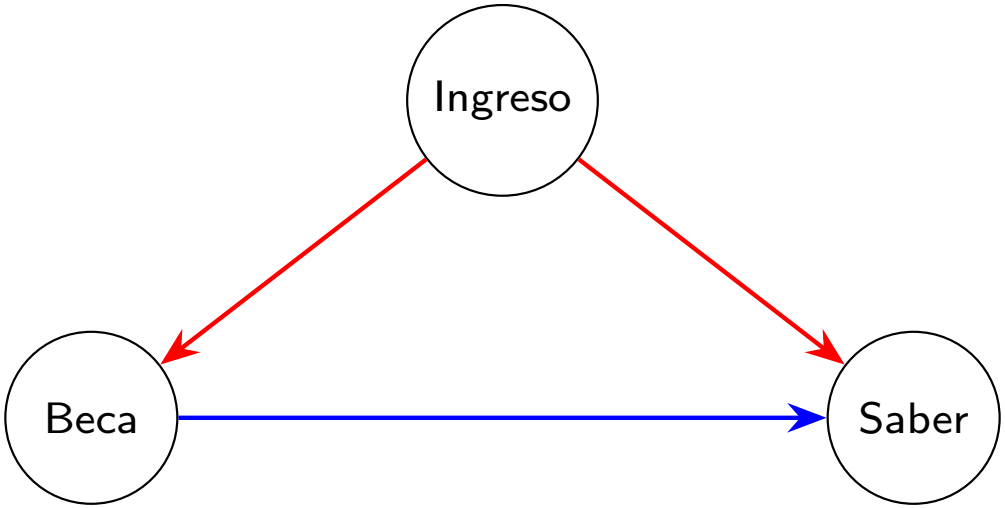

- Ahora Z = ingreso familiar del estudiante.
- Estudiantes de menores ingresos tienen **más necesidad** de la beca y se inscriben activamente.
- Pero el menor ingreso también se asocia con **peores condiciones** de estudio.
- **Resultado:** Sesgo **negativo**. OLS **subestima** el efecto de la beca.
- **Mismo mecanismo que la motivación, pero sesgo en dirección opuesta.** La dirección depende de la naturaleza del confounder.

Colliders: cuando controlar genera sesgo

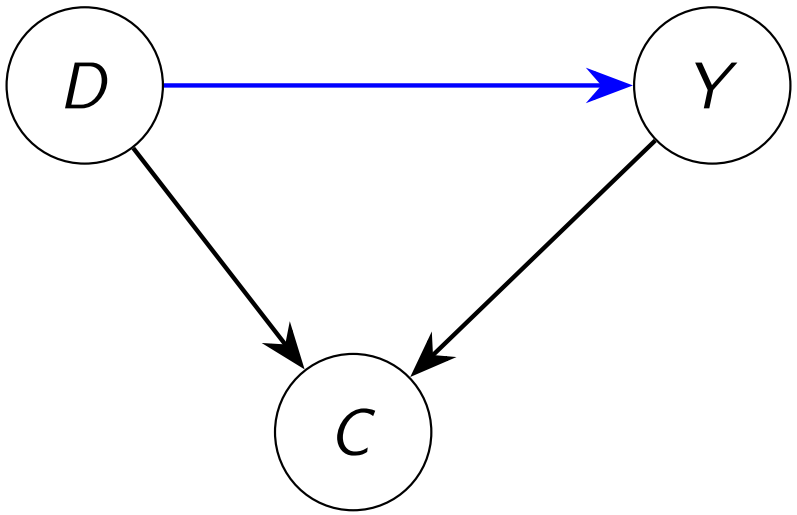

- C es un **collider**: recibe flechas de D *y* de Y.
- El camino $D \to C \leftarrow Y$ está **bloqueado** naturalmente (las flechas "chocan" en C).
- **Pero:** si condicionamos en C (lo controlamos o filtramos por C), *abrimos* el camino y **creamos** una asociación espuria.

Collider en la beca: graduación

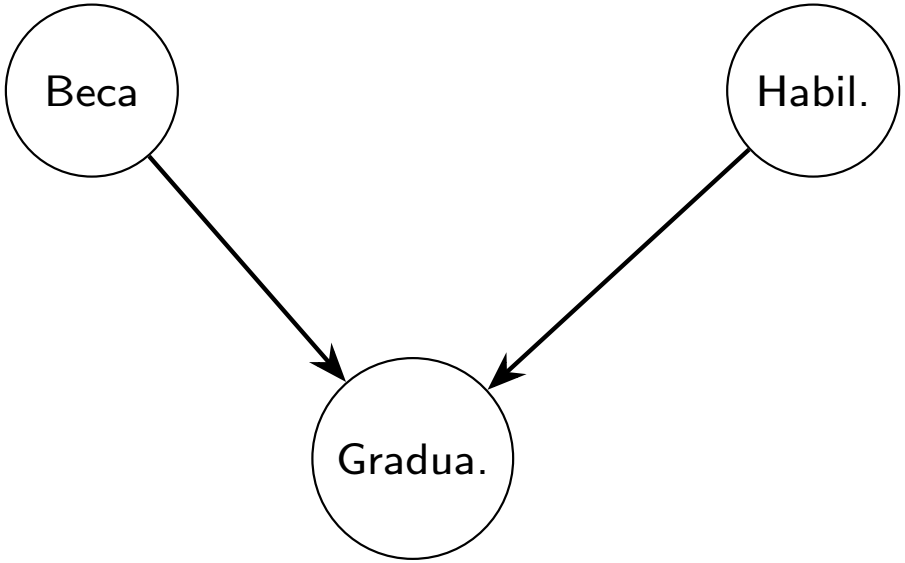

- D = recibir la beca, Y = habilidad académica innata, C = graduarse.
- Tanto la beca (recursos económicos) como la habilidad (rendimiento) ayudan a que un estudiante se gradúe: ambas causan C.

Collider en la beca: graduación

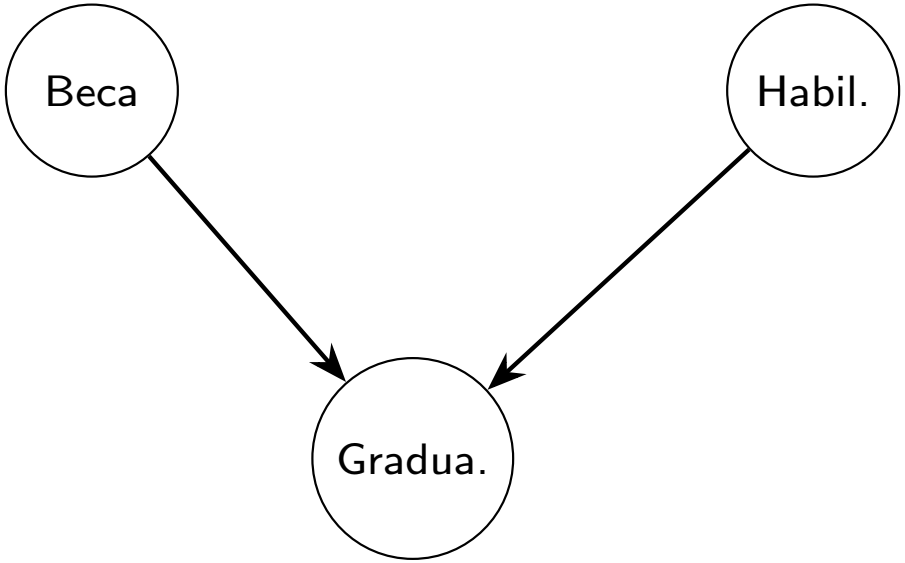

- D = recibir la beca, Y = habilidad académica innata, C = graduarse.
- Tanto la beca (recursos económicos) como la habilidad (rendimiento) ayudan a que un estudiante se gradúe: ambas causan C.
- Si analizamos **solo graduados** (condicionamos en $C = 1$), creamos una correlación espuria: entre quienes se graduaron, los becados tienden a tener menor habilidad (no la "necesitaban" para graduarse), y viceversa.

Collider en la beca: graduación

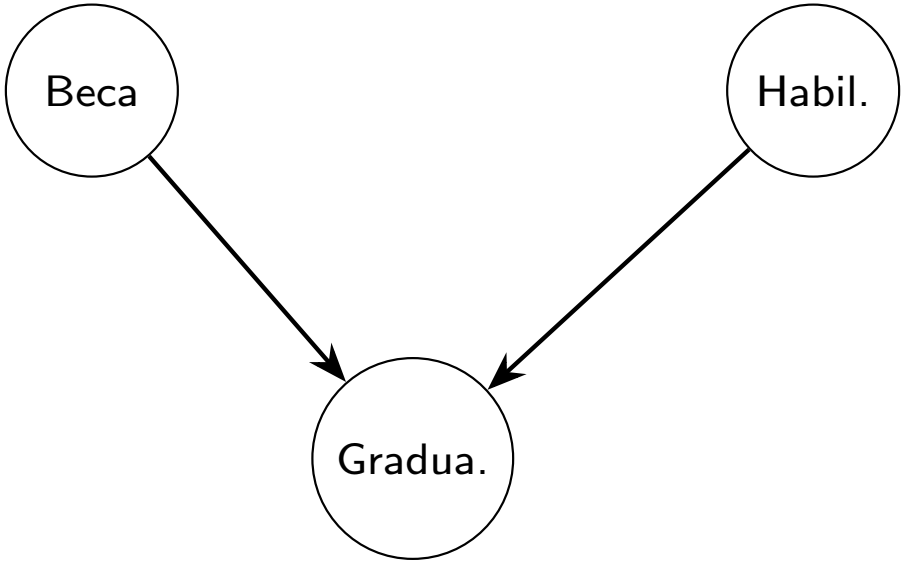

- D = recibir la beca, Y = habilidad académica innata, C = graduarse.
- Tanto la beca (recursos económicos) como la habilidad (rendimiento) ayudan a que un estudiante se gradúe: ambas causan C.
- Si analizamos **solo graduados** (condicionamos en $C = 1$), creamos una correlación espuria: entre quienes se graduaron, los becados tienden a tener menor habilidad (no la "necesitaban" para graduarse), y viceversa.
- **Lección:** restringir la muestra a graduados **abre** un camino espurio y distorsiona la relación entre beca y habilidad.

Variables mediadoras

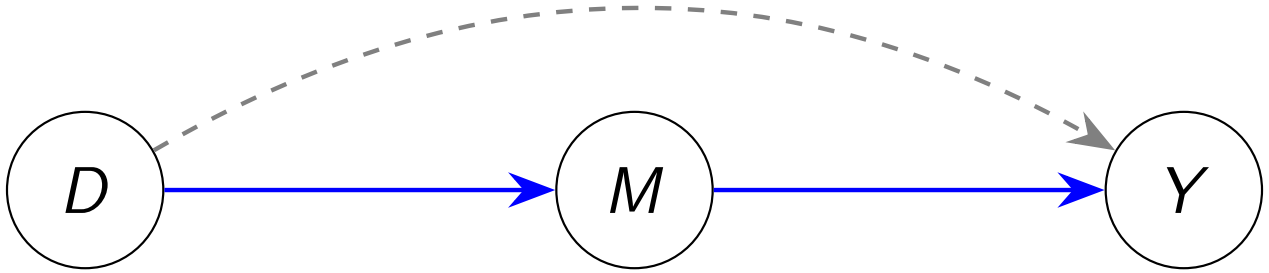

- M es un **mediador**: parte del efecto causal de D sobre Y *pasa a través* de M.
- El camino $D \to M \to Y$ es un **canal causal indirecto**; la flecha punteada $D \dashrightarrow Y$ es el **efecto directo**.
- Si controlamos por M, **bloqueamos** el canal indirecto y solo capturamos el efecto directo.

Mediador en la beca: horas de estudio

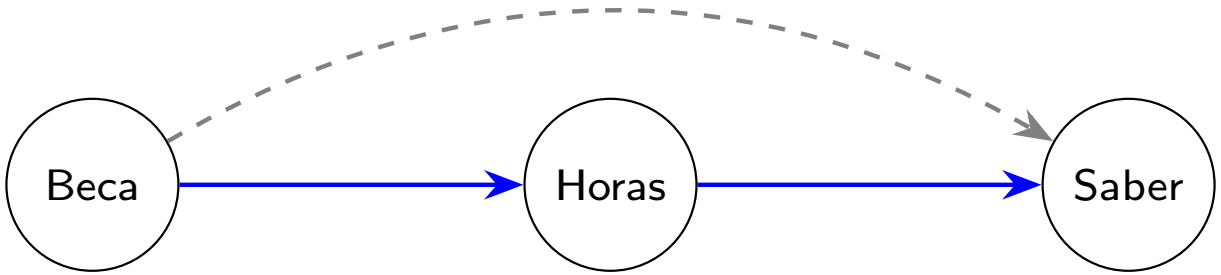

- D = beca, M = horas semanales de estudio, Y = puntaje Saber Pro.
- La beca libera tiempo (el estudiante no necesita trabajar) $\Rightarrow$ más horas de estudio $\Rightarrow$ mejor puntaje.

Mediador en la beca: horas de estudio

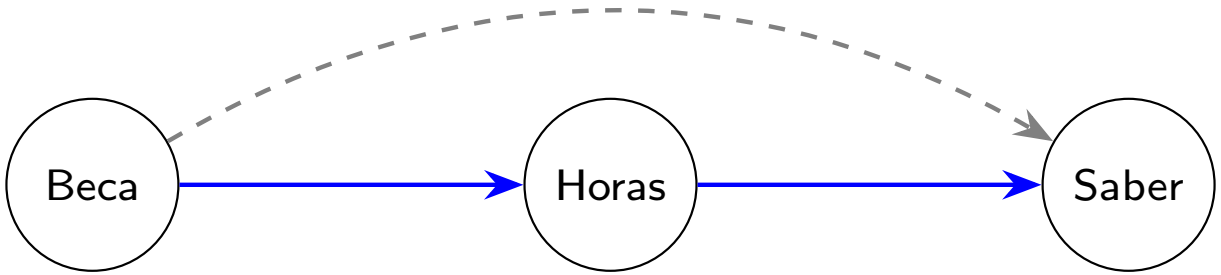

- D = beca, M = horas semanales de estudio, Y = puntaje Saber Pro.
- La beca libera tiempo (el estudiante no necesita trabajar) $\Rightarrow$ más horas de estudio $\Rightarrow$ mejor puntaje.
- **Cuidado:** si el investigador controla por horas de estudio para "aislar" el efecto de la beca, está bloqueando uno de los **canales causales legítimos** por los cuales la beca opera.

Mediador en la beca: horas de estudio

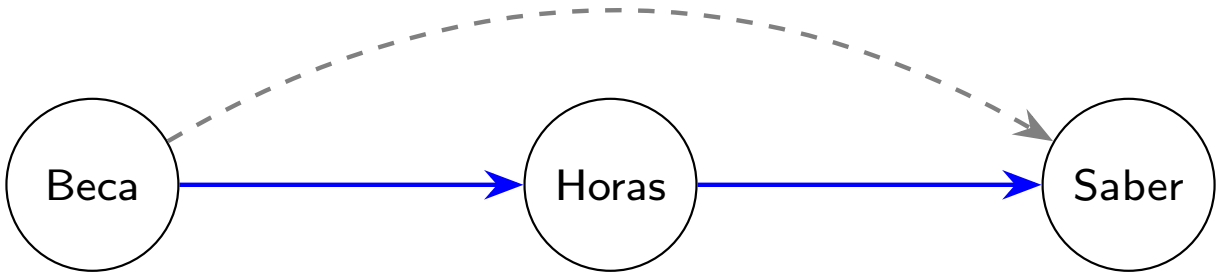

- D = beca, M = horas semanales de estudio, Y = puntaje Saber Pro.
- La beca libera tiempo (el estudiante no necesita trabajar) $\Rightarrow$ más horas de estudio $\Rightarrow$ mejor puntaje.
- **Cuidado:** si el investigador controla por horas de estudio para "aislar" el efecto de la beca, está bloqueando uno de los **canales causales legítimos** por los cuales la beca opera.
- **Regla práctica:** no controlar por mediadores cuando se quiere estimar el efecto **total** de D sobre Y.

Resumen: tres estructuras en el DAG de la beca

1. **Confounder** ($D \leftarrow Z \rightarrow Y$): la motivación o el ingreso generan un backdoor path **abierto**. Controlar Z lo **cierra** ✓.
2. **Mediador** ($D \rightarrow M \rightarrow Y$): las horas de estudio transmiten parte del efecto causal. Controlar M bloquea ese canal (no siempre es deseable).
3. **Collider** ($D \rightarrow C \leftarrow Y$): la graduación está **bloqueada** por defecto. Controlar C lo **abre** y genera sesgo $\times$.

Resumen: tres estructuras en el DAG de la beca

1. **Confounder** ($D \leftarrow Z \rightarrow Y$): la motivación o el ingreso generan un backdoor path **abierto**. Controlar Z lo **cierra** ✓.
2. **Mediador** ($D \rightarrow M \rightarrow Y$): las horas de estudio transmiten parte del efecto causal. Controlar M bloquea ese canal (no siempre es deseable).
3. **Collider** ($D \rightarrow C \leftarrow Y$): la graduación está **bloqueada** por defecto. Controlar C lo **abre** y genera sesgo $\times$.

Siguiente paso:

¿cómo formalizamos estas ideas? El **modelo de resultados potenciales** (Rubin) nos dará la notación para expresar exactamente qué es el efecto causal y qué es el sesgo.

1 Motivación

2 DAGs: Visualizando la causalidad

3 Marco conceptual: Rubin Causal Model

4 ¿Qué dice y qué no dice una regresión?

5 Del caso bivariado al multivariado: OLS matricial

6 Sesgo por variable omitida

Pregunta de investigación

Situemonos por un momento al siguiente contexto...

Pregunta de investigación

Situemonos por un momento al siguiente contexto...

Se implementa un programa de becas de sostenimiento dirigido a estudiantes universitarios de bajos recursos en universidades públicas.

Pregunta de investigación

Situemonos por un momento al siguiente contexto...

Se implementa un programa de becas de sostenimiento dirigido a estudiantes universitarios de bajos recursos en universidades públicas.

Los beneficiarios son seleccionados por orden de inscripción: solo los primeros N estudiantes inscritos reciben el apoyo financiero y a partir de la posición N+1 no reciben ningún apoyo financiero.

Pregunta de investigación

Situemonos por un momento al siguiente contexto...

Se implementa un programa de becas de sostenimiento dirigido a estudiantes universitarios de bajos recursos en universidades públicas.

Los beneficiarios son seleccionados por orden de inscripción: solo los primeros N estudiantes inscritos reciben el apoyo financiero y a partir de la posición N+1 no reciben ningún apoyo financiero.

Nuestro objetivo es estimar el efecto de este programa sobre los logros educativos, medidos a través del puntaje de las pruebas Saber Pro de los estudiantes (Y).

¿Cómo estimaríamos el efecto sin un marco causal?

Enfoque ingenuo: simplemente comparar el puntaje promedio del Saber Pro entre becados y no becados.

	Becados ($D = 1$)	No becados ($D = 0$)
Puntaje Saber Pro promedio	$\bar{Y}_1$	$\bar{Y}_0$

$$\hat{\beta}_{\text{naive}} = \bar{Y}_1 - \bar{Y}_0$$

¿Cómo estimaríamos el efecto sin un marco causal?

Enfoque ingenuo: simplemente comparar el puntaje promedio del Saber Pro entre becados y no becados.

	Becados ($D = 1$)	No becados ($D = 0$)
Puntaje Saber Pro promedio	$\bar{Y}_1$	$\bar{Y}_0$

$$\hat{\beta}_{\text{naive}} = \bar{Y}_1 - \bar{Y}_0$$

¿Por qué esto puede ser problemático?

- Los estudiantes que se inscriben primero (y reciben la beca) pueden ser **diferentes** de los que no la reciben.
- Por ejemplo: ¿son más motivados? ¿tienen mejor preparación previa? ¿son más jóvenes?
- Si estas diferencias también afectan el puntaje, la comparación simple **mezcla** el efecto de la beca con las diferencias preexistentes.

¿Cómo estimaríamos el efecto sin un marco causal?

Enfoque ingenuo: simplemente comparar el puntaje promedio del Saber Pro entre becados y no becados.

	Becados ($D = 1$)	No becados ($D = 0$)
Puntaje Saber Pro promedio	$\bar{Y}_1$	$\bar{Y}_0$

$$\hat{\beta}_{\text{naive}} = \bar{Y}_1 - \bar{Y}_0$$

¿Por qué esto puede ser problemático?

- Los estudiantes que se inscriben primero (y reciben la beca) pueden ser **diferentes** de los que no la reciben.
- Por ejemplo: ¿son más motivados? ¿tienen mejor preparación previa? ¿son más jóvenes?
- Si estas diferencias también afectan el puntaje, la comparación simple **mezcla** el efecto de la beca con las diferencias preexistentes.

Necesitamos un marco formal que nos permita separar el efecto causal de estas diferencias. Eso es exactamente lo que nos da el **modelo de resultados potenciales** (Rubin).

Notación básica

Unidades y tratamiento:

$$i = 1, \ldots, n, \qquad D_i \in \{0, 1\}$$

donde $D_i = 1$ si el estudiante recibe la beca y $D_i = 0$ en caso contrario.

Resultados potenciales:

$$Y_i(1),\ Y_i(0) \quad \text{(bien definidos)}$$

$Y_i(1)$ y $Y_i(0)$, puntaje Saber Pro con y sin beca, respectivamente.

Resultado observado:

$$Y_i \ = \ D_i\, Y_i(1) \ + \ (1 - D_i)\, Y_i(0)$$

Efecto individual (inobservable):

$$\tau_i \ = \ Y_i(1) - Y_i(0)$$

Problema fundamental

Para cada i observamos *solo uno* de $\{Y_i(1),\ Y_i(0)\}$.

El estimador ingenuo: diferencia de medias

Recordemos el enfoque que planteamos antes de introducir la notación formal. La forma más directa de evaluar el programa es comparar promedios:

$$\hat{\beta}_{\text{naive}} \;=\; \mathbb{E}[Y \mid D = 1] \;-\; \mathbb{E}[Y \mid D = 0]$$

El estimador ingenuo: diferencia de medias

Recordemos el enfoque que planteamos antes de introducir la notación formal. La forma más directa de evaluar el programa es comparar promedios:

$$\hat{\beta}_{\text{naive}} = \mathbb{E}[Y \mid D = 1] - \mathbb{E}[Y \mid D = 0]$$

En nuestro ejemplo:

- $\mathbb{E}[Y \mid D = 1]$: puntaje Saber Pro promedio de los becados.
- $\mathbb{E}[Y \mid D = 0]$: puntaje Saber Pro promedio de los no becados.

El estimador ingenuo: diferencia de medias

Recordemos el enfoque que planteamos antes de introducir la notación formal. La forma más directa de evaluar el programa es comparar promedios:

$$\hat{\beta}_{\text{naive}} = \mathbb{E}[Y \mid D = 1] - \mathbb{E}[Y \mid D = 0]$$

En nuestro ejemplo:

- $\mathbb{E}[Y \mid D = 1]$: puntaje Saber Pro promedio de los becados.
- $\mathbb{E}[Y \mid D = 0]$: puntaje Saber Pro promedio de los no becados.

Pregunta clave: ¿captura esta diferencia el efecto causal de la beca?

Para responder, necesitamos descomponer esta diferencia usando los resultados potenciales que acabamos de definir.

Descomposición de la diferencia de medias

Usando resultados potenciales, podemos escribir:

$$\underbrace{\mathbb{E}[Y \mid D=1] - \mathbb{E}[Y \mid D=0]}_{\text{Diferencia observada}} = \underbrace{\mathbb{E}[Y(1) - Y(0)]}_{\text{Efecto causal (ATE)}} + \underbrace{\Big(\mathbb{E}[Y(0) \mid D=1] - \mathbb{E}[Y(0) \mid D=0]\Big)}_{\text{Sesgo de selección}}$$

Descomposición de la diferencia de medias

Usando resultados potenciales, podemos escribir:

$$\underbrace{\mathbb{E}[Y \mid D=1] - \mathbb{E}[Y \mid D=0]}_{\text{Diferencia observada}} = \underbrace{\mathbb{E}[Y(1) - Y(0)]}_{\text{Efecto causal (ATE)}} + \underbrace{\Big(\mathbb{E}[Y(0) \mid D=1] - \mathbb{E}[Y(0) \mid D=0]\Big)}_{\text{Sesgo de selección}}$$

¿De dónde sale esta descomposición?

Se obtiene sumando y restando $\mathbb{E}[Y(0) \mid D=1]$ en el lado izquierdo:

$$Dif.Observada = \mathbb{E}[Y(1) \mid D=1] - \mathbb{E}[Y(0) \mid D=0]$$
$$Dif.Observada = \mathbb{E}[Y(1) \mid D=1] - \mathbb{E}[Y(0) \mid D=1] + \mathbb{E}[Y(0) \mid D=1] - \mathbb{E}[Y(0) \mid D=0]$$

Interpretación: efecto causal vs. sesgo de selección

$$\hat{\beta}_{\text{naive}} = \underbrace{\text{ATE}}_{\text{lo que queremos}} + \underbrace{\delta}_{\text{lo que contamina}}$$

Interpretación: efecto causal vs. sesgo de selección

$$\hat{\beta}_{\text{naive}} = \underbrace{\text{ATE}}_{\text{lo que queremos}} + \underbrace{\delta}_{\text{lo que contamina}}$$

Efecto causal (ATE):

- $\mathbb{E}[Y(1) - Y(0)]$: cambio promedio en el puntaje Saber Pro que *produciría* otorgar la beca.
- Es el objeto de interés: ¿cuánto mejora el puntaje *gracias a* la beca?

Interpretación: efecto causal vs. sesgo de selección

$$\hat{\beta}_{\text{naive}} = \underbrace{\text{ATE}}_{\text{lo que queremos}} + \underbrace{\delta}_{\text{lo que contamina}}$$

Efecto causal (ATE):

- $\mathbb{E}[Y(1) - Y(0)]$: cambio promedio en el puntaje Saber Pro que *produciría* otorgar la beca.
- Es el objeto de interés: ¿cuánto mejora el puntaje *gracias a* la beca?

Sesgo de selección (δ):

- $\mathbb{E}[Y(0) \mid D = 1] - \mathbb{E}[Y(0) \mid D = 0]$: diferencias *preexistentes* entre becados y no becados.
- Compara el puntaje que **habrían obtenido sin beca** los dos grupos.
- Si $\delta \neq 0$, la diferencia de medias **no** es el efecto causal.

Interpretación: efecto causal vs. sesgo de selección

$$\hat{\beta}_{\text{naive}} = \underbrace{\text{ATE}}_{\text{lo que queremos}} + \underbrace{\delta}_{\text{lo que contamina}}$$

Efecto causal (ATE):

- $\mathbb{E}[Y(1) - Y(0)]$: cambio promedio en el puntaje Saber Pro que *produciría* otorgar la beca.
- Es el objeto de interés: ¿cuánto mejora el puntaje *gracias a* la beca?

Sesgo de selección (δ):

- $\mathbb{E}[Y(0) \mid D = 1] - \mathbb{E}[Y(0) \mid D = 0]$: diferencias *preexistentes* entre becados y no becados.
- Compara el puntaje que **habrían obtenido sin beca** los dos grupos.
- Si $\delta \neq 0$, la diferencia de medias **no** es el efecto causal.

Ejemplo: si los becados son más motivados *ex ante*,
$\mathbb{E}[Y(0) \mid D = 1] > \mathbb{E}[Y(0) \mid D = 0]$ y $\delta > 0$: sobreestimamos el efecto.

Implicaciones: Sesgo de selección positivo

Ejemplos de mecanismos: Quienes se inscriben primero tienen mayor motivación/autoeficacia, o pueden tener mejor preparación previa (tutorías, capital académico). Es decir:

$$\mathbb{E}[Y(0) \mid D = 1] > \mathbb{E}[Y(0) \mid D = 0]$$

Entonces el término de selección es positivo:

$$\delta \equiv (\mathbb{E}[Y(0) \mid D = 1] - \mathbb{E}[Y(0) \mid D = 0]) > 0$$

Por tanto el $\hat{\beta}_{naive}$ atribuye al programa diferencias *ex ante* (motivación, preparación, acceso a información) que ya favorecían a los tratados aun sin beca.

$$\hat{\beta}_{naive} = ATE + \delta$$

Implicaciones: Sesgo de selección negativo

Ejemplos de mecanismos: se inscriben primero estudiantes con mayor necesidad financiera (madres/padres jóvenes o cuidadores) y menor capital académico.
Implica que, *ex ante*, los tratados tenían peores resultados academicos que los no tratados:

$$\mathbb{E}[Y(0) \mid D = 1] \; < \; \mathbb{E}[Y(0) \mid D = 0]$$

Entonces el término de selección es negativo:

$$\delta \; \equiv \; (\mathbb{E}[Y(0) \mid D = 1] - \mathbb{E}[Y(0) \mid D = 0]) < 0$$

Por tanto el $\hat{\beta}_{naive}$ subestima el efecto causal

$$\hat{\beta}_{naive} = ATE + \delta$$

Si $|\delta| > |\mathrm{ATE}|$, la diferencia observada puede incluso *invertir de signo* y sugerir (erróneamente) un efecto negativo.

1 Motivación

2 DAGs: Visualizando la causalidad

3 Marco conceptual: Rubin Causal Model

4 ¿Qué dice y qué no dice una regresión?

5 Del caso bivariado al multivariado: OLS matricial

6 Sesgo por variable omitida

¿Qué es una regresión?

- Hasta ahora no hemos especificado *cómo* estimar la diferencia de medias del Saber Pro entre becados y no becados.
- La forma más simple es una regresión lineal con un indicador de beca.
- Una **regresión** consiste en explicar una variable en función de otra(s) variables a través de una función (típicamente lineal).

¿Qué es una regresión?

- Hasta ahora no hemos especificado *cómo* estimar la diferencia de medias del Saber Pro entre becados y no becados.
- La forma más simple es una regresión lineal con un indicador de beca.
- Una **regresión** consiste en explicar una variable en función de otra(s) variables a través de una función (típicamente lineal).

$$y_i = \alpha + \beta_1 X_{1i} + \beta_2 X_{2i} + \varepsilon_i$$

- Y_{1i}: variable de resultado (puntaje Saber Pro).
- X_{1i}: variable de interés (beca de sostenimiento).
- X_{2i}: variable de control (GPA previo, edad, carrera, etc.).
- ε_i: término de error (toda la variación de y_i no explicada por X_{1i} y X_{2i}).

Interpretación de β_1

$$\beta_1 = \frac{\partial \mathbb{E}[Y \mid X_1, X_2]}{\partial X_1}$$

- Si X_{1i} es recibir la beca (binaria), β_1 es una *diferencia condicional de medias* entre estudiantes comparables en X_{2i} (GPA previo, carrera, cohorte, etc.).

Interpretación de β_1

$$\beta_1 = \frac{\partial \mathbb{E}[Y \mid X_1, X_2]}{\partial X_1}$$

- Si X_{1i} es recibir la beca (binaria), β_1 es una *diferencia condicional de medias* entre estudiantes comparables en X_{2i} (GPA previo, carrera, cohorte, etc.).
- **En introducción a la econometría, se suele leer:**

Interpretación de β_1

$$\beta_1 = \frac{\partial \mathbb{E}[Y \mid X_1, X_2]}{\partial X_1}$$

- Si X_{1i} es recibir la beca (binaria), β_1 es una *diferencia condicional de medias* entre estudiantes comparables en X_{2i} (GPA previo, carrera, cohorte, etc.).
- **En introducción a la econometría, se suele leer:**
  - "β_1 es el **efecto** de un cambio de X_{1i} sobre y_i"

Interpretación de β_1

$$\beta_1 = \frac{\partial \mathbb{E}[Y \mid X_1, X_2]}{\partial X_1}$$

- Si X_{1i} es recibir la beca (binaria), β_1 es una *diferencia condicional de medias* entre estudiantes comparables en X_{2i} (GPA previo, carrera, cohorte, etc.).
- **En introducción a la econometría, se suele leer:**
  - "β_1 es el **efecto** de un cambio de X_{1i} sobre y_i"
  - "Un aumento de una unidad en X_1 está **asociado** a un aumento en y_i de β_1 unidades"

Interpretación de β_1

$$\beta_1 = \frac{\partial \mathbb{E}[Y \mid X_1, X_2]}{\partial X_1}$$

- Si X_{1i} es recibir la beca (binaria), β_1 es una *diferencia condicional de medias* entre estudiantes comparables en X_{2i} (GPA previo, carrera, cohorte, etc.).
- **En introducción a la econometría, se suele leer:**
  - "β_1 es el **efecto** de un cambio de X_{1i} sobre y_i"
  - "Un aumento de una unidad en X_1 está **asociado** a un aumento en y_i de β_1 unidades"
- **¿Ven alguna diferencia entre estas dos interpretaciones?**

Interpretación de β_1

$$\beta_1 = \frac{\partial \mathbb{E}[Y \mid X_1, X_2]}{\partial X_1}$$

- Si X_{1i} es recibir la beca (binaria), β_1 es una *diferencia condicional de medias* entre estudiantes comparables en X_{2i} (GPA previo, carrera, cohorte, etc.).
- **En introducción a la econometría, se suele leer:**
  - "β_1 es el **efecto** de un cambio de X_{1i} sobre y_i"
  - "Un aumento de una unidad en X_1 está **asociado** a un aumento en y_i de β_1 unidades"
- **¿Ven alguna diferencia entre estas dos interpretaciones?**
  - "Efecto" sugiere **causalidad**.
  - "Asociado" describe **correlación** (relación estadística) sin afirmar causalidad.

Interpretación de β_1

$$\beta_1 = \frac{\partial \mathbb{E}[Y \mid X_1, X_2]}{\partial X_1}$$

- Si X_{1i} es recibir la beca (binaria), β_1 es una *diferencia condicional de medias* entre estudiantes comparables en X_{2i} (GPA previo, carrera, cohorte, etc.).
- **En introducción a la econometría, se suele leer:**
  - "β_1 es el **efecto** de un cambio de X_{1i} sobre y_i"
  - "Un aumento de una unidad en X_1 está **asociado** a un aumento en y_i de β_1 unidades"
- **¿Ven alguna diferencia entre estas dos interpretaciones?**
  - "Efecto" sugiere **causalidad**.
  - "Asociado" describe **correlación** (relación estadística) sin afirmar causalidad.
- **Clave:** misma ecuación, *dos lecturas distintas*. La causalidad depende del **diseño** y los **supuestos**, no solo de estimar una recta.

Interpretación *predictiva* de una regresión

Idea central: la lectura predictiva es **descriptiva**: no afirma causalidad; resume **correlaciones (condicionales)** presentes en los datos para pronosticar Y.

$$\hat{Y}_i = \hat{\alpha} + \hat{\beta}_1 X_{1i} + \hat{\beta}_2 X_{2i} + \cdots$$

- Optimiza **error de predicción** (p. ej., MSE/RMSE), no un parámetro causal.

Interpretación *predictiva* de una regresión

Idea central: la lectura predictiva es **descriptiva**: no afirma causalidad; resume **correlaciones (condicionales)** presentes en los datos para pronosticar Y.

$$\hat{Y}_i = \hat{\alpha} + \hat{\beta}_1 X_{1i} + \hat{\beta}_2 X_{2i} + \cdots$$

- Optimiza **error de predicción** (p. ej., MSE/RMSE), no un parámetro causal.
- Buena predicción $\Rightarrow$ capta patrones útiles aunque provengan de variables omitidas, simultaneidad o pura asociación.

Interpretación *predictiva* de una regresión

Idea central: la lectura predictiva es **descriptiva**: no afirma causalidad; resume **correlaciones (condicionales)** presentes en los datos para pronosticar Y.

$$\hat{Y}_i = \hat{\alpha} + \hat{\beta}_1 X_{1i} + \hat{\beta}_2 X_{2i} + \cdots$$

- Optimiza **error de predicción** (p. ej., MSE/RMSE), no un parámetro causal.
- Buena predicción $\Rightarrow$ capta patrones útiles aunque provengan de variables omitidas, simultaneidad o pura asociación.

¿Cuándo es útil predecir?

- Clasificar hogares por probabilidad de **pobreza** usando variables simples (techo, material de la vivienda, etc.).
- Anticipar **lluvia** a partir de nubosidad, temperatura, humedad, etc.
- *Ejemplo descriptivo (Colombia):* correlación ≈ 0.72 entre **educación de padres** y **educación de hijos**; ≈ 0.83 en **hogares pobres**.

Mensaje: la regresión predictiva "no toma partido" por mecanismos; su meta es acertar pronósticos, no identificar efectos.

Interpretación *causal* de una regresión

Más ambiciosa (y arriesgada): intenta decir *cómo funciona el mundo*, no sólo describir patrones.

Ejemplo motivador:

- "Los beneficiarios de la beca obtienen un puntaje Saber Pro **20% mayor** que los no beneficiarios." *(descriptivo/asociativo)*
- "*Otorgar* la beca **aumenta** el puntaje Saber Pro del estudiante en **20%**." *(causal)*

Interpretación *causal* de una regresión

Más ambiciosa (y arriesgada): intenta decir *cómo funciona el mundo*, no sólo describir patrones.

Ejemplo motivador:

- "Los beneficiarios de la beca obtienen un puntaje Saber Pro **20% mayor** que los no beneficiarios." *(descriptivo/asociativo)*
- "*Otorgar* la beca **aumenta** el puntaje Saber Pro del estudiante en **20%**." *(causal)*

¿Qué necesitamos para leer β_1 como efecto causal?

- Una fuente de variación exogena y supuestos que hagan creíble la interpretación causal.

Interpretación *causal* de una regresión

Más ambiciosa (y arriesgada): intenta decir *cómo funciona el mundo*, no sólo describir patrones.

Ejemplo motivador:

- "Los beneficiarios de la beca obtienen un puntaje Saber Pro **20% mayor** que los no beneficiarios." *(descriptivo/asociativo)*
- "*Otorgar* la beca **aumenta** el puntaje Saber Pro del estudiante en **20%**." *(causal)*

¿Qué necesitamos para leer β_1 como efecto causal?

- Una fuente de variación exogena y supuestos que hagan creíble la interpretación causal.

¿Qué es una variable exógena?

- Un regresor cuya variación es **independiente** de ε_i (*la asignación de la beca no está correlacionada con inobservables que afectan simultáneamente a* Y_i). Es decir, que $(\mathbb{E}[Y(0) \mid D = 1] - \mathbb{E}[Y(0) \mid D = 0]) = 0$
- Por ejemplo, si los cupos se asignan por sorteo entre las personas inscritas, en lugar de por orden de llegada.

1 Motivación

2 DAGs: Visualizando la causalidad

3 Marco conceptual: Rubin Causal Model

4 ¿Qué dice y qué no dice una regresión?

5 Del caso bivariado al multivariado: OLS matricial

6 Sesgo por variable omitida

¿Qué hemos logrado hasta aquí?

Resultado clave: bajo los supuestos del modelo clásico,

$$\mathbb{E}[\hat{\beta} \mid \mathbf{X}] = \beta$$

El estimador OLS es **insesgado**: en promedio, recupera los verdaderos parámetros poblacionales.

¿Qué hemos logrado hasta aquí?

Resultado clave: bajo los supuestos del modelo clásico,

$$\mathbb{E}[\hat{\beta} \mid \mathbf{X}] = \beta$$

El estimador OLS es **insesgado**: en promedio, recupera los verdaderos parámetros poblacionales.

Pero esto descansa en supuestos fuertes. En particular:

- El modelo está correctamente especificado (incluye *todas* las variables relevantes).
- $\mathbb{E}[\varepsilon \mid \mathbf{X}] = 0$ (exogeneidad estricta).

¿Qué hemos logrado hasta aquí?

Resultado clave: bajo los supuestos del modelo clásico,

$$\mathbb{E}[\hat{\beta} \mid \mathbf{X}] = \beta$$

El estimador OLS es **insesgado**: en promedio, recupera los verdaderos parámetros poblacionales.

Pero esto descansa en supuestos fuertes. En particular:

- El modelo está correctamente especificado (incluye *todas* las variables relevantes).
- $\mathbb{E}[\varepsilon \mid \mathbf{X}] = 0$ (exogeneidad estricta).

¿Qué ocurre cuando algún supuesto falla?

- Si **omitimos una variable relevante** que está correlacionada con los regresores, $\mathbb{E}[\hat{\beta} \mid \mathbf{X}] \neq \beta$.
- El estimador se vuelve **sesgado**, y la magnitud y dirección del sesgo dependen de la relación entre la variable omitida y las variables incluidas.

Esto nos lleva al problema de la variable omitida...

El Estimador OLS en forma matricial

La forma escalar se generaliza al caso multivariado usando notación matricial.

El Estimador OLS en forma matricial

La forma escalar se generaliza al caso multivariado usando notación matricial.

Modelo lineal:

$$\mathbf{y} = \mathbf{X}\beta + \varepsilon$$

Dimensiones:

$$\mathbf{X} : n \times k, \quad \mathbf{y} : n \times 1, \quad \hat{\beta} : k \times 1$$

El Estimador OLS en forma matricial

La forma escalar se generaliza al caso multivariado usando notación matricial.

Modelo lineal:

$$\mathbf{y} = \mathbf{X}\beta + \varepsilon$$

Dimensiones:

$$\mathbf{X} : n \times k, \quad \mathbf{y} : n \times 1, \quad \hat{\beta} : k \times 1$$

Objetivo: Minimizar la suma de los residuos al cuadrado:

$$\min_{\beta} (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta)$$

El Estimador OLS en forma matricial

La forma escalar se generaliza al caso multivariado usando notación matricial.

Modelo lineal:

$$\mathbf{y} = \mathbf{X}\beta + \varepsilon$$

Dimensiones:

$$\mathbf{X} : n \times k, \quad \mathbf{y} : n \times 1, \quad \hat{\beta} : k \times 1$$

Objetivo: Minimizar la suma de los residuos al cuadrado:

$$\min_{\beta} (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta)$$

Solución analítica:

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

El Estimador OLS en forma matricial

La forma escalar se generaliza al caso multivariado usando notación matricial.

Modelo lineal:

$$\mathbf{y} = \mathbf{X}\beta + \varepsilon$$

Dimensiones:

$$\mathbf{X} : n \times k, \quad \mathbf{y} : n \times 1, \quad \hat{\beta} : k \times 1$$

Objetivo: Minimizar la suma de los residuos al cuadrado:

$$\min_{\beta} (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta)$$

Solución analítica:

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

Interpretación

$\hat{\beta}$ es el vector de coeficientes que mejor ajusta $\mathbf{y}$ en el sentido de mínimos cuadrados, siempre que $\mathbf{X}'\mathbf{X}$ sea invertible.

Derivación del Estimador OLS (matricial)

Problema de optimización: encontrar los coeficientes β que minimizan la suma de los residuos al cuadrado:

$$S(\beta) = \sum_{i=1}^{n} (y_i - x_i'\beta)^2 = \varepsilon'\varepsilon = (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta)$$

Derivación del Estimador OLS (matricial)

Problema de optimización: encontrar los coeficientes β que minimizan la suma de los residuos al cuadrado:

$$S(\beta) = \sum_{i=1}^{n} (y_i - x_i'\beta)^2 = \varepsilon'\varepsilon = (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta)$$

1. **Expandimos el producto cuadrático:**

$$S(\beta) = \mathbf{y}'\mathbf{y} - 2\beta'\mathbf{X}'\mathbf{y} + \beta'(\mathbf{X}'\mathbf{X})\beta$$

Derivación del Estimador OLS (matricial)

Problema de optimización: encontrar los coeficientes β que minimizan la suma de los residuos al cuadrado:

$$S(\beta) = \sum_{i=1}^{n} (y_i - x_i'\beta)^2 = \varepsilon'\varepsilon = (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta)$$

1. **Expandimos el producto cuadrático:**

$$S(\beta) = \mathbf{y}'\mathbf{y} - 2\beta'\mathbf{X}'\mathbf{y} + \beta'(\mathbf{X}'\mathbf{X})\beta$$

2. **Derivamos con respecto a β:**

$$\frac{\partial S(\beta)}{\partial \beta} = -2\mathbf{X}'\mathbf{y} + 2\mathbf{X}'\mathbf{X}\beta$$

Derivación del Estimador OLS (matricial)

Problema de optimización: encontrar los coeficientes β que minimizan la suma de los residuos al cuadrado:

$$S(\beta) = \sum_{i=1}^{n} (y_i - x_i'\beta)^2 = \varepsilon'\varepsilon = (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta)$$

1. **Expandimos el producto cuadrático:**

$$S(\beta) = \mathbf{y}'\mathbf{y} - 2\beta'\mathbf{X}'\mathbf{y} + \beta'(\mathbf{X}'\mathbf{X})\beta$$

2. **Derivamos con respecto a β:**

$$\frac{\partial S(\beta)}{\partial \beta} = -2\mathbf{X}'\mathbf{y} + 2\mathbf{X}'\mathbf{X}\beta$$

3. **Igualamos a cero (condición de primer orden):**

$$\mathbf{X}'\mathbf{X}\beta = \mathbf{X}'\mathbf{y}$$

Derivación del Estimador OLS (matricial)

Problema de optimización: encontrar los coeficientes β que minimizan la suma de los residuos al cuadrado:

$$S(\beta) = \sum_{i=1}^{n} (y_i - x_i'\beta)^2 = \varepsilon'\varepsilon = (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta)$$

1. **Expandimos el producto cuadrático:**

$$S(\beta) = \mathbf{y}'\mathbf{y} - 2\beta'\mathbf{X}'\mathbf{y} + \beta'(\mathbf{X}'\mathbf{X})\beta$$

2. **Derivamos con respecto a β:**

$$\frac{\partial S(\beta)}{\partial \beta} = -2\mathbf{X}'\mathbf{y} + 2\mathbf{X}'\mathbf{X}\beta$$

3. **Igualamos a cero (condición de primer orden):**

$$\mathbf{X}'\mathbf{X}\beta = \mathbf{X}'\mathbf{y}$$

4. **Solución (ecuaciones normales):**

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

1 Motivación

2 DAGs: Visualizando la causalidad

3 Marco conceptual: Rubin Causal Model

4 ¿Qué dice y qué no dice una regresión?

5 Del caso bivariado al multivariado: OLS matricial

6 Sesgo por variable omitida

Sesgo por variable omitida

Modelo verdadero (con omitidas):

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{Z}\phi + \mathbf{u}, \qquad \mathbb{E}[\mathbf{u} \mid \mathbf{X}, \mathbf{Z}] = \mathbf{0}$$

Sesgo por variable omitida

Modelo verdadero (con omitidas):

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{Z}\phi + \mathbf{u}, \qquad \mathbb{E}[\mathbf{u} \mid \mathbf{X}, \mathbf{Z}] = \mathbf{0}$$

Modelo estimado (omite Z):

$$\mathbf{y} = \mathbf{X}\tilde{\beta} + \tilde{\mathbf{u}}$$

Sesgo por variable omitida

Modelo verdadero (con omitidas):

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{Z}\phi + \mathbf{u}, \qquad \mathbb{E}[\mathbf{u} \mid \mathbf{X}, \mathbf{Z}] = \mathbf{0}$$

Modelo estimado (omite Z):

$$\mathbf{y} = \mathbf{X}\tilde{\beta} + \tilde{\mathbf{u}}$$

Estimador OLS con omitidas:

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

Sesgo por variable omitida

Modelo verdadero (con omitidas):

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{Z}\phi + \mathbf{u}, \qquad \mathbb{E}[\mathbf{u} \mid \mathbf{X}, \mathbf{Z}] = \mathbf{0}$$

Modelo estimado (omite Z):

$$\mathbf{y} = \mathbf{X}\tilde{\beta} + \tilde{\mathbf{u}}$$

Estimador OLS con omitidas:

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

Sustituyendo y del modelo verdadero:

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\beta + \mathbf{Z}\phi + \mathbf{u})$$

Sesgo por variable omitida

Modelo verdadero (con omitidas):

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{Z}\phi + \mathbf{u}, \qquad \mathbb{E}[\mathbf{u} \mid \mathbf{X}, \mathbf{Z}] = \mathbf{0}$$

Modelo estimado (omite Z):

$$\mathbf{y} = \mathbf{X}\tilde{\beta} + \tilde{\mathbf{u}}$$

Estimador OLS con omitidas:

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

Sustituyendo y del modelo verdadero:

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\beta + \mathbf{Z}\phi + \mathbf{u})$$

Resolviendo se obtiene:

$$\hat{\beta} = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Z}\phi + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}$$

Esperanza del estimador con variable omitida

Aplicando esperanza condicional:

$$\mathbb{E}[\hat{\beta} \mid \mathbf{X}, \mathbf{Z}] = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Z}\phi + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbb{E}[\mathbf{u} \mid \mathbf{X}, \mathbf{Z}]$$

Esperanza del estimador con variable omitida

Aplicando esperanza condicional:

$$\mathbb{E}[\hat{\beta} \mid \mathbf{X}, \mathbf{Z}] = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Z}\phi + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbb{E}[\mathbf{u} \mid \mathbf{X}, \mathbf{Z}]$$

Por exogenidad: $\mathbb{E}[\mathbf{u} \mid \mathbf{X}, \mathbf{Z}] = \mathbf{0}$

$$\mathbb{E}[\hat{\beta} \mid \mathbf{X}, \mathbf{Z}] = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Z}\phi$$

Esperanza del estimador con variable omitida

Aplicando esperanza condicional:

$$\mathbb{E}[\hat{\beta} \mid \mathbf{X}, \mathbf{Z}] = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Z}\phi + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbb{E}[\mathbf{u} \mid \mathbf{X}, \mathbf{Z}]$$

Por exogenidad: $\mathbb{E}[\mathbf{u} \mid \mathbf{X}, \mathbf{Z}] = \mathbf{0}$

$$\mathbb{E}[\hat{\beta} \mid \mathbf{X}, \mathbf{Z}] = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Z}\phi$$

Por expectativas iteradas (Fijando Z y condicionando en X):

$$\mathbb{E}[\hat{\beta} \mid \mathbf{X}] = \beta + \underbrace{(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Z}}_{\text{Cor}(\mathbf{X},\mathbf{Z})}\phi$$

Esperanza del estimador con variable omitida

Aplicando esperanza condicional:

$$\mathbb{E}[\hat{\beta} \mid \mathbf{X}, \mathbf{Z}] = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Z}\phi + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbb{E}[\mathbf{u} \mid \mathbf{X}, \mathbf{Z}]$$

Por exogenidad: $\mathbb{E}[\mathbf{u} \mid \mathbf{X}, \mathbf{Z}] = \mathbf{0}$

$$\mathbb{E}[\hat{\beta} \mid \mathbf{X}, \mathbf{Z}] = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Z}\phi$$

Por expectativas iteradas (Fijando Z y condicionando en X):

$$\mathbb{E}[\hat{\beta} \mid \mathbf{X}] = \beta + \underbrace{(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Z}}_{\text{Cor}(\mathbf{X},\mathbf{Z})}\phi$$

En el caso univariado: $\delta = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Z}$

$$\mathbb{E}[\hat{\beta} \mid \mathbf{X}] = \beta + \delta \cdot \phi$$

OVB en el DAG de la beca

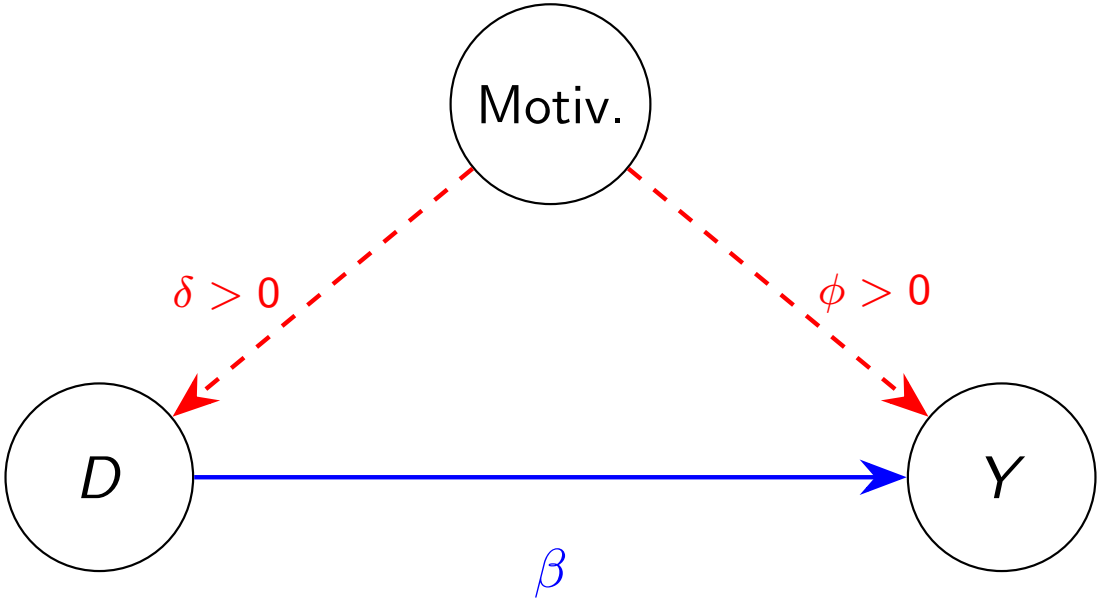

- Z = Motivación (no observada): $\delta > 0$ (más motivados se inscriben primero) y $\phi > 0$ (motivación mejora el puntaje).
- **Sesgo** $= \delta \cdot \phi > 0 \Rightarrow$ OLS **sobreestima** el efecto de la beca.

OVB en el DAG de la beca

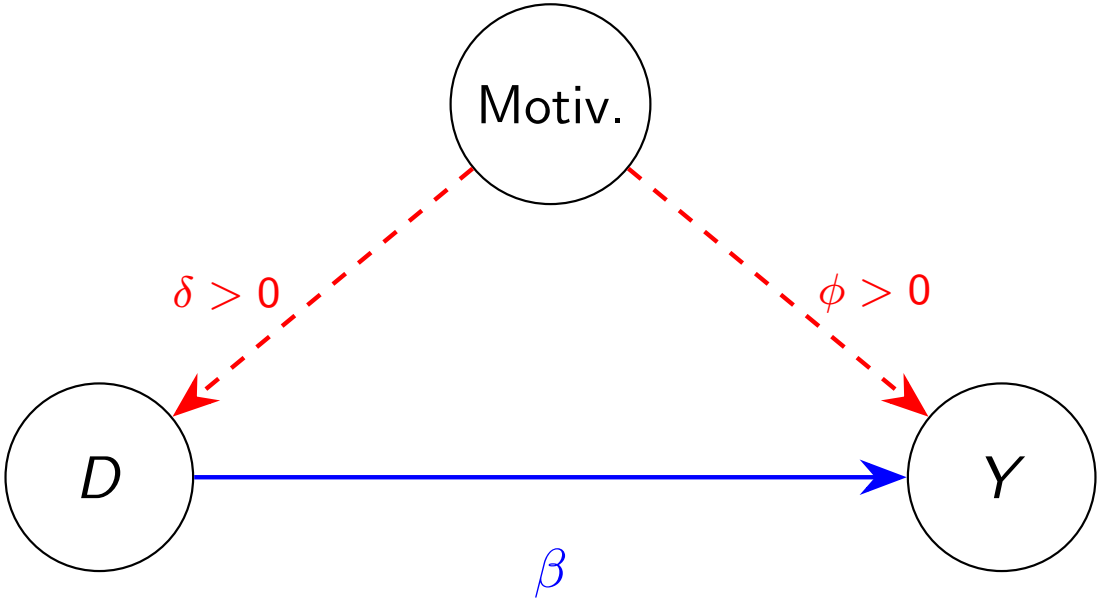

- Z = Motivación (no observada): $\delta > 0$ (más motivados se inscriben primero) y $\phi > 0$ (motivación mejora el puntaje).
- **Sesgo** $= \delta \cdot \phi > 0 \Rightarrow$ OLS **sobreestima** el efecto de la beca.
- Esto es el **sesgo de selección positivo** derivado con resultados potenciales:

$$\hat{\beta}_{naive} = \text{ATE} + \underbrace{\delta \cdot \phi}_{>0}$$

- El DAG y la fórmula de OVB nos dicen lo mismo: el backdoor path abierto $D \leftarrow Z \rightarrow Y$ genera sesgo.

¿Cómo cambia el sesgo según el mecanismo de asignación?

El signo y la magnitud del sesgo dependen de *quién* recibe el tratamiento y *por qué*. Exploremos variaciones:

¿Cómo cambia el sesgo según el mecanismo de asignación?

El signo y la magnitud del sesgo dependen de *quién* recibe el tratamiento y *por qué*. Exploremos variaciones:

Escenario A — Asignación por orden de llegada (caso base):

- Los más motivados se inscriben primero $\Rightarrow \delta > 0$, $\phi > 0 \Rightarrow$ sesgo **positivo**.

¿Cómo cambia el sesgo según el mecanismo de asignación?

El signo y la magnitud del sesgo dependen de *quién* recibe el tratamiento y *por qué*. Exploremos variaciones:

Escenario A — Asignación por orden de llegada (caso base):

- Los más motivados se inscriben primero $\Rightarrow \delta > 0$, $\phi > 0 \Rightarrow$ sesgo **positivo**.

Escenario B — Asignación por necesidad económica (focalización):

- Se seleccionan los estudiantes más vulnerables. Estos pueden tener menor capital académico *ex ante*.
- $\delta < 0$ (tratados con peores condiciones iniciales), $\phi > 0 \Rightarrow$ sesgo **negativo**: OLS **subestima** el efecto.

¿Cómo cambia el sesgo según el mecanismo de asignación?

El signo y la magnitud del sesgo dependen de *quién* recibe el tratamiento y *por qué*. Exploremos variaciones:

Escenario A — Asignación por orden de llegada (caso base):

- Los más motivados se inscriben primero $\Rightarrow \delta > 0$, $\phi > 0 \Rightarrow$ sesgo **positivo**.

Escenario B — Asignación por necesidad económica (focalización):

- Se seleccionan los estudiantes más vulnerables. Estos pueden tener menor capital académico *ex ante*.
- $\delta < 0$ (tratados con peores condiciones iniciales), $\phi > 0 \Rightarrow$ sesgo **negativo**: OLS **subestima** el efecto.

Escenario C — Asignación aleatoria (lotería):

- La beca no está correlacionada con ninguna característica previa.
- $\delta = 0 \Rightarrow$ **sin sesgo**. La diferencia de medias *es* el efecto causal.

¿Cómo cambia el sesgo según el mecanismo de asignación?

El signo y la magnitud del sesgo dependen de *quién* recibe el tratamiento y *por qué*. Exploremos variaciones:

Escenario A — Asignación por orden de llegada (caso base):

- Los más motivados se inscriben primero $\Rightarrow \delta > 0$, $\phi > 0 \Rightarrow$ sesgo **positivo**.

Escenario B — Asignación por necesidad económica (focalización):

- Se seleccionan los estudiantes más vulnerables. Estos pueden tener menor capital académico *ex ante*.
- $\delta < 0$ (tratados con peores condiciones iniciales), $\phi > 0 \Rightarrow$ sesgo **negativo**: OLS **subestima** el efecto.

Escenario C — Asignación aleatoria (lotería):

- La beca no está correlacionada con ninguna característica previa.
- $\delta = 0 \Rightarrow$ **sin sesgo**. La diferencia de medias *es* el efecto causal.

Mensaje

El diseño de la asignación determina si podemos interpretar OLS causalmente. La aleatorización elimina el sesgo de selección.

Síntesis: dirección del sesgo por variable omitida

Habiendo visto el ejemplo concreto, podemos generalizar. **El sesgo depende de dos factores:**

- La correlación entre la variable de interés X y la variable omitida Z (signo de δ).
- El efecto causal de la variable omitida Z sobre Y (signo de ϕ).

Síntesis: dirección del sesgo por variable omitida

Habiendo visto el ejemplo concreto, podemos generalizar. **El sesgo depende de dos factores:**

- La correlación entre la variable de interés X y la variable omitida Z (signo de δ).
- El efecto causal de la variable omitida Z sobre Y (signo de ϕ).

$$\text{Sesgo} = \delta \cdot \phi$$

Correlación X–Z (δ)	Efecto $Z \to Y$ (ϕ)	Dirección del sesgo en $\hat{\beta}$
Positiva	Positiva	$+$ (sobreestima β)
Negativa	Positiva	$-$ (subestima β)
Positiva	Negativa	$-$ (subestima β)
Negativa	Negativa	$+$ (sobreestima β)

Síntesis: dirección del sesgo por variable omitida

Habiendo visto el ejemplo concreto, podemos generalizar. **El sesgo depende de dos factores:**

- La correlación entre la variable de interés X y la variable omitida Z (signo de δ).
- El efecto causal de la variable omitida Z sobre Y (signo de ϕ).

$$\text{Sesgo} = \delta \cdot \phi$$

Correlación X–Z (δ)	Efecto $Z \to Y$ (ϕ)	Dirección del sesgo en $\hat{\beta}$
Positiva	Positiva	$+$ (sobreestima β)
Negativa	Positiva	$-$ (subestima β)
Positiva	Negativa	$-$ (subestima β)
Negativa	Negativa	$+$ (sobreestima β)

Aplicación rápida: en el escenario de la beca con asignación por necesidad, $\delta < 0$ y $\phi > 0$, confirmamos sesgo negativo ($\delta \cdot \phi < 0$).

Preparación para la próxima clase...

Elección del artículo académico

- **Hoy:** los estudiantes revisan la bibliografía cargada y piensan su tema de interés.
- **Próxima clase:** definimos quién presenta el artículo del *RCT* y asignaremos los responsables de los temas de las semanas siguientes.

Para aprovechar al máximo la próxima sesión, por favor:

- **Entorno de Trabajo Instalado**
  - R (versión 4.0 o superior)
  - RStudio (Paquetes: `tidyverse` y `rio`)
- **Revisar Material Compartido**
  - Introducción a R: Disponible [aquí]
  - Manipulación de Datos con `dplyr`: Disponible [aquí]
  - Gestión y Organización de Datos: Disponible [aquí]
  - Lectura y Escritura de Datos: Disponible [aquí]

Referencias esenciales

- Angrist, J., & Pischke, J.-S. (2009). *Mostly Harmless Econometrics*. Princeton.
- Bernal, R., & Peña, X. (2011). *Guía práctica para la evaluación de impacto*. Universidad de los Andes.
- Cunningham, S. (2021). *Causal Inference: The Mixtape*. Yale University Press.
- Gertler, P., Martinez, S., Premand, P., Rawlings, L., & Vermeersch, C. (2017). *La evaluación de impacto en la práctica* (2ª ed.). Banco Mundial.
- Hernán, M., & Robins, J. (2020). *Causal Inference*. Chapman & Hall/CRC (libro abierto).
- Imbens, G., & Rubin, D. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences*. CUP.
- Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2ª ed.). Cambridge.
- Rubin, D. B. (1974). *Estimating Causal Effects of Treatments in Randomized and Nonrandomized Studies*. J. Educ. Psychology.