Inferencia, Causalidad y Políticas Públicas
ECO-60116

Week 02: Experimentos Aleatorios Controlados (RCTs)

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

April 17, 2026

Roadmap

1. Experimentos Aleatorios Controlados (RCTs)
   - El RCT como solución al problema causal
   - Diseño Experimental
   - Estimación del Efecto
   - Limitaciones y/o Amenazas a la Validez
2. Incentives Work: Getting Teachers to Come to School
   - Este Paper
   - Diseño Experimental
   - Datos
   - Resultados
3. Hands-on: replicar el RCT en R

RECAP

- **Efecto individual:** $\tau_i = Y_i(1) - Y_i(0)$.
- **Problema fundamental de la inferencia causal:** para cada unidad i sólo se observa uno de los dos resultados potenciales.

$$Y_i \;=\; D_i\, Y_i(1) \;+\; (1 - D_i)\, Y_i(0)$$

RECAP

- **Efecto individual:** $\tau_i = Y_i(1) - Y_i(0)$.
- **Problema fundamental de la inferencia causal:** para cada unidad i sólo se observa uno de los dos resultados potenciales.

$$Y_i \;=\; D_i\, Y_i(1) \;+\; (1 - D_i)\, Y_i(0)$$

- **Diferencia de medias observada:**

$$\underbrace{\mathbb{E}[Y \mid D = 1] - \mathbb{E}[Y \mid D = 0]}_{\text{Diferencia observada}} = \underbrace{\mathbb{E}[Y(1) - Y(0)]}_{\text{Efecto causal (ATE)}} + \underbrace{\Big(\mathbb{E}[Y(0) \mid D = 1] - \mathbb{E}[Y(0) \mid D = 0]\Big)}_{\text{Sesgo de selección}}$$

RECAP

- **Efecto individual:** $\tau_i = Y_i(1) - Y_i(0)$.
- **Problema fundamental de la inferencia causal:** para cada unidad i sólo se observa uno de los dos resultados potenciales.

$$Y_i \;=\; D_i\, Y_i(1) \;+\; (1 - D_i)\, Y_i(0)$$

- **Diferencia de medias observada:**

$$\underbrace{\mathbb{E}[Y \mid D = 1] - \mathbb{E}[Y \mid D = 0]}_{\text{Diferencia observada}} = \underbrace{\mathbb{E}[Y(1) - Y(0)]}_{\text{Efecto causal (ATE)}} + \underbrace{\Big(\mathbb{E}[Y(0) \mid D = 1] - \mathbb{E}[Y(0) \mid D = 0]\Big)}_{\text{Sesgo de selección}}$$

- **Condición clave para interpretación causal:** se requiere *variación exógena* en D_i (diseño/identificación), no basta con estimar una regresión.

$$\mathbb{E}[\varepsilon \mid \mathbf{X}] = 0$$

RECAP

- **Efecto individual:** $\tau_i = Y_i(1) - Y_i(0)$.
- **Problema fundamental de la inferencia causal:** para cada unidad i sólo se observa uno de los dos resultados potenciales.

$$Y_i \;=\; D_i\, Y_i(1) \;+\; (1 - D_i)\, Y_i(0)$$

- **Diferencia de medias observada:**

$$\underbrace{\mathbb{E}[Y \mid D = 1] - \mathbb{E}[Y \mid D = 0]}_{\text{Diferencia observada}} = \underbrace{\mathbb{E}[Y(1) - Y(0)]}_{\text{Efecto causal (ATE)}} + \underbrace{\Big(\mathbb{E}[Y(0) \mid D = 1] - \mathbb{E}[Y(0) \mid D = 0]\Big)}_{\text{Sesgo de selección}}$$

- **Condición clave para interpretación causal:** se requiere *variación exógena* en D_i (diseño/identificación), no basta con estimar una regresión.

$$\mathbb{E}[\varepsilon \mid \mathbf{X}] = 0$$

- **Bajo exogeneidad:** el estimador de Mínimos Cuadrados Ordinarios (OLS) es insesgado.

$$\mathbb{E}[\hat{\beta} \mid \mathbf{X}] = \beta$$

Roadmap

1. Experimentos Aleatorios Controlados (RCTs)
   - El RCT como solución al problema causal
   - Diseño Experimental
   - Estimación del Efecto
   - Limitaciones y/o Amenazas a la Validez
2. Incentives Work: Getting Teachers to Come to School
   - Este Paper
   - Diseño Experimental
   - Datos
   - Resultados
3. Hands-on: replicar el RCT en R

¿Dónde nos quedamos?

En la semana pasada dejamos abierto un problema:

- **Problema fundamental:** nunca observamos $Y_i(1)$ y $Y_i(0)$ simultáneamente.

¿Dónde nos quedamos?

En la semana pasada dejamos abierto un problema:

- **Problema fundamental:** nunca observamos $Y_i(1)$ y $Y_i(0)$ simultáneamente.
- **Lo que queremos estimar es el contrafactual:** ¿qué habrían obtenido los tratados si no hubieran sido tratados? Formalmente, $\mathbb{E}[Y(0) \mid D = 1]$.

¿Dónde nos quedamos?

En la semana pasada dejamos abierto un problema:

- **Problema fundamental:** nunca observamos $Y_i(1)$ y $Y_i(0)$ simultáneamente.
- **Lo que queremos estimar es el contrafactual:** ¿qué habrían obtenido los tratados si no hubieran sido tratados? Formalmente, $\mathbb{E}[Y(0) \mid D = 1]$.
- **El sesgo de selección aparece** cuando la asignación D *no es independiente* de los resultados potenciales:

$$\mathbb{E}[Y(0) \mid D = 1] \neq \mathbb{E}[Y(0) \mid D = 0]$$

- **Consecuencia:** la diferencia de medias observada contamina el ATE con δ.

¿Dónde nos quedamos?

En la semana pasada dejamos abierto un problema:

- **Problema fundamental:** nunca observamos $Y_i(1)$ y $Y_i(0)$ simultáneamente.
- **Lo que queremos estimar es el contrafactual:** ¿qué habrían obtenido los tratados si no hubieran sido tratados? Formalmente, $\mathbb{E}[Y(0) \mid D = 1]$.
- **El sesgo de selección aparece** cuando la asignación D *no es independiente* de los resultados potenciales:

$$\mathbb{E}[Y(0) \mid D = 1] \neq \mathbb{E}[Y(0) \mid D = 0]$$

- **Consecuencia:** la diferencia de medias observada contamina el ATE con δ.
- **Origen del problema:** D está correlacionado con variables no observadas que afectan Y —el clásico sesgo por variable omitida.

¿Dónde nos quedamos?

En la semana pasada dejamos abierto un problema:

- **Problema fundamental:** nunca observamos $Y_i(1)$ y $Y_i(0)$ simultáneamente.
- **Lo que queremos estimar es el contrafactual:** ¿qué habrían obtenido los tratados si no hubieran sido tratados? Formalmente, $\mathbb{E}[Y(0) \mid D = 1]$.
- **El sesgo de selección aparece** cuando la asignación D *no es independiente* de los resultados potenciales:

$$\mathbb{E}[Y(0) \mid D = 1] \neq \mathbb{E}[Y(0) \mid D = 0]$$

- **Consecuencia:** la diferencia de medias observada contamina el ATE con δ.
- **Origen del problema:** D está correlacionado con variables no observadas que afectan Y —el clásico sesgo por variable omitida.

Pregunta motivadora de esta semana

¿Existe algún **mecanismo de asignación** que garantice, *por diseño*, que el sesgo de selección sea cero —sin necesidad de observar ni controlar por las variables relevantes?

La aleatorización en el lenguaje de los DAGs

Antes (asignación por orden de llegada): la motivación (Z) influye en la beca y en el puntaje.

Sin aleatorización

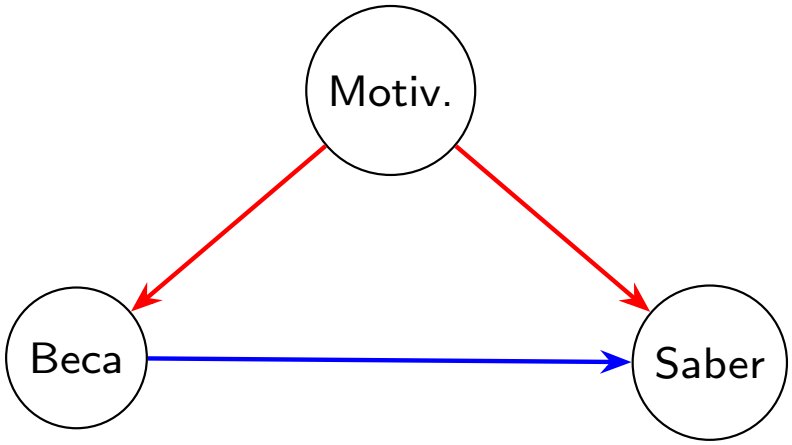

Sesgo por variable omitida: $\delta \cdot \phi \neq 0$

Con aleatorización

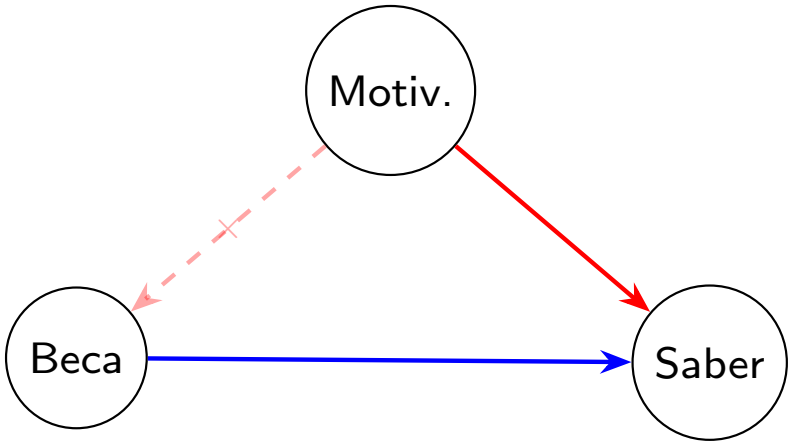

La lotería rompe la correlación entre D y Z: $\delta = 0$

La aleatorización en el lenguaje de los DAGs

Antes (asignación por orden de llegada): la motivación (Z) influye en la beca y en el puntaje.

Sin aleatorización

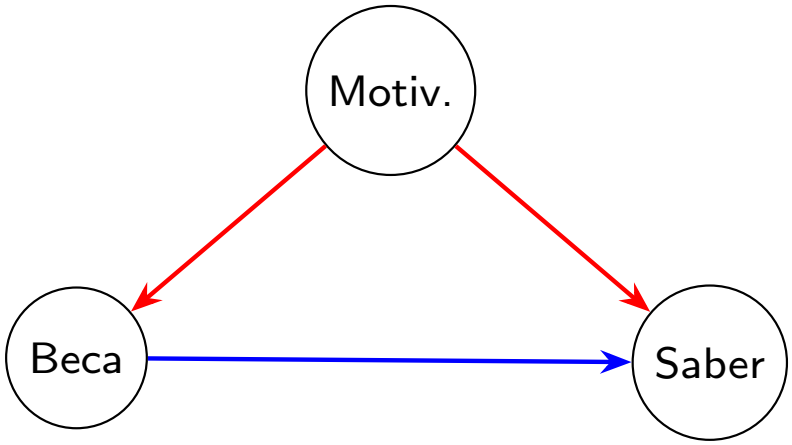

Sesgo por variable omitida: $\delta \cdot \phi \neq 0$

Con aleatorización

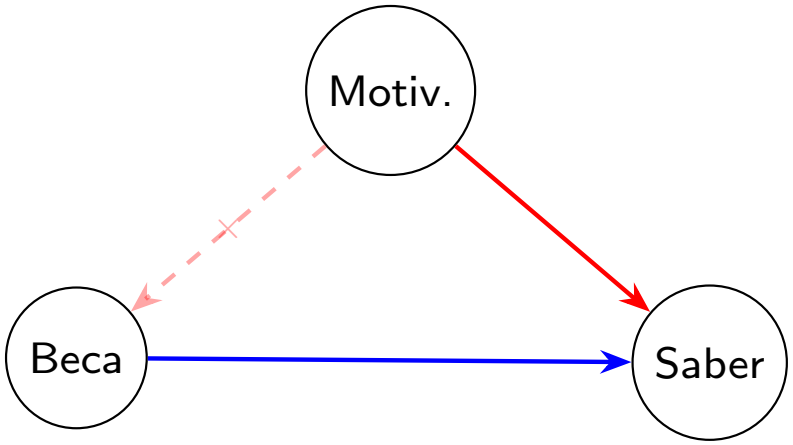

La lotería rompe la correlación entre D y Z: $\delta = 0$

Lo que hace la aleatorización: rompe *por diseño* cualquier correlación entre D y las variables no observadas. Independientemente de cuántas haya, de si las observamos o no, **ninguna** puede predecir el tratamiento.

La aleatorización en el lenguaje de los DAGs

Antes (asignación por orden de llegada): la motivación (Z) influye en la beca y en el puntaje.

Sin aleatorización

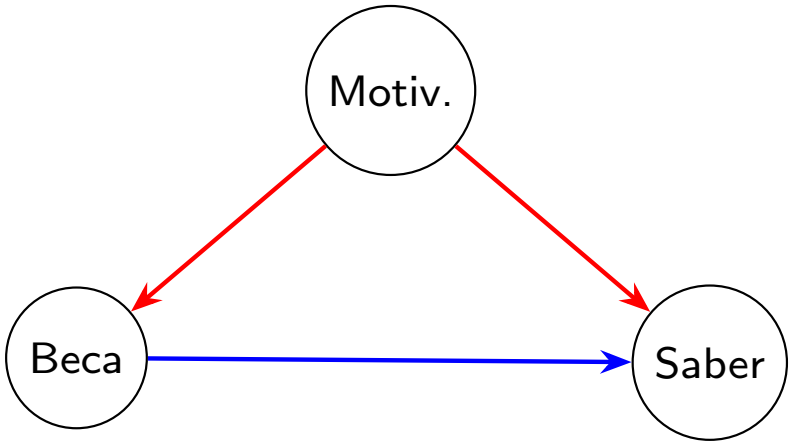

Sesgo por variable omitida: $\delta \cdot \phi \neq 0$

Con aleatorización

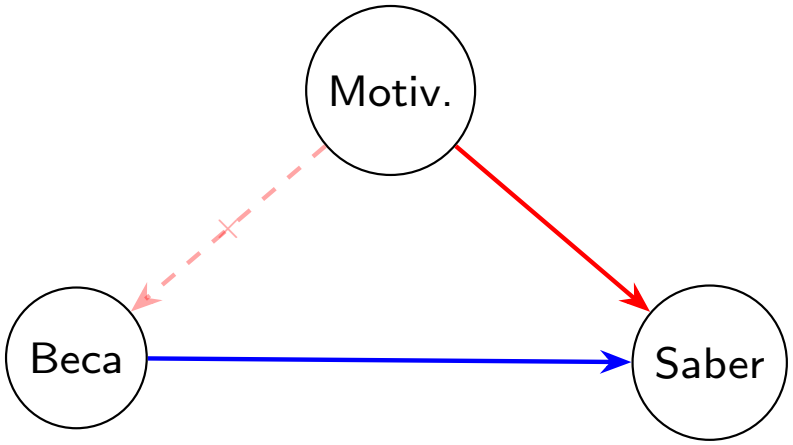

La lotería rompe la correlación entre D y Z: $\delta = 0$

Lo que hace la aleatorización: rompe *por diseño* cualquier correlación entre D y las variables no observadas. Independientemente de cuántas haya, de si las observamos o no, **ninguna** puede predecir el tratamiento.

Consecuencia: el sesgo por variable omitida se elimina **por construcción**. Ya no hace falta *controlar* por Z; basta con *aleatorizar*.

La aleatorización en el lenguaje del RCM

La misma idea, expresada con resultados potenciales:

Independencia por diseño:

$$D_i \perp\!\!\!\perp \{Y_i(0),\ Y_i(1)\}$$

La aleatorización en el lenguaje del RCM

La misma idea, expresada con resultados potenciales:

Independencia por diseño:

$$D_i \perp\!\!\!\perp \{Y_i(0),\, Y_i(1)\}$$

Implicación inmediata:

$$\mathbb{E}[Y(0) \mid D = 1] \;=\; \mathbb{E}[Y(0) \mid D = 0] \;=\; \mathbb{E}[Y(0)]$$

El sesgo de selección δ **es cero por construcción**.

La aleatorización en el lenguaje del RCM

La misma idea, expresada con resultados potenciales:

Independencia por diseño:

$$D_i \perp\!\!\!\perp \{Y_i(0),\, Y_i(1)\}$$

Implicación inmediata:

$$\mathbb{E}[Y(0) \mid D = 1] \;=\; \mathbb{E}[Y(0) \mid D = 0] \;=\; \mathbb{E}[Y(0)]$$

El sesgo de selección δ **es cero por construcción**.

Interpretación como contrafactual: el grupo de control es, en valor esperado, el *contrafactual* del grupo tratado —lo que los tratados habrían obtenido de no haber sido tratados.

La aleatorización en el lenguaje del RCM

La misma idea, expresada con resultados potenciales:

Independencia por diseño:

$$D_i \perp\!\!\!\perp \{Y_i(0),\, Y_i(1)\}$$

Implicación inmediata:

$$\mathbb{E}[Y(0) \mid D = 1] \;=\; \mathbb{E}[Y(0) \mid D = 0] \;=\; \mathbb{E}[Y(0)]$$

El sesgo de selección δ **es cero por construcción**.

Interpretación como contrafactual: el grupo de control es, en valor esperado, el *contrafactual* del grupo tratado —lo que los tratados habrían obtenido de no haber sido tratados.

La diferencia de medias identifica el ATE:

$$\underbrace{\mathbb{E}[Y \mid D = 1] - \mathbb{E}[Y \mid D = 0]}_{\text{lo que observamos}} \;=\; \underbrace{\mathbb{E}[Y(1) - Y(0)]}_{\text{ATE}} + \underbrace{0}_{\delta \text{ eliminado por diseño}}$$

La aleatorización en el lenguaje del RCM

La misma idea, expresada con resultados potenciales:

Independencia por diseño:

$$D_i \perp\!\!\!\perp \{Y_i(0),\, Y_i(1)\}$$

Implicación inmediata:

$$\mathbb{E}[Y(0) \mid D = 1] \;=\; \mathbb{E}[Y(0) \mid D = 0] \;=\; \mathbb{E}[Y(0)]$$

El sesgo de selección δ **es cero por construcción**.

Interpretación como contrafactual: el grupo de control es, en valor esperado, el *contrafactual* del grupo tratado —lo que los tratados habrían obtenido de no haber sido tratados.

La diferencia de medias identifica el ATE:

$$\underbrace{\mathbb{E}[Y \mid D = 1] - \mathbb{E}[Y \mid D = 0]}_{\text{lo que observamos}} \;=\; \underbrace{\mathbb{E}[Y(1) - Y(0)]}_{\text{ATE}} + \underbrace{0}_{\delta \text{ eliminado por diseño}}$$

Síntesis: La aleatorización resuelve el problema de variables omitidas, porque rompe por diseño cualquier correlación entre D y ellas.

Tres propiedades que hereda el RCT

De la condición $D_i \perp\!\!\!\perp \{Y_i(0), Y_i(1)\}$ se siguen tres propiedades que hacen del RCT el diseño más transparente para inferencia causal:

Tres propiedades que hereda el RCT

De la condición $D_i \perp\!\!\!\perp \{Y_i(0), Y_i(1)\}$ se siguen tres propiedades que hacen del RCT el diseño más transparente para inferencia causal:

1. **Balance en observables** (verificable con datos):

$$\mathbb{E}[X \mid D = 1] \;=\; \mathbb{E}[X \mid D = 0] \quad \forall X \text{ predeterminado}$$

Podemos *comprobarlo* comparando medias de covariables en línea base.

Tres propiedades que hereda el RCT

De la condición $D_i \perp\!\!\!\perp \{Y_i(0), Y_i(1)\}$ se siguen tres propiedades que hacen del RCT el diseño más transparente para inferencia causal:

1. **Balance en observables** (verificable con datos):

$$\mathbb{E}[X \mid D = 1] \;=\; \mathbb{E}[X \mid D = 0] \quad \forall X \text{ predeterminado}$$

Podemos *comprobarlo* comparando medias de covariables en línea base.

2. **Balance en no observables** (implicado por el diseño):

$$\mathbb{E}[U \mid D = 1] \;=\; \mathbb{E}[U \mid D = 0]$$

No podemos verificarlo con datos, pero la aleatorización lo garantiza en valor esperado. **Esta es la ventaja fundamental** sobre los métodos observacionales.

Tres propiedades que hereda el RCT

De la condición $D_i \perp\!\!\!\perp \{Y_i(0), Y_i(1)\}$ se siguen tres propiedades que hacen del RCT el diseño más transparente para inferencia causal:

1. **Balance en observables** (verificable con datos):

$$\mathbb{E}[X \mid D = 1] \;=\; \mathbb{E}[X \mid D = 0] \quad \forall X \text{ predeterminado}$$

Podemos *comprobarlo* comparando medias de covariables en línea base.

2. **Balance en no observables** (implicado por el diseño):

$$\mathbb{E}[U \mid D = 1] \;=\; \mathbb{E}[U \mid D = 0]$$

No podemos verificarlo con datos, pero la aleatorización lo garantiza en valor esperado. **Esta es la ventaja fundamental** sobre los métodos observacionales.

3. **Identificación sin supuestos funcionales:**

$$\widehat{ATE} \;=\; \bar{Y}_{D=1} - \bar{Y}_{D=0}$$

No necesitamos modelar Y, ni asumir linealidad, ni especificar una forma funcional. **La identificación viene del diseño, no del modelo.**

Por eso el RCT se conoce como el "gold standard" de la evaluación de impacto.

SUTVA: el supuesto que sostiene todo esto

Todo lo anterior descansa en un supuesto silencioso: **SUTVA** (*Stable Unit Treatment Value Assumption*).

SUTVA: el supuesto que sostiene todo esto

Todo lo anterior descansa en un supuesto silencioso: **SUTVA** (*Stable Unit Treatment Value Assumption*).

SUTVA tiene dos componentes:

1. **No interferencia entre unidades:** el resultado potencial de la unidad i depende *solo* de su propio tratamiento D_i, no del tratamiento de otras unidades.

$$Y_i(D_1, D_2, \ldots, D_N) \;=\; Y_i(D_i)$$

SUTVA: el supuesto que sostiene todo esto

Todo lo anterior descansa en un supuesto silencioso: **SUTVA** (*Stable Unit Treatment Value Assumption*).

SUTVA tiene dos componentes:

1. **No interferencia entre unidades:** el resultado potencial de la unidad i depende *solo* de su propio tratamiento D_i, no del tratamiento de otras unidades.
$$Y_i(D_1, D_2, \ldots, D_N) \;=\; Y_i(D_i)$$

2. **Una sola versión del tratamiento:** $D_i = 1$ significa *lo mismo* para toda unidad tratada (no hay dosis distintas, variantes, ni intensidades).

SUTVA: el supuesto que sostiene todo esto

Todo lo anterior descansa en un supuesto silencioso: **SUTVA** (*Stable Unit Treatment Value Assumption*).

SUTVA tiene dos componentes:

1. **No interferencia entre unidades:** el resultado potencial de la unidad i depende *solo* de su propio tratamiento D_i, no del tratamiento de otras unidades.
$$Y_i(D_1, D_2, \ldots, D_N) \;=\; Y_i(D_i)$$

2. **Una sola versión del tratamiento:** $D_i = 1$ significa *lo mismo* para toda unidad tratada (no hay dosis distintas, variantes, ni intensidades).

¿Cuándo falla SUTVA?

- *No interferencia:* vacunación (externalidades biológicas), programas educativos dentro del aula (interacción entre estudiantes), mercados laborales (equilibrio general).

SUTVA: el supuesto que sostiene todo esto

Todo lo anterior descansa en un supuesto silencioso: **SUTVA** (*Stable Unit Treatment Value Assumption*).

SUTVA tiene dos componentes:

1. **No interferencia entre unidades:** el resultado potencial de la unidad i depende *solo* de su propio tratamiento D_i, no del tratamiento de otras unidades.
$$Y_i(D_1, D_2, \ldots, D_N) \;=\; Y_i(D_i)$$

2. **Una sola versión del tratamiento:** $D_i = 1$ significa *lo mismo* para toda unidad tratada (no hay dosis distintas, variantes, ni intensidades).

¿Cuándo falla SUTVA?

- *No interferencia:* vacunación (externalidades biológicas), programas educativos dentro del aula (interacción entre estudiantes), mercados laborales (equilibrio general).
- *Versión única:* si "recibir la beca" significa cosas distintas para unos y otros (ej. distintos montos o servicios asociados).

Hoy entra en escena un paper

Para ver cada pieza *encarnada* en un caso real, usaremos como hilo conductor:

Duflo, Hanna & Ryan (2012)

"Incentives Work: Getting Teachers to Come to School"
American Economic Review, 102(4): 1241–1278.

La pregunta: ¿pueden el monitoreo tecnológico y los incentivos financieros reducir el ausentismo docente y mejorar el aprendizaje?

Hoy entra en escena un paper

Para ver cada pieza *encarnada* en un caso real, usaremos como hilo conductor:

Duflo, Hanna & Ryan (2012)

"Incentives Work: Getting Teachers to Come to School"
American Economic Review, 102(4): 1241–1278.

La pregunta: ¿pueden el monitoreo tecnológico y los incentivos financieros reducir el ausentismo docente y mejorar el aprendizaje?

El diseño (avance):

- 120 escuelas no formales en Rajasthan, India.
- Aleatorización balanceada: 60 tratamiento vs. 60 control.
- Cámara con sello fecha/hora + pago no lineal por asistencia.
- Seguimiento de 30 meses (2003–2006).

Hoy entra en escena un paper

Para ver cada pieza *encarnada* en un caso real, usaremos como hilo conductor:

Duflo, Hanna & Ryan (2012)

"Incentives Work: Getting Teachers to Come to School"
American Economic Review, 102(4): 1241–1278.

La pregunta: ¿pueden el monitoreo tecnológico y los incentivos financieros reducir el ausentismo docente y mejorar el aprendizaje?

El diseño (avance):

- 120 escuelas no formales en Rajasthan, India.
- Aleatorización balanceada: 60 tratamiento vs. 60 control.
- Cámara con sello fecha/hora + pago no lineal por asistencia.
- Seguimiento de 30 meses (2003–2006).

Cómo lo usaremos: no presentaré el paper como un ejercicio separado al final; lo iremos viendo **en el camino**, aterrizando cada concepto (unidad de aleatorización, balance, poder, estimación, amenazas) en las decisiones concretas de los autores.

Roadmap

1. Experimentos Aleatorios Controlados (RCTs)
   - El RCT como solución al problema causal
   - Diseño Experimental
   - Estimación del Efecto
   - Limitaciones y/o Amenazas a la Validez
2. Incentives Work: Getting Teachers to Come to School
   - Este Paper
   - Diseño Experimental
   - Datos
   - Resultados
3. Hands-on: replicar el RCT en R

Unidad de Aleatorización

Unidad de aleatorización

- Puede ser:
  - **Individual**: hogares, estudiantes, pacientes.
  - **Por grupos o clusters**: escuelas, veredas, municipios, hospitales.

Unidad de Aleatorización

Unidad de aleatorización

- Puede ser:
  - **Individual**: hogares, estudiantes, pacientes.
  - **Por grupos o clusters**: escuelas, veredas, municipios, hospitales.
- La elección depende de la naturaleza de la intervención y del riesgo de **spillovers**:
  - Ej.: un programa educativo impartido a nivel de escuela $\rightarrow$ aleatorización a nivel de escuela.
  - Previene contaminación: los controles no reciben efectos indirectos (ej. interacción entre alumnos).

Unidad de Aleatorización

Unidad de aleatorización

- Puede ser:
  - **Individual**: hogares, estudiantes, pacientes.
  - **Por grupos o clusters**: escuelas, veredas, municipios, hospitales.
- La elección depende de la naturaleza de la intervención y del riesgo de **spillovers**:
  - Ej.: un programa educativo impartido a nivel de escuela $\rightarrow$ aleatorización a nivel de escuela.
  - Previene contaminación: los controles no reciben efectos indirectos (ej. interacción entre alumnos).
- **Costos y logística:** aleatorizar por cluster suele ser más barato y operativo, pero requiere muestras mayores para mantener poder estadístico.

Unidad de Aleatorización

Unidad de aleatorización

- Puede ser:
  - **Individual**: hogares, estudiantes, pacientes.
  - **Por grupos o clusters**: escuelas, veredas, municipios, hospitales.
- La elección depende de la naturaleza de la intervención y del riesgo de **spillovers**:
  - Ej.: un programa educativo impartido a nivel de escuela $\rightarrow$ aleatorización a nivel de escuela.
  - Previene contaminación: los controles no reciben efectos indirectos (ej. interacción entre alumnos).
- **Costos y logística:** aleatorizar por cluster suele ser más barato y operativo, pero requiere muestras mayores para mantener poder estadístico.
- **Implicación estadística:**
  - Los resultados de unidades en un mismo cluster están correlacionados $\rightarrow \rho$ (intracluster correlation coefficient).
  - Esto aumenta la varianza de los estimadores: se debe ajustar con errores estándar `cluster-robust` y calcular el **factor de diseño**.

Estratificación

Estratificación o blocking

- Consiste en dividir la muestra en **estratos homogéneos** usando variables predeterminadas (sexo, edad, escuela, valor en línea base de Y).
- Dentro de cada estrato, se realiza la aleatorización **separadamente**.

Estratificación

Estratificación o blocking

- Consiste en dividir la muestra en **estratos homogéneos** usando variables predeterminadas (sexo, edad, escuela, valor en línea base de Y).
- Dentro de cada estrato, se realiza la aleatorización **separadamente**.
- **Beneficios:**
  - Mejora la **precisión**: controla la varianza, balancea covariables clave.
  - Asegura **representatividad** en subgrupos relevantes (p.ej., que mujeres y hombres estén bien distribuidos).
  - Reduce el riesgo de "mala suerte" en la asignación.

Estratificación

Estratificación o blocking

- Consiste en dividir la muestra en **estratos homogéneos** usando variables predeterminadas (sexo, edad, escuela, valor en línea base de Y).
- Dentro de cada estrato, se realiza la aleatorización **separadamente**.
- **Beneficios:**
  - Mejora la **precisión**: controla la varianza, balancea covariables clave.
  - Asegura **representatividad** en subgrupos relevantes (p.ej., que mujeres y hombres estén bien distribuidos).
  - Reduce el riesgo de "mala suerte" en la asignación.
- **Requisitos:**
  - Tamaños mínimos adecuados en cada estrato $\rightarrow$ evitar celdas muy pequeñas.
  - Variables de estratificación deben definirse antes del tratamiento y no ser afectadas por él.

Estratificación

Estratificación o blocking

- Consiste en dividir la muestra en **estratos homogéneos** usando variables predeterminadas (sexo, edad, escuela, valor en línea base de Y).
- Dentro de cada estrato, se realiza la aleatorización **separadamente**.
- **Beneficios:**
  - Mejora la **precisión**: controla la varianza, balancea covariables clave.
  - Asegura **representatividad** en subgrupos relevantes (p.ej., que mujeres y hombres estén bien distribuidos).
  - Reduce el riesgo de "mala suerte" en la asignación.
- **Requisitos:**
  - Tamaños mínimos adecuados en cada estrato $\rightarrow$ evitar celdas muy pequeñas.
  - Variables de estratificación deben definirse antes del tratamiento y no ser afectadas por él.
- **Regla práctica:** si usas estratificación, debes **controlar por los estratos** en la estimación (regresión/ANOVA), incluso si el balance es perfecto.

Chequeos de balance

Bajo aleatorización válida:

$$X \perp D \quad \Rightarrow \quad \mathbb{E}[X \mid D = 1] = \mathbb{E}[X \mid D = 0]$$

donde X son características predeterminadas (línea base) y D indica tratamiento.

Chequeos de balance

Bajo aleatorización válida:

$$X \perp D \quad \Rightarrow \quad \mathbb{E}[X \mid D = 1] = \mathbb{E}[X \mid D = 0]$$

donde X son características predeterminadas (línea base) y D indica tratamiento.

¿Qué se hace en la práctica?

- **Tabla de balance:** reportar medias por grupo, diferencias, errores estándar y p-valores para cada covariable relevante (edad, educación, línea base del outcome, etc.).
- **Si hubo estratificación:** incluir dummies de estrato en la estimación para reflejar el diseño.

Chequeos de balance

Bajo aleatorización válida:

$$X \perp D \quad \Rightarrow \quad \mathbb{E}[X \mid D = 1] = \mathbb{E}[X \mid D = 0]$$

donde X son características predeterminadas (línea base) y D indica tratamiento.

¿Qué se hace en la práctica?

- **Tabla de balance:** reportar medias por grupo, diferencias, errores estándar y p-valores para cada covariable relevante (edad, educación, línea base del outcome, etc.).
- **Si hubo estratificación:** incluir dummies de estrato en la estimación para reflejar el diseño.

Enfoques complementarios

- **Prueba conjunta:** estimar una regresión $D_i = \alpha + X_i'\gamma + u_i$ y aplicar un test F de significancia global.

Mensaje: el balance empírico brinda evidencia de que la asignación aleatoria funcionó como se esperaba.

Poder estadístico y tamaño muestral

¿Qué es el poder estadístico?

- Probabilidad de rechazar H_0 cuando el efecto realmente existe $(1 - \beta)$.
- Depende de: tamaño muestral n, varianza del outcome σ^2, nivel de significancia α, y magnitud del efecto mínimo detectable Δ.

$$n \approx \frac{2\sigma^2 \left(z_{1-\alpha/2} + z_{1-\beta}\right)^2}{\Delta^2}$$

Poder estadístico y tamaño muestral

¿Qué es el poder estadístico?

- Probabilidad de rechazar H_0 cuando el efecto realmente existe $(1-\beta)$.
- Depende de: tamaño muestral n, varianza del outcome σ^2, nivel de significancia α, y magnitud del efecto mínimo detectable Δ.

$$n \approx \frac{2\sigma^2 \left(z_{1-\alpha/2} + z_{1-\beta}\right)^2}{\Delta^2}$$

Cluster RCT: pérdida de eficiencia

- Observaciones en un cluster correlacionadas $\Rightarrow$ mayor varianza.
- Factor de diseño (DEFF):

$$DEFF \approx 1 + (\bar{m} - 1)\rho$$

donde $\bar{m}$ = tamaño promedio de cluster, ρ = ICC (Intracluster Correlation Coefficient). Siendo la muestra efectiva: $n_{\text{ef}} = n/DEFF$.

Implicación: en RCTs por clusters se requieren más unidades para alcanzar el mismo poder que en un RCT individual.

Roadmap

1. Experimentos Aleatorios Controlados (RCTs)
   - El RCT como solución al problema causal
   - Diseño Experimental
   - Estimación del Efecto
   - Limitaciones y/o Amenazas a la Validez
2. Incentives Work: Getting Teachers to Come to School
   - Este Paper
   - Diseño Experimental
   - Datos
   - Resultados
3. Hands-on: replicar el RCT en R

Estimación básica en un RCT

Idea central: la aleatorización asegura que D_i es exógeno, por lo que el estimador de diferencia de medias es insesgado.

Diferencia de medias:

$$\widehat{\tau} \;=\; \bar{Y}_{D=1} - \bar{Y}_{D=0}$$

Regresión equivalente:

$$Y_i = \alpha + \beta D_i + \varepsilon_i$$

donde:

$$\mathbb{E}[Y_i \mid D_i = 1] = \alpha + \beta, \quad \mathbb{E}[Y_i \mid D_i = 0] = \alpha$$

Interpretación:

$$\hat{\beta} = \widehat{\tau} \;\Rightarrow\; \text{Efecto promedio del tratamiento (ATE/ITT)}$$

Clave: si la aleatorización funcionó, no hay riesgo de sesgo por variable omitida.

¿Por qué incluir controles en un RCT?

El estimador ya es insesgado, pero los controles pueden:

- Aumentar la **precisión** de la estimación al reducir $\text{Var}(\varepsilon_i)$.
- Explicar parte de la variabilidad en $Y_i \rightarrow$ mayor R^2.
- Ganar **poder estadístico**: el estimador $\hat{\beta}$ es más preciso.

¿Por qué incluir controles en un RCT?

El estimador ya es insesgado, pero los controles pueden:

- Aumentar la **precisión** de la estimación al reducir $\text{Var}(\varepsilon_i)$.
- Explicar parte de la variabilidad en $Y_i \rightarrow$ mayor R^2.
- Ganar **poder estadístico**: el estimador $\hat{\beta}$ es más preciso.

Regresión con controles:

$$Y_i = \alpha + \beta D_i + \gamma' X_i + \varepsilon_i$$

Controles típicos:

- Variables predeterminadas y no afectadas por el tratamiento.
- El valor de Y_i en la línea base es uno de los más poderosos.

¿Por qué incluir controles en un RCT?

El estimador ya es insesgado, pero los controles pueden:

- Aumentar la **precisión** de la estimación al reducir $\text{Var}(\varepsilon_i)$.
- Explicar parte de la variabilidad en $Y_i \rightarrow$ mayor R^2.
- Ganar **poder estadístico**: el estimador $\hat{\beta}$ es más preciso.

Regresión con controles:

$$Y_i = \alpha + \beta D_i + \gamma' X_i + \varepsilon_i$$

Controles típicos:

- Variables predeterminadas y no afectadas por el tratamiento.
- El valor de Y_i en la línea base es uno de los más poderosos.

Mensaje: el efecto estimado será similar sin controles, pero **menos significativo** al tener mayor varianza residual.

Roadmap

1. Experimentos Aleatorios Controlados (RCTs)
   - El RCT como solución al problema causal
   - Diseño Experimental
   - Estimación del Efecto
   - Limitaciones y/o Amenazas a la Validez
2. Incentives Work: Getting Teachers to Come to School
   - Este Paper
   - Diseño Experimental
   - Datos
   - Resultados
3. Hands-on: replicar el RCT en R

Consideraciones Éticas en los RCTs

- En ciencias sociales, un RCT puede decidir quién recibe un beneficio esencial (ej. alimentación, salud, educación). **¿Estamos jugando con la vida de las personas?**

Consideraciones Éticas en los RCTs

- En ciencias sociales, un RCT puede decidir quién recibe un beneficio esencial (ej. alimentación, salud, educación). **¿Estamos jugando con la vida de las personas?**

- **Condición fundamental:** sobresuscripción
  - La demanda excede la capacidad de la intervención.
  - No se puede reducir el número de beneficiarios que era posible atender con el presupuesto/capacidad disponible.

Consideraciones Éticas en los RCTs

- En ciencias sociales, un RCT puede decidir quién recibe un beneficio esencial (ej. alimentación, salud, educación). **¿Estamos jugando con la vida de las personas?**

- **Condición fundamental:** sobresuscripción
  - La demanda excede la capacidad de la intervención.
  - No se puede reducir el número de beneficiarios que era posible atender con el presupuesto/capacidad disponible.

- La asignación aleatoria se aplica **dentro de los elegibles**, lo que:
  - Garantiza igualdad de oportunidades.
  - Puede reducir la discrecionalidad (evitar que los más conectados siempre ganen).

Consideraciones Éticas en los RCTs

- En ciencias sociales, un RCT puede decidir quién recibe un beneficio esencial (ej. alimentación, salud, educación). **¿Estamos jugando con la vida de las personas?**

- **Condición fundamental:** sobresuscripción
  - La demanda excede la capacidad de la intervención.
  - No se puede reducir el número de beneficiarios que era posible atender con el presupuesto/capacidad disponible.

- La asignación aleatoria se aplica **dentro de los elegibles**, lo que:
  - Garantiza igualdad de oportunidades.
  - Puede reducir la discrecionalidad (evitar que los más conectados siempre ganen).

- **Desafío práctico:** Todos deben inscribirse como beneficiarios potenciales antes del sorteo $\rightarrow$ manejar expectativas y asegurar transparencia.

Amenazas a la validez interna (I)

1. **Attrition (pérdida de muestra):**
   - Cuando las tasas de respuesta difieren entre tratamiento y control, la comparabilidad inicial se pierde.
   - Ej.: encuesta de seguimiento con 90% en tratados y 70% en controles.
   - *Mitigación:*
     - ★ Maximizar esfuerzos de seguimiento (visitas adicionales, incentivos).
     - ★ Verificar balance en línea base de quienes permanecen.
     - ★ Usar métodos de corrección (bounds de Lee, imputaciones).

Amenazas a la validez interna (I)

1. **Attrition (pérdida de muestra):**
   - Cuando las tasas de respuesta difieren entre tratamiento y control, la comparabilidad inicial se pierde.
   - Ej.: encuesta de seguimiento con 90% en tratados y 70% en controles.
   - *Mitigación:*
     - ★ Maximizar esfuerzos de seguimiento (visitas adicionales, incentivos).
     - ★ Verificar balance en línea base de quienes permanecen.
     - ★ Usar métodos de corrección (bounds de Lee, imputaciones).
2. **Spillovers / Externalidades:**
   - Ocurren cuando el tratamiento afecta indirectamente a no tratados.
   - *Tipos:*
     1. Externalidades biológicas (ej. vacunación, desparasitación).
     2. Interacción social (redes de empleo, educación).
     3. Equilibrio general (mercados laborales, precios).
   - *Mitigación:*
     - ★ Aleatorización por clusters o uso de buffers geográficos.
     - ★ Medición explícita de la exposición indirecta.

Amenazas a la validez interna (II)

3. **Efecto John Henry:**
   - El grupo de control se esfuerza más al sentirse en competencia con los tratados.
   - Ej.: estudiantes en control aumentan su rendimiento para "demostrar" que no son peores.
   - *Consecuencia:* sesgo hacia abajo en la estimación del efecto.
   - *Mitigación:* anonimizar la asignación cuando sea posible; usar clusters que reduzcan competencia directa.

Amenazas a la validez interna (II)

3. **Efecto John Henry:**
   - El grupo de control se esfuerza más al sentirse en competencia con los tratados.
   - Ej.: estudiantes en control aumentan su rendimiento para "demostrar" que no son peores.
   - *Consecuencia:* sesgo hacia abajo en la estimación del efecto.
   - *Mitigación:* anonimizar la asignación cuando sea posible; usar clusters que reduzcan competencia directa.

4. **Efecto Hawthorne:**
   - Los individuos cambian su comportamiento solo por saberse observados.
   - Ej.: trabajadores aumentan productividad durante el experimento, independientemente del tratamiento.
   - *Consecuencia:* los resultados no reflejan un escenario "normal", reduciendo validez externa e interna.
   - *Mitigación:* estandarizar la observación para tratados y controles; usar períodos de adaptación ("run-in").

Otras consideraciones en los RCTs (I)

- **Noncompliance (incumplimiento):**
  - No todos los asignados reciben el tratamiento (no-take-up, crossovers).
  - En este caso, la estimación principal es el **ITT** (Intention-to-Treat).
  - Importante discutir las implicaciones: ¿quiénes cumplen y quiénes no?, ¿qué significa para la validez de la intervención?

Otras consideraciones en los RCTs (I)

- **Noncompliance (incumplimiento):**
  - No todos los asignados reciben el tratamiento (no-take-up, crossovers).
  - En este caso, la estimación principal es el **ITT** (Intention-to-Treat).
  - Importante discutir las implicaciones: ¿quiénes cumplen y quiénes no?, ¿qué significa para la validez de la intervención?

- **Heterogeneidad ex ante:**
  - Incluso con aleatorización, puede haber interés en estimar efectos por subgrupos definidos antes del tratamiento (ej.: hombres vs. mujeres, hogares rurales vs. urbanos).
  - Relevante para la política pública: permite ver **para quién funciona** y si hay equidad en los efectos.
  - Recomendación: definir subgrupos de antemano y evitar análisis ad hoc.

Otras consideraciones en los RCTs (II)

- **Múltiples outcomes:**
  - Cuando se miden muchos resultados, aumenta el riesgo de encontrar efectos espurios (*data mining*).
  - **Buenas prácticas:**
    1. Pre-registro del plan de análisis.
    2. Construcción de índices compuestos (ej.: educación, salud).
    3. Ajustes por multiplicidad (Bonferroni, FDR).

Otras consideraciones en los RCTs (II)

- **Múltiples outcomes:**
  - Cuando se miden muchos resultados, aumenta el riesgo de encontrar efectos espurios (*data mining*).
  - **Buenas prácticas:**
    1. Pre-registro del plan de análisis.
    2. Construcción de índices compuestos (ej.: educación, salud).
    3. Ajustes por multiplicidad (Bonferroni, FDR).
- **Validez externa:**
  - La muestra del RCT puede ser muy específica o poco representativa (ej.: ONGs ejemplares, contextos piloto).
  - La implementación a pequeña escala puede diferir de lo que ocurriría en políticas nacionales (problemas de **scaling up**).
  - Recomendación: siempre discutir límites de generalización y complementar con evidencia observacional.

Roadmap

1. Experimentos Aleatorios Controlados (RCTs)
   - El RCT como solución al problema causal
   - Diseño Experimental
   - Estimación del Efecto
   - Limitaciones y/o Amenazas a la Validez
2. Incentives Work: Getting Teachers to Come to School
   - Este Paper
   - Diseño Experimental
   - Datos
   - Resultados
3. Hands-on: replicar el RCT en R

Este Paper

Pregunta central: ¿Pueden los incentivos financieros ligados a asistencia, monitoreada con tecnología, reducir el ausentismo docente y mejorar el aprendizaje?

Contexto:

- En India, cerca del 24% de los docentes estaban ausentes en horas de clase.
- Escuelas no formales en Rajasthan, operadas por la ONG *Seva Mandir*.
- Docentes: *para-teachers*, con salarios bajos, contratos flexibles y alta rotación.

Contribución del paper:

- Ensayo controlado aleatorizado (RCT) de 30 meses (2003–2006).
- Uso de cámaras digitales con sello de hora como herramienta de monitoreo.
- Estimación experimental + modelo estructural dinámico de oferta laboral.

Diseño Experimental

Muestra y asignación:

- 120 escuelas no formales seleccionadas: 60 tratamiento, 60 control.
- Aleatorización balanceada en características iniciales (asistencia y desempeño estudiantil).

Tratamiento:

- Docentes con cámaras digitales: fotos al inicio y fin de la jornada, con sello de fecha/hora.
- Pago no lineal: salario base + bono (Rs. 50) por cada día trabajado por encima de 20 al mes.
- Multas por inasistencia o falsificación de registros.

Grupo control:

- Salario fijo de Rs. 1,000/mes, sin monitoreo adicional.

Periodo de estudio: 2003–2006, con visitas mensuales no anunciadas a todas las escuelas.

Datos

Fuentes principales:

- **Asistencia docente:**
  - Visitas aleatorias mensuales (tratamiento y control).
  - Fotos con sello de hora (solo en tratamiento).
- **Actividad en aula:** uso de tablero, interacción con estudiantes, número de niños presentes.
- **Resultados de aprendizaje:**
  - Prueba inicial (línea base).
  - Mid-test (abril 2004).
  - Post-test (septiembre 2004).
  - Resultados en Hindi y Matemáticas, medidos en desviaciones estándar.
- **Verificación de integridad:**
  - Balance inicial en asistencia y puntajes entre grupos.
  - Seguimiento completo durante los 30 meses.

Resultados

Impactos principales:

- **Asistencia docente:**
  - Ausentismo cayó de 42% a 21% en el grupo tratamiento.
  - Efecto persistente incluso 4 años después del inicio.
- **Resultados de aprendizaje:**
  - $+0.17$ desviaciones estándar en puntajes de los estudiantes.
  - $+10$ pp de probabilidad de transición a escuelas formales.
- **Elasticidad de oferta laboral:**
  - Modelo estructural: 0.20–0.30 respecto al bono.
  - Evidencia de fuerte respuesta de docentes a incentivos monetarios.
- **Costo-efectividad:**
  - Reducción de costos unitarios de educación.
  - Incentivos simples + monitoreo confiable $\rightarrow$ gran impacto en capital humano.

Roadmap

1. Experimentos Aleatorios Controlados (RCTs)
   - El RCT como solución al problema causal
   - Diseño Experimental
   - Estimación del Efecto
   - Limitaciones y/o Amenazas a la Validez
2. Incentives Work: Getting Teachers to Come to School
   - Este Paper
   - Diseño Experimental
   - Datos
   - Resultados
3. Hands-on: replicar el RCT en R

Paquete de replicación oficial (112523-V1)

La AER exige a los autores publicar el paquete que reproduce todas las tablas y figuras del paper. El de Duflo, Hanna & Ryan está disponible en:

doi.org/10.3886/E112523V1

Paquete de replicación oficial (112523-V1)

La AER exige a los autores publicar el paquete que reproduce todas las tablas y figuras del paper. El de Duflo, Hanna & Ryan está disponible en:

doi.org/10.3886/E112523V1

¿Qué contiene?

- Todos los datos (crudos y derivados), programas en Stata, y logs necesarios para replicar el paper de principio a fin.
- Guía detallada en `Read-Me.pdf`.

Dos subcarpetas principales:

- `Incentives_FINAL/` — análisis reducido del RCT (Tablas 1–11, Figuras 1–3).
- `Structural-Programs/` — modelo estructural en Java (Tablas 12–14).

Nota práctica: los `.do` files usan rutas tipo `C:\Incentives_Matter_Data\...`; hay que adaptarlas al correr en Mac/Linux.

Estructura interna de Incentives_FINAL/

Raw-Data/ — datos primarios del experimento:

- RandomCheck/: randomcheck.dta (3.183 visitas sorpresa) y teacher_test.dta (prueba a los docentes).
- RDD/: cameras.txt y data_RDD.dta con asistencia diaria por cámara.
- Tests/: pruebas a los niños (baseline, midline, endline).

Estructura interna de Incentives_FINAL/

Raw-Data/ — datos primarios del experimento:

- RandomCheck/: randomcheck.dta (3.183 visitas sorpresa) y teacher_test.dta (prueba a los docentes).
- RDD/: cameras.txt y data_RDD.dta con asistencia diaria por cámara.
- Tests/: pruebas a los niños (baseline, midline, endline).

Programs/ — 14 .do files de Stata, uno por tabla/figura:

- Table1_Fig1_update.do, Table-2.do, Table-3-Col-1-2.do, etc.
- MasterDoFile.do los ejecuta en secuencia.

Estructura interna de Incentives_FINAL/

Raw-Data/ — datos primarios del experimento:

- RandomCheck/: randomcheck.dta (3.183 visitas sorpresa) y teacher_test.dta (prueba a los docentes).
- RDD/: cameras.txt y data_RDD.dta con asistencia diaria por cámara.
- Tests/: pruebas a los niños (baseline, midline, endline).

Programs/ — 14 .do files de Stata, uno por tabla/figura:

- Table1_Fig1_update.do, Table-2.do, Table-3-Col-1-2.do, etc.
- MasterDoFile.do los ejecuta en secuencia.

Output/ — tablas exportadas en .csv y figura FIG3_T.gph.

Log-Files/ — bitácoras .log/.smcl, útiles para depurar y verificar reproducibilidad.

Qué replicaremos hoy en R: Tablas 1, 2 y 3

Tabla 1 — Balance en línea base: compara tratamiento y control en la primera visita (`time == 1`); medias, diferencias y SE. *Panel A*: asistencia. *Paneles B/D*: condiciones de aula. *Panel C*: puntaje docente. Fuente: `randomcheck.dta` + `teacher_test.dta`.

Qué replicaremos hoy en R: Tablas 1, 2 y 3

Tabla 1 — Balance en línea base: compara tratamiento y control en la primera visita (`time == 1`); medias, diferencias y SE. *Panel A*: asistencia. *Paneles B/D*: condiciones de aula. *Panel C*: puntaje docente. Fuente: `randomcheck.dta` + `teacher_test.dta`.

Tabla 2 — ITT sobre asistencia docente: 12 columnas de `lm(open ~ treat)` con SE agrupados por escuela (`cluster(schid)`), en toda la muestra post-baseline y en sub-períodos; incluye paneles por calidad docente (arriba/abajo de la mediana).

Qué replicaremos hoy en R: Tablas 1, 2 y 3

Tabla 1 — Balance en línea base: compara tratamiento y control en la primera visita (`time == 1`); medias, diferencias y SE. *Panel A*: asistencia. *Paneles B/D*: condiciones de aula. *Panel C*: puntaje docente. Fuente: `randomcheck.dta` + `teacher_test.dta`.

Tabla 2 — ITT sobre asistencia docente: 12 columnas de `lm(open ~ treat)` con SE agrupados por escuela (`cluster(schid)`), en toda la muestra post-baseline y en sub-períodos; incluye paneles por calidad docente (arriba/abajo de la mediana).

Script: `replication_duflo_2012.R`. Usa `haven` para leer `.dta`, `fixest::feols` para SE clusterizados, y `etable` para exportar CSVs comparables al output de Stata. Resultados en `Output-R/`.

Paquetes: `haven`, `dplyr`, `tidyr`, `readr`, `fixest`, `broom`.