

# Inferencia, Causalidad y Políticas Públicas

## ECO-60116

Week 04: Regresión Discontinua Nítida (Sharp RD)

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

May 8, 2026

# Roadmap

- 1 Sharp RD como solución al problema causal
  - La idea fundamental
  - Identificación: continuidad
  - Identificación: continuidad
- 2 Estimación: regresión local polinómica
  - De los límites a la regresión local
- 3 Pruebas de validación del diseño
- 4 Ludwig & Miller (2007): Head Start y Mortalidad Infantil
  - Este Paper
  - Contexto Institucional
  - Datos y Diseño
  - Resultados
- 5 Hands-on: Sharp RD en R con datos de Ludwig & Miller (2007)

## RECAP: IV

- **Objetivo:** identificar el efecto causal de  $X$  sobre  $Y$  cuando hay *endogeneidad*.
- **Instrumento válido ( $Z$ ):**
  - ▶ *Relevancia:*  $\text{Cov}(Z, X) \neq 0$
  - ▶ *Exclusión:*  $\text{Cov}(Z, \varepsilon) = 0$ .
- **Estimación:**
  - ▶ 1ª etapa  $X_i = \phi + \gamma Z_i + \nu_i$
  - ▶ 2ª etapa  $Y_i = \alpha + \beta \hat{X}_i + \epsilon_i$
  - ▶ **Atajo (Wald,  $Z$  binaria):**  $\hat{\beta} = \frac{\mathbb{E}[Y|Z=1] - \mathbb{E}[Y|Z=0]}{\mathbb{E}[X|Z=1] - \mathbb{E}[X|Z=0]}$

## RECAP: IV

- **Objetivo:** identificar el efecto causal de  $X$  sobre  $Y$  cuando hay *endogeneidad*.
- **Instrumento válido ( $Z$ ):**
  - ▶ *Relevancia:*  $\text{Cov}(Z, X) \neq 0$
  - ▶ *Exclusión:*  $\text{Cov}(Z, \varepsilon) = 0$ .
- **Estimación:**
  - ▶ 1ª etapa  $X_i = \phi + \gamma Z_i + \nu_i$
  - ▶ 2ª etapa  $Y_i = \alpha + \beta \hat{X}_i + \epsilon_i$
  - ▶ **Atajo (Wald,  $Z$  binaria):** 
$$\hat{\beta} = \frac{\mathbb{E}[Y|Z=1] - \mathbb{E}[Y|Z=0]}{\mathbb{E}[X|Z=1] - \mathbb{E}[X|Z=0]}$$
- **Diagnósticos clave:**  $F$  de instrumentos excluidos  $> 10$ ; signos consistentes entre 1ª etapa, forma reducida y 2SLS.

## RECAP: IV

- **Objetivo:** identificar el efecto causal de  $X$  sobre  $Y$  cuando hay *endogeneidad*.
- **Instrumento válido ( $Z$ ):**
  - ▶ *Relevancia:*  $\text{Cov}(Z, X) \neq 0$
  - ▶ *Exclusión:*  $\text{Cov}(Z, \varepsilon) = 0$ .
- **Estimación:**
  - ▶ 1ª etapa  $X_i = \phi + \gamma Z_i + \nu_i$
  - ▶ 2ª etapa  $Y_i = \alpha + \beta \hat{X}_i + \epsilon_i$
  - ▶ **Atajo (Wald,  $Z$  binaria):** 
$$\hat{\beta} = \frac{\mathbb{E}[Y|Z = 1] - \mathbb{E}[Y|Z = 0]}{\mathbb{E}[X|Z = 1] - \mathbb{E}[X|Z = 0]}$$
- **Diagnósticos clave:**  $F$  de instrumentos excluidos  $> 10$ ; signos consistentes entre 1ª etapa, forma reducida y 2SLS.
- **Reporte:** mostrar 1ª etapa, forma reducida y 2SLS; discutir plausibilidad de exclusión; pruebas de sobreidentificación (si  $L > K$ ) informan consistencia conjunta (no prueban exclusión).

# De IV a RD: el problema del instrumento creíble

**La pregunta práctica:** *¿de dónde sacamos un instrumento creíble?*

- Loterías (Vietnam draft, programas con sobreinscripción).
- Distancia geográfica (a hospitales, escuelas).
- **Reglas administrativas con umbrales:** elegibilidad por puntaje, edad, fecha de corte.

## La idea de esta semana

Cuando una política asigna un beneficio según un *umbral* de una variable continua, las unidades *justo por encima* y *justo por debajo* del umbral son comparables — excepto por el tratamiento. Esa es la idea de la **Regresión Discontinua**.

# Roadmap

- 1 Sharp RD como solución al problema causal
  - La idea fundamental
  - Identificación: continuidad
  - Identificación: continuidad
- 2 Estimación: regresión local polinómica
  - De los límites a la regresión local
- 3 Pruebas de validación del diseño
- 4 Ludwig & Miller (2007): Head Start y Mortalidad Infantil
  - Este Paper
  - Contexto Institucional
  - Datos y Diseño
  - Resultados
- 5 Hands-on: Sharp RD en R con datos de Ludwig & Miller (2007)

# La idea intuitiva

Imagine un programa de subsidio mensual que se otorga a todas las personas a partir de los 65 años cumplidos.

**Pregunta:** ¿el subsidio reduce las horas trabajadas?



# La idea intuitiva

Imagine un programa de subsidio mensual que se otorga a todas las personas a partir de los 65 años cumplidos.

**Pregunta:** ¿el subsidio reduce las horas trabajadas?

**Comparar beneficiarios con no beneficiarios (ingenuamente):**

- Beneficiarios → mayores en promedio: peor salud, menor productividad laboral.
- No beneficiarios → más jóvenes en promedio: mayor capacidad de generar ingresos.
- Comparación contaminada por todo lo que la edad correlaciona.

# La idea intuitiva

Imagine un programa de subsidio mensual que se otorga a todas las personas a partir de los 65 años cumplidos.

**Pregunta:** ¿el subsidio reduce las horas trabajadas?

**Comparar beneficiarios con no beneficiarios (ingenuamente):**


- Beneficiarios → mayores en promedio: peor salud, menor productividad laboral.
- No beneficiarios → más jóvenes en promedio: mayor capacidad de generar ingresos.
- Comparación contaminada por todo lo que la edad correlaciona.

**La idea clave de RD:**

- Comparar a alguien de 64 años y 11 meses con alguien de 65 años y 1 mes es *casi* comparar a la misma persona.
- Salud, experiencia laboral y entorno son prácticamente idénticos en una ventana estrecha alrededor de los 65.
- **Lo único que cambia abruptamente** a los 65 es el derecho al subsidio.

*El umbral genera variación cuasi-aleatoria del tratamiento entre unidades comparables.*

# Sharp RD: visualización



**El salto vertical en  $X = c$  es el efecto causal  $\tau_{RD}$ .**

**Lo que no observamos** (líneas punteadas): qué habría obtenido el grupo tratado de no haber sido tratado, y viceversa.

# Definición formal del Sharp RD

Tres ingredientes definen un diseño Sharp RD:

1. **Variable de asignación (running)**: una variable continua  $X_i$ .

# Definición formal del Sharp RD

Tres ingredientes definen un diseño Sharp RD:

1. **Variable de asignación (running):** una variable continua  $X_i$ .
2. **Umbral conocido:** un punto de corte  $c$  fijado por la regla.

# Definición formal del Sharp RD

Tres ingredientes definen un diseño Sharp RD:

1. **Variable de asignación (running):** una variable continua  $X_i$ .
2. **Umbral conocido:** un punto de corte  $c$  fijado por la regla.
3. **Asignación determinística (sharp):**

$$D_i = \mathbf{1}\{X_i \geq c\} = \begin{cases} 1 & \text{si } X_i \geq c, \\ 0 & \text{si } X_i < c. \end{cases}$$

# Definición formal del Sharp RD

Tres ingredientes definen un diseño Sharp RD:

1. **Variable de asignación (running):** una variable continua  $X_i$ .
2. **Umbral conocido:** un punto de corte  $c$  fijado por la regla.
3. **Asignación determinística (sharp):**

$$D_i = \mathbf{1}\{X_i \geq c\} = \begin{cases} 1 & \text{si } X_i \geq c, \\ 0 & \text{si } X_i < c. \end{cases}$$

**Lo que distingue “sharp”:** El umbral asigna el tratamiento *con certeza*. Toda unidad con  $X \geq c$  recibe el tratamiento; ninguna unidad con  $X < c$  lo recibe.

# Definición formal del Sharp RD

Tres ingredientes definen un diseño Sharp RD:

1. **Variable de asignación (running):** una variable continua  $X_i$ .
2. **Umbral conocido:** un punto de corte  $c$  fijado por la regla.
3. **Asignación determinística (sharp):**

$$D_i = \mathbf{1}\{X_i \geq c\} = \begin{cases} 1 & \text{si } X_i \geq c, \\ 0 & \text{si } X_i < c. \end{cases}$$

**Lo que distingue “sharp”:** El umbral asigna el tratamiento *con certeza*. Toda unidad con  $X \geq c$  recibe el tratamiento; ninguna unidad con  $X < c$  lo recibe.

## Ejemplos típicos de Sharp RD:

- Elegibilidad por edad (mayoría de edad, jubilación obligatoria).
- Reglas electorales (ganar una elección por margen de votos).
- Cortes administrativos sin discrecionalidad (puntaje mínimo de admisión).



# Hoy entra en escena un paper

Ludwig & Miller (2007)

*“Does Head Start Improve Children’s Life Chances? Evidence from a Regression Discontinuity Design”*. *Quarterly Journal of Economics*, 122(1): 159–208.

**La pregunta:** ¿el programa Head Start —preescolar federal lanzado en 1965 como parte de la *War on Poverty*— mejora la salud y educación de los niños beneficiarios?

# Hoy entra en escena un paper

Ludwig & Miller (2007)

*"Does Head Start Improve Children's Life Chances? Evidence from a Regression Discontinuity Design". Quarterly Journal of Economics, 122(1): 159–208.*

**La pregunta:** ¿el programa Head Start —preescolar federal lanzado en 1965 como parte de la *War on Poverty*— mejora la salud y educación de los niños beneficiarios?

**El problema de identificación:** comparar niños que asistieron a Head Start con quienes no asistieron no es válido. Las familias que inscriben a sus hijos difieren en ingresos, educación y entorno — sesgo de selección clásico.

# Hoy entra en escena un paper

Ludwig & Miller (2007)

*“Does Head Start Improve Children’s Life Chances? Evidence from a Regression Discontinuity Design”*. *Quarterly Journal of Economics*, 122(1): 159–208.

**La pregunta:** ¿el programa Head Start —preescolar federal lanzado en 1965 como parte de la *War on Poverty*— mejora la salud y educación de los niños beneficiarios?

**El problema de identificación:** comparar niños que asistieron a Head Start con quienes no asistieron no es válido. Las familias que inscriben a sus hijos difieren en ingresos, educación y entorno — sesgo de selección clásico.

**La solución:** la OEO asignó *asistencia técnica* a los 300 condados más pobres usando datos del Censo de 1960 — regla administrativa que generó variación cuasi-aleatoria en el acceso al programa.

- $X$ : tasa de pobreza del condado en 1960 (running variable).
- $D = 1\{X \geq c\}$ : = 1 si el condado recibió asistencia OEO ( $c = 59.1984\%$ ).
- $Y$ : mortalidad infantil (5–9 años) por causas afectables por Head Start.

# Roadmap

- 1 Sharp RD como solución al problema causal
  - La idea fundamental
  - **Identificación: continuidad**
  - Identificación: continuidad
- 2 Estimación: regresión local polinómica
  - De los límites a la regresión local
- 3 Pruebas de validación del diseño
- 4 Ludwig & Miller (2007): Head Start y Mortalidad Infantil
  - Este Paper
  - Contexto Institucional
  - Datos y Diseño
  - Resultados
- 5 Hands-on: Sharp RD en R con datos de Ludwig & Miller (2007)

# Roadmap

- 1 Sharp RD como solución al problema causal
  - La idea fundamental
  - Identificación: continuidad
  - **Identificación: continuidad**
- 2 Estimación: regresión local polinómica
  - De los límites a la regresión local
- 3 Pruebas de validación del diseño
- 4 Ludwig & Miller (2007): Head Start y Mortalidad Infantil
  - Este Paper
  - Contexto Institucional
  - Datos y Diseño
  - Resultados
- 5 Hands-on: Sharp RD en R con datos de Ludwig & Miller (2007)

## ¿Por qué funciona? El supuesto de continuidad

En un Sharp RD no comparamos a todos los tratados con todos los no tratados. Comparamos solo en el umbral.

**Idea central:** si los resultados potenciales  $\mathbb{E}[Y(0) \mid X = x]$  y  $\mathbb{E}[Y(1) \mid X = x]$  son funciones *continuas* de  $X$  en  $x = c$ , entonces:

- Las unidades con  $X = c - \epsilon$  tienen el mismo  $\mathbb{E}[Y(0)]$  que las unidades con  $X = c + \epsilon$  *tendrían si no fueran tratadas*.
- El salto en  $\mathbb{E}[Y \mid X]$  en  $X = c$  es **exclusivamente** atribuible al tratamiento.

## ¿Por qué funciona? El supuesto de continuidad

En un Sharp RD no comparamos a todos los tratados con todos los no tratados. Comparamos solo en el umbral.

**Idea central:** si los resultados potenciales  $\mathbb{E}[Y(0) \mid X = x]$  y  $\mathbb{E}[Y(1) \mid X = x]$  son funciones *continuas* de  $X$  en  $x = c$ , entonces:

- Las unidades con  $X = c - \epsilon$  tienen el mismo  $\mathbb{E}[Y(0)]$  que las unidades con  $X = c + \epsilon$  *tendrían si no fueran tratadas*.
- El salto en  $\mathbb{E}[Y \mid X]$  en  $X = c$  es **exclusivamente** atribuible al tratamiento.

Supuesto de identificación (Hahn, Todd & Van der Klaauw, 2001)

$\mathbb{E}[Y(0) \mid X = x]$  y  $\mathbb{E}[Y(1) \mid X = x]$  son continuas en  $x = c$ .

## ¿Por qué funciona? El supuesto de continuidad

En un Sharp RD no comparamos a todos los tratados con todos los no tratados. Comparamos solo en el umbral.

**Idea central:** si los resultados potenciales  $\mathbb{E}[Y(0) \mid X = x]$  y  $\mathbb{E}[Y(1) \mid X = x]$  son funciones *continuas* de  $X$  en  $x = c$ , entonces:

- Las unidades con  $X = c - \epsilon$  tienen el mismo  $\mathbb{E}[Y(0)]$  que las unidades con  $X = c + \epsilon$  *tendrían si no fueran tratadas*.
- El salto en  $\mathbb{E}[Y \mid X]$  en  $X = c$  es **exclusivamente** atribuible al tratamiento.

### Supuesto de identificación (Hahn, Todd & Van der Klaauw, 2001)

$\mathbb{E}[Y(0) \mid X = x]$  y  $\mathbb{E}[Y(1) \mid X = x]$  son continuas en  $x = c$ .

### Corolario — identificación del efecto en el umbral:

$$\tau_{RD} = \mathbb{E}[Y(1) - Y(0) \mid X = c] = \lim_{x \downarrow c} \mathbb{E}[Y \mid X = x] - \lim_{x \uparrow c} \mathbb{E}[Y \mid X = x].$$


*No comparamos los tratados con los controles. Comparamos los límites.*



# Sharp RD en un diagrama causal

**El problema general:**  $D$  está correlacionado con variables no observadas  $U$ , generando sesgo.

## Comparación general




$\text{Cov}(D, U) \neq 0 \Rightarrow \text{OLS sesgado}$

# Sharp RD en un diagrama causal


**El problema general:**  $D$  está correlacionado con variables no observadas  $U$ , generando sesgo.

## Comparación general



$\text{Cov}(D, U) \neq 0 \Rightarrow \text{OLS sesgado}$

## En el umbral $X = c$




En el umbral:  $U$  es continuo en  $X = c$

# Sharp RD en un diagrama causal


**El problema general:**  $D$  está correlacionado con variables no observadas  $U$ , generando sesgo.

## Comparación general



$\text{Cov}(D, U) \neq 0 \Rightarrow \text{OLS sesgado}$

## En el umbral $X = c$



En el umbral:  $U$  es continuo en  $X = c$

**Por qué se “rompe” la flecha  $U \rightarrow D$  en el umbral:**

- Lejos del umbral:  $D$  está correlacionado con  $U$  (los tratados son sistemáticamente distintos).
- En la *vecindad infinitesimal* del umbral:  $D$  depende solo de  $X = c$  —no hay información adicional para inferir  $U$ .

*La continuidad reemplaza al supuesto de exogeneidad de OLS.*

# ¿Cuándo es creíble el supuesto de continuidad?

La continuidad de los resultados potenciales en el umbral falla cuando:

- Las unidades pueden **manipular precisamente** su valor de  $X$  para caer en el lado deseado del umbral.

# ¿Cuándo es creíble el supuesto de continuidad?

La continuidad de los resultados potenciales en el umbral falla cuando:

- Las unidades pueden **manipular precisamente** su valor de  $X$  para caer en el lado deseado del umbral.
  - ▶ Ej. profesores que “redondean” notas para asegurar que un estudiante apruebe.
  - ▶ Ej. municipios que ajustan reportes de población para acceder a transferencias.
  - ▶ Ej. familias que reportan ingresos por debajo del SISBEN para entrar al programa.

# ¿Cuándo es creíble el supuesto de continuidad?

La continuidad de los resultados potenciales en el umbral falla cuando:

- Las unidades pueden **manipular precisamente** su valor de  $X$  para caer en el lado deseado del umbral.
  - ▶ Ej. profesores que “redondean” notas para asegurar que un estudiante apruebe.
  - ▶ Ej. municipios que ajustan reportes de población para acceder a transferencias.
  - ▶ Ej. familias que reportan ingresos por debajo del SISBEN para entrar al programa.
- Otra política o programa cambia exactamente en el mismo umbral  $c$ .
  - ▶ Ej. a los 18 años cambia: derecho al voto, responsabilidad penal, derecho a comprar alcohol, servicio militar...
  - ▶ Si todos cambian a la vez, no podemos atribuir el efecto a ninguno en particular.

# Buenas prácticas para defender continuidad

## Cómo argumentar credibilidad:

- 1 Argumentar institucionalmente por qué la manipulación precisa es difícil o imposible.
- 2 Hacer prueba de densidad de McCrary (cubierta más adelante).
- 3 Verificar continuidad de covariables predeterminadas en el umbral.
- 4 Discutir explícitamente otras reglas que cambien en el mismo umbral.

*En RD, la narrativa institucional es tan importante como la estadística: hay que convencer al lector de que el umbral es esencialmente arbitrario.*

## Por qué L&M es un casi-experimento

La intuición probabilística del RD —formalizada por Lee (2008)— dice que cuando los individuos no pueden manipular precisamente  $X$  alrededor del umbral, las unidades a cada lado son comparables en *todas* las características de fondo, observables y no observables.



# Por qué L&M es un casi-experimento

La intuición probabilística del RD —formalizada por Lee (2008)— dice que cuando los individuos no pueden manipular precisamente  $X$  alrededor del umbral, las unidades a cada lado son comparables en *todas* las características de fondo, observables y no observables.

**En el caso de Head Start, el argumento se cumple con fuerza máxima:**

- La medida de pobreza usada es del Censo de 1960; el umbral fue fijado en 1965 por la OEO.
- Ningún condado podía conocer el umbral cinco años antes —ni manipular su tasa de pobreza para entrar.
- No hay siquiera manipulación *imperfecta*: la asignación es exógena *por construcción*.

# Por qué L&M es un casi-experimento

La intuición probabilística del RD —formalizada por Lee (2008)— dice que cuando los individuos no pueden manipular precisamente  $X$  alrededor del umbral, las unidades a cada lado son comparables en *todas* las características de fondo, observables y no observables.

## En el caso de Head Start, el argumento se cumple con fuerza máxima:

- La medida de pobreza usada es del Censo de 1960; el umbral fue fijado en 1965 por la OEO.
- Ningún condado podía conocer el umbral cinco años antes —ni manipular su tasa de pobreza para entrar.
- No hay siquiera manipulación *imperfecta*: la asignación es exógena *por construcción*.

## ¿Qué deberíamos esperar entonces de los datos?

- La densidad de la tasa de pobreza en 1960 es continua en  $c = 59.1984\%$ .
- Características predeterminadas (urbanización, composición étnica, escolaridad de adultos, gasto en otros programas) son continuas en  $c$ .
- Outcomes que Head Start *no debería afectar* (ej. mortalidad por accidentes) no saltan en  $c$ .

*Si esto se verifica empíricamente, el salto en mortalidad infantil en  $c$  es atribuible solo al*

# Roadmap

- 1 Sharp RD como solución al problema causal
  - La idea fundamental
  - Identificación: continuidad
  - Identificación: continuidad
- 2 Estimación: regresión local polinómica
  - De los límites a la regresión local
- 3 Pruebas de validación del diseño
- 4 Ludwig & Miller (2007): Head Start y Mortalidad Infantil
  - Este Paper
  - Contexto Institucional
  - Datos y Diseño
  - Resultados
- 5 Hands-on: Sharp RD en R con datos de Ludwig & Miller (2007)

## Del estimando al estimador

**Idea ingenua:** comparar la media de  $Y$  entre unidades muy cerca del umbral.

$$\hat{\tau}_{RD}^{\text{ingenuo}} = \bar{Y}_{X \in [c, c+h]} - \bar{Y}_{X \in [c-h, c]}$$

con  $h$  pequeño.

**Problema:** si  $\mathbb{E}[Y(d) \mid X]$  tiene pendiente *distinta de cero* en  $c$ , entonces  $\bar{Y}_{X \in [c, c+h]} \neq \mathbb{E}[Y \mid X = c]$  en general. La diferencia de medias dentro de una ventana confunde el efecto del tratamiento con la pendiente local.

# Del estimando al estimador

**Idea ingenua:** comparar la media de  $Y$  entre unidades muy cerca del umbral.

$$\hat{\tau}_{RD}^{\text{ingenuo}} = \bar{Y}_{X \in [c, c+h]} - \bar{Y}_{X \in [c-h, c]}$$

con  $h$  pequeño.

**Problema:** si  $\mathbb{E}[Y(d) \mid X]$  tiene pendiente *distinta de cero* en  $c$ , entonces  $\bar{Y}_{X \in [c, c+h]} \neq \mathbb{E}[Y \mid X = c]$  en general. La diferencia de medias dentro de una ventana confunde el efecto del tratamiento con la pendiente local.

**Solución estándar:** ajustar regresiones *separadas* a cada lado del umbral, dentro de una ventana, e *interpolan* hacia el punto  $c$ .

# Del estimando al estimador

**Idea ingenua:** comparar la media de  $Y$  entre unidades muy cerca del umbral.

$$\hat{\tau}_{RD}^{\text{ingenuo}} = \bar{Y}_{X \in [c, c+h]} - \bar{Y}_{X \in [c-h, c]}$$

con  $h$  pequeño.

**Problema:** si  $\mathbb{E}[Y(d) \mid X]$  tiene pendiente *distinta de cero* en  $c$ , entonces  $\bar{Y}_{X \in [c, c+h]} \neq \mathbb{E}[Y \mid X = c]$  en general. La diferencia de medias dentro de una ventana confunde el efecto del tratamiento con la pendiente local.

**Solución estándar:** ajustar regresiones *separadas* a cada lado del umbral, dentro de una ventana, e *interpolan* hacia el punto  $c$ .

**Forma operativa — regresión polinómica local de grado  $p$  con kernel uniforme:**


Lado izquierdo: 
$$\min_{\alpha^-, \beta^-} \sum_{i: X_i \in [c-h, c)} (Y_i - \alpha^- - \beta^- \cdot (X_i - c))^2$$

Lado derecho: 
$$\min_{\alpha^+, \beta^+} \sum_{i: X_i \in [c, c+h]} (Y_i - \alpha^+ - \beta^+ \cdot (X_i - c))^2$$

**Estimador:**

$$\hat{\tau}_{RD} = \hat{\alpha}^+ - \hat{\alpha}^-.$$

# Del estimando al estimador: visualización



*Con pendiente positiva en  $\mathbb{E}[Y | X]$ , la media de  $Y$  dentro de la ventana sobreestima el límite derecho y subestima el izquierdo. La regresión local lineal interpola correctamente hacia  $c$ .*

## ¿Qué grado polinómico usar?

**Polinomio local de grado  $p$ :**

$$Y_i = \alpha + \tau \cdot D_i + \beta_1(X_i - c) + \beta_2 D_i(X_i - c) + \cdots + \beta_p (X_i - c)^p + \varepsilon_i$$

donde  $D_i = \mathbf{1}\{X_i \geq c\}$  y la regresión se ejecuta solo sobre  $|X_i - c| \leq h$ .



## ¿Qué grado polinómico usar?

**Polinomio local de grado  $p$ :**

$$Y_i = \alpha + \tau \cdot D_i + \beta_1(X_i - c) + \beta_2 D_i(X_i - c) + \cdots + \beta_p (X_i - c)^p + \varepsilon_i$$

donde  $D_i = \mathbf{1}\{X_i \geq c\}$  y la regresión se ejecuta solo sobre  $|X_i - c| \leq h$ .

**Recomendaciones modernas (Gelman & Imbens, 2019; Cattaneo et al., 2020):**

- **No usar polinomios de orden alto.** Aunque es tentador (“más flexible”),  $p \geq 4$  pone peso indebido en observaciones lejos del umbral.

## ¿Qué grado polinómico usar?

**Polinomio local de grado  $p$ :**

$$Y_i = \alpha + \tau \cdot D_i + \beta_1(X_i - c) + \beta_2 D_i(X_i - c) + \cdots + \beta_p (X_i - c)^p + \varepsilon_i$$

donde  $D_i = \mathbf{1}\{X_i \geq c\}$  y la regresión se ejecuta solo sobre  $|X_i - c| \leq h$ .

**Recomendaciones modernas (Gelman & Imbens, 2019; Cattaneo et al., 2020):**

- **No usar polinomios de orden alto.** Aunque es tentador (“más flexible”),  $p \geq 4$  pone peso indebido en observaciones lejos del umbral.
- **Lineal local ( $p = 1$ )** es el estándar para inferencia. Es lo que implementa `rdrobust` por default.
- **Cuadrático local ( $p = 2$ )** se usa a veces como robustez.

## ¿Qué grado polinómico usar?

**Polinomio local de grado  $p$ :**

$$Y_i = \alpha + \tau \cdot D_i + \beta_1(X_i - c) + \beta_2 D_i(X_i - c) + \cdots + \beta_p (X_i - c)^p + \varepsilon_i$$


donde  $D_i = \mathbf{1}\{X_i \geq c\}$  y la regresión se ejecuta solo sobre  $|X_i - c| \leq h$ .

**Recomendaciones modernas (Gelman & Imbens, 2019; Cattaneo et al., 2020):**

- **No usar polinomios de orden alto.** Aunque es tentador (“más flexible”),  $p \geq 4$  pone peso indebido en observaciones lejos del umbral.
- **Lineal local ( $p = 1$ )** es el estándar para inferencia. Es lo que implementa `rdrobust` por default.
- **Cuadrático local ( $p = 2$ )** se usa a veces como robustez.

**Argumento:** el sesgo viene de la curvatura local; el ancho de banda es el control principal, no el grado polinómico. Mejor banda más estrecha con  $p = 1$  que banda amplia con  $p = 4$ .

## ¿Qué grado polinómico usar?: visualización



*Mismo dataset, mismo bandwidth.  $p = 1$  y  $p = 2$  producen estimaciones estables.  $p = 4$  ondula cerca del umbral y en los bordes de la ventana, ajustando variación que es ruido.*

# La elección del ancho de banda $h$

## El trade-off central:

- $h$  grande  $\Rightarrow$  más obs., menor varianza, *pero* mayor sesgo.
- $h$  pequeño  $\Rightarrow$  menos obs., mayor varianza, *pero* menor sesgo.

# La elección del ancho de banda $h$

## El trade-off central:

- $h$  grande  $\Rightarrow$  más obs., menor varianza, *pero* mayor sesgo.
- $h$  pequeño  $\Rightarrow$  menos obs., mayor varianza, *pero* menor sesgo.

## Selección óptima por MSE (Imbens & Kalyanaraman, 2012):

$$h_{IK}^* = \arg \min_h \mathbb{E}[(\hat{\tau}_{RD}(h) - \tau_{RD})^2]$$

# La elección del ancho de banda $h$

## El trade-off central:

- $h$  grande  $\Rightarrow$  más obs., menor varianza, *pero* mayor sesgo.
- $h$  pequeño  $\Rightarrow$  menos obs., mayor varianza, *pero* menor sesgo.

## Selección óptima por MSE (Imbens & Kalyanaraman, 2012):

$$h_{IK}^* = \arg \min_h \mathbb{E}[(\hat{\tau}_{RD}(h) - \tau_{RD})^2]$$

## Selección óptima por CCT (Calonico, Cattaneo & Titiunik, 2014):

- Refina IK con un estimador del sesgo más robusto.
- Es el default actual: lo usa `rdrobust::rdbwselect()`.

# La elección del ancho de banda $h$

## El trade-off central:

- $h$  grande  $\Rightarrow$  más obs., menor varianza, *pero* mayor sesgo.
- $h$  pequeño  $\Rightarrow$  menos obs., mayor varianza, *pero* menor sesgo.

## Selección óptima por MSE (Imbens & Kalyanaraman, 2012):

$$h_{IK}^* = \arg \min_h \mathbb{E}[(\hat{\tau}_{RD}(h) - \tau_{RD})^2]$$



## Selección óptima por CCT (Calonico, Cattaneo & Titiunik, 2014):

- Refina IK con un estimador del sesgo más robusto.
- Es el default actual: lo usa `rdrobust::rdbwselect()`.

**Práctica:** reportar resultado principal con  $h_{CCT}^*$ , mostrar robustez con  $h/2$  y  $2h$ , no elegir  $h$  “a ojo” o por p-valor.



# La elección del ancho de banda $h$ : visualización



Izquierda: con  $h$  grande la regresión lineal no puede capturar la curvatura de  $\mathbb{E}[Y | X]$  y el estimador queda severamente sesgado. Derecha: el MSE óptimo  $h^*$  balancea sesgo<sup>2</sup> creciente y varianza decreciente.

## Inferencia robusta: Calonico, Cattaneo & Titiunik (2014)

**Problema con la inferencia tradicional:** cuando se elige  $h$  minimizando MSE, queda un sesgo no despreciable de orden  $h^{p+1}$ . Los intervalos de confianza usuales (con SE basado en la varianza) no cubren con la probabilidad nominal.

## Inferencia robusta: Calonico, Cattaneo & Titiunik (2014)

**Problema con la inferencia tradicional:** cuando se elige  $h$  minimizando MSE, queda un sesgo no despreciable de orden  $h^{p+1}$ . Los intervalos de confianza usuales (con SE basado en la varianza) no cubren con la probabilidad nominal.

**La propuesta CCT:**

# Inferencia robusta: Calonico, Cattaneo & Titiunik (2014)

**Problema con la inferencia tradicional:** cuando se elige  $h$  minimizando MSE, queda un sesgo no despreciable de orden  $h^{p+1}$ . Los intervalos de confianza usuales (con SE basado en la varianza) no cubren con la probabilidad nominal.

## La propuesta CCT:

- 1 Estimar  $\hat{\tau}_{RD}$  con polinomio de grado  $p$  (típicamente  $p = 1$ ).
- 2 Estimar el sesgo con un polinomio de grado  $p + 1$ .
- 3 Construir el estimador **corregido por sesgo**:  $\hat{\tau}_{RD}^{bc} = \hat{\tau}_{RD} - \widehat{\text{sesgo}}$ .
- 4 Construir un **IC robusto** que tenga en cuenta la varianza adicional introducida por la corrección.

# Inferencia robusta: Calonico, Cattaneo & Titiunik (2014)

**Problema con la inferencia tradicional:** cuando se elige  $h$  minimizando MSE, queda un sesgo no despreciable de orden  $h^{p+1}$ . Los intervalos de confianza usuales (con SE basado en la varianza) no cubren con la probabilidad nominal.

## La propuesta CCT:

- 1 Estimar  $\hat{\tau}_{RD}$  con polinomio de grado  $p$  (típicamente  $p = 1$ ).
- 2 Estimar el sesgo con un polinomio de grado  $p + 1$ .
- 3 Construir el estimador **corregido por sesgo**:  $\hat{\tau}_{RD}^{bc} = \hat{\tau}_{RD} - \widehat{\text{sesgo}}$ .
- 4 Construir un **IC robusto** que tenga en cuenta la varianza adicional introducida por la corrección.

## En `rdrobust` se reportan tres estimadores:

- Conventional:  $\hat{\tau}_{RD}$  con SE convencional. Sesgo no corregido.
- Bias-corrected:  $\hat{\tau}_{RD}^{bc}$  con SE convencional.
- Robust:  $\hat{\tau}_{RD}^{bc}$  con SE robusto a la corrección. **Es el que se debe reportar para inferencia.**

# Roadmap

- 1 Sharp RD como solución al problema causal
  - La idea fundamental
  - Identificación: continuidad
  - Identificación: continuidad
- 2 Estimación: regresión local polinómica
  - De los límites a la regresión local
- 3 Pruebas de validación del diseño
- 4 Ludwig & Miller (2007): Head Start y Mortalidad Infantil
  - Este Paper
  - Contexto Institucional
  - Datos y Diseño
  - Resultados
- 5 Hands-on: Sharp RD en R con datos de Ludwig & Miller (2007)

## Tres pruebas estándar

El supuesto de continuidad es **no testeable** directamente (involucra contrafactuales). Pero sus *implicaciones observables* sí lo son.

# Tres pruebas estándar

El supuesto de continuidad es **no testeable** directamente (involucra contrafactuales). Pero sus *implicaciones observables* sí lo son.

**Tres pruebas se han vuelto el estándar:**

- 1 **Prueba de manipulación de la densidad (McCrary):** la densidad  $f_X(x)$  debe ser continua en  $c$ . Una discontinuidad en la densidad sugiere que algunas unidades manipularon su valor de  $X$  para entrar/salir del programa.
- 2 **Continuidad de covariables predeterminadas:** variables  $W_i$  medidas *antes* del tratamiento deberían ser continuas en  $c$ . Si saltan, la población a ambos lados del umbral no es comparable.
- 3 **Umbrales placebo:** estimar el “efecto” en umbrales falsos  $c' \neq c$ . Si encontramos saltos en lugares donde no hay tratamiento, el diseño es sospechoso.



# Tres pruebas estándar

El supuesto de continuidad es **no testeable** directamente (involucra contrafactuales). Pero sus *implicaciones observables* sí lo son.

**Tres pruebas se han vuelto el estándar:**

- 1 **Prueba de manipulación de la densidad (McCrary):** la densidad  $f_X(x)$  debe ser continua en  $c$ . Una discontinuidad en la densidad sugiere que algunas unidades manipularon su valor de  $X$  para entrar/salir del programa.
- 2 **Continuidad de covariables predeterminadas:** variables  $W_i$  medidas *antes* del tratamiento deberían ser continuas en  $c$ . Si saltan, la población a ambos lados del umbral no es comparable.
- 3 **Umbrales placebo:** estimar el “efecto” en umbrales falsos  $c' \neq c$ . Si encontramos saltos en lugares donde no hay tratamiento, el diseño es sospechoso.

*Pasar las tres pruebas no garantiza la validez. Fallar alguna sí compromete la credibilidad.*

# Prueba de densidad de McCrary (2008)

**Idea:** si los individuos manipulan precisamente  $X$  para entrar al programa, debería haber exceso de masa justo por encima de  $c$  y *déficit* justo por debajo.

# Prueba de densidad de McCrary (2008)

**Idea:** si los individuos manipulan precisamente  $X$  para entrar al programa, debería haber exceso de masa justo por encima de  $c$  y *déficit* justo por debajo.

## Implementación:

- 1 Estimar la densidad de  $X$  a cada lado del umbral (*kernel local*).
- 2 Calcular:  $\theta = \log f_X^+(c) - \log f_X^-(c)$ .
- 3 Test de hipótesis:  $H_0 : \theta = 0$  (no hay manipulación).

# Prueba de densidad de McCrary (2008)

**Idea:** si los individuos manipulan precisamente  $X$  para entrar al programa, debería haber exceso de masa justo por encima de  $c$  y *déficit* justo por debajo.

## Implementación:

- 1 Estimar la densidad de  $X$  a cada lado del umbral (*kernel local*).
- 2 Calcular:  $\theta = \log f_X^+(c) - \log f_X^-(c)$ .
- 3 Test de hipótesis:  $H_0 : \theta = 0$  (no hay manipulación).

## Implementación moderna — Cattaneo, Jansson & Ma (2020):

- Paquete `rddensity` en R.
- Estimación con polinomios locales y SE robustos.
- Más recomendado que el McCrary original.

# Prueba de densidad de McCrary (2008)

**Idea:** si los individuos manipulan precisamente  $X$  para entrar al programa, debería haber exceso de masa justo por encima de  $c$  y *déficit* justo por debajo.

## Implementación:

- 1 Estimar la densidad de  $X$  a cada lado del umbral (*kernel local*).
- 2 Calcular:  $\theta = \log f_X^+(c) - \log f_X^-(c)$ .
- 3 Test de hipótesis:  $H_0 : \theta = 0$  (no hay manipulación).

## Implementación moderna — Cattaneo, Jansson & Ma (2020):

- Paquete `rddensity` en R.
- Estimación con polinomios locales y SE robustos.
- Más recomendado que el McCrary original.

## En el caso de L&M (2007):

- $X$  = tasa de pobreza del condado en 1960.
- El umbral se fijó en 1965 sobre datos pasados  $\Rightarrow$  por construcción, no debería haber manipulación.
- El test de densidad confirma: no hay discontinuidad en la distribución de  $X$  en  $c$ .

# Continuidad de covariables predeterminadas

**La lógica:** si la población *a la izquierda* y *a la derecha* del umbral son comparables, entonces variables medidas *antes* del tratamiento deberían tener la misma distribución en ambos lados.

# Continuidad de covariables predeterminadas

**La lógica:** si la población *a la izquierda* y *a la derecha* del umbral son comparables, entonces variables medidas *antes* del tratamiento deberían tener la misma distribución en ambos lados.

## Implementación:

- Repetir la regresión RD pero con cada covariable  $W_i$  como variable dependiente:

$$W_i = \alpha + \tau_W \cdot D_i + \beta(X_i - c) + \dots + \varepsilon_i$$

- $\tau_W$  debería ser *cero* (no significativo) para todas las covariables predeterminadas.

# Continuidad de covariables predeterminadas

**La lógica:** si la población *a la izquierda* y *a la derecha* del umbral son comparables, entonces variables medidas *antes* del tratamiento deberían tener la misma distribución en ambos lados.

## Implementación:

- Repetir la regresión RD pero con cada covariable  $W_i$  como variable dependiente:

$$W_i = \alpha + \tau_W \cdot D_i + \beta(X_i - c) + \dots + \varepsilon_i$$

- $\tau_W$  debería ser *cero* (no significativo) para todas las covariables predeterminadas.

## Qué reportar:

- Una tabla con varias covariables y sus saltos estimados.
- Un gráfico estilo McCrary para una o dos covariables clave.



# Continuidad de covariables predeterminadas

**La lógica:** si la población *a la izquierda* y *a la derecha* del umbral son comparables, entonces variables medidas *antes* del tratamiento deberían tener la misma distribución en ambos lados.

## Implementación:

- Repetir la regresión RD pero con cada covariable  $W_i$  como variable dependiente:

$$W_i = \alpha + \tau_W \cdot D_i + \beta(X_i - c) + \dots + \varepsilon_i$$

- $\tau_W$  debería ser *cero* (no significativo) para todas las covariables predeterminadas.

## Qué reportar:

- Una tabla con varias covariables y sus saltos estimados.
- Un gráfico estilo McCrary para una o dos covariables clave.

## Ojo con la interpretación:

- Si *una* covariable salta, el diseño puede aún ser válido (alguna prueba puede ser falso positivo).
- Si *varias* covariables saltan, el diseño está comprometido.

# Pruebas placebo

## Umbrales placebo:

- Estimar  $\tau_{RD}$  en umbrales falsos  $c' = c + 1, c - 1$ , etc.
- No deberíamos encontrar saltos significativos en lugares donde no hay tratamiento.
- Si los hay  $\Rightarrow$  la metodología detecta saltos espurios.

# Pruebas placebo

## Umbrales placebo:

- Estimar  $\tau_{RD}$  en umbrales falsos  $c' = c + 1, c - 1$ , etc.
- No deberíamos encontrar saltos significativos en lugares donde no hay tratamiento.
- Si los hay  $\Rightarrow$  la metodología detecta saltos espurios.

## Outcomes placebo:

- Estimar  $\tau_{RD}$  usando como  $Y$  una variable que no debería ser afectada por el tratamiento (*outcome predeterminado, efectos en períodos previos*).
- Salto cero  $\Rightarrow$  buen indicio.

# Pruebas de robustez

## Sensibilidad al ancho de banda:

- Reportar  $\hat{\tau}_{RD}$  para varios  $h$ :  $h^*/2$ ,  $h^*$ ,  $2h^*$ .
- El estimador no debería cambiar dramáticamente.

# Pruebas de robustez

## Sensibilidad al ancho de banda:

- Reportar  $\hat{\tau}_{RD}$  para varios  $h$ :  $h^*/2$ ,  $h^*$ ,  $2h^*$ .
- El estimador no debería cambiar dramáticamente.

## Sensibilidad al grado polinómico:

- Reportar resultados con  $p = 1$  y  $p = 2$ .
- Mostrar el gráfico RD “crudo” con `rdplot`.

# Pruebas de robustez

## Sensibilidad al ancho de banda:

- Reportar  $\hat{\tau}_{RD}$  para varios  $h$ :  $h^*/2$ ,  $h^*$ ,  $2h^*$ .
- El estimador no debería cambiar dramáticamente.

## Sensibilidad al grado polinómico:

- Reportar resultados con  $p = 1$  y  $p = 2$ .
- Mostrar el gráfico RD “crudo” con `rdplot`.

*Una buena aplicación de RD reporta no una estimación, sino una batería de estimaciones que muestren robustez.*

# Roadmap

- 1 Sharp RD como solución al problema causal
  - La idea fundamental
  - Identificación: continuidad
  - Identificación: continuidad
- 2 Estimación: regresión local polinómica
  - De los límites a la regresión local
- 3 Pruebas de validación del diseño
- 4 Ludwig & Miller (2007): Head Start y Mortalidad Infantil
  - Este Paper
  - Contexto Institucional
  - Datos y Diseño
  - Resultados
- 5 Hands-on: Sharp RD en R con datos de Ludwig & Miller (2007)

## Este Paper

**Referencia:** Ludwig, J. & Miller, D. L. (2007). “Does Head Start Improve Children’s Life Chances? Evidence from a Regression Discontinuity Design.” *Quarterly Journal of Economics*, 122(1): 159–208.

**Pregunta central:** ¿El programa Head Start —preescolar federal lanzado en 1965 como parte de la *War on Poverty*— mejora la salud y el desempeño escolar de los niños beneficiarios?



# Este Paper

**Referencia:** Ludwig, J. & Miller, D. L. (2007). “Does Head Start Improve Children’s Life Chances? Evidence from a Regression Discontinuity Design.” *Quarterly Journal of Economics*, 122(1): 159–208.

**Pregunta central:** ¿El programa Head Start —preescolar federal lanzado en 1965 como parte de la *War on Poverty*— mejora la salud y el desempeño escolar de los niños beneficiarios?

## Por qué importa:

- Head Start es uno de los programas sociales más grandes de EE.UU.: atiende a más de 900.000 niños/año.
- Décadas de evaluaciones con resultados contradictorios.
- Las familias que inscriben a sus hijos son sistemáticamente distintas ⇒ comparaciones simples están contaminadas por sesgo de selección.

## Contribución del paper:

- Primera evaluación causal creíble de Head Start usando datos a nivel de condado.
- Aprovecha una regla administrativa hasta entonces ignorada como fuente de variación cuasi-aleatoria.
- Inauguró el uso de RD para evaluar políticas territoriales (*place-based policies*).

# Contexto: la regla de la OEO (1965)

## Antecedentes:

- Head Start se lanzó en 1965 como parte de la *War on Poverty*.
- La *Office of Economic Opportunity* (OEO) tenía recursos limitados de *asistencia técnica* para ayudar a los condados a aplicar a los fondos federales.
- Decisión administrativa: enfocar la asistencia en los **300 condados más pobres** de EE.UU.

# Contexto: la regla de la OEO (1965)

## Antecedentes:

- Head Start se lanzó en 1965 como parte de la *War on Poverty*.
- La *Office of Economic Opportunity* (OEO) tenía recursos limitados de *asistencia técnica* para ayudar a los condados a aplicar a los fondos federales.
- Decisión administrativa: enfocar la asistencia en los **300 condados más pobres** de EE.UU.

## Mecánica de la regla:

- Medida de pobreza: índice construido por la OEO usando datos del **Censo de 1960**.
- Umbral: tasa de pobreza del condado #300 (59.1984%).
- La asistencia consistía en talleres y apoyo logístico para preparar las propuestas.
- Sin esta asistencia, muchos condados pobres no aplicaban  $\Rightarrow$  discontinuidad grande en el gasto efectivo de Head Start.

# Contexto: la regla de la OEO (1965)

## Antecedentes:

- Head Start se lanzó en 1965 como parte de la *War on Poverty*.
- La *Office of Economic Opportunity* (OEO) tenía recursos limitados de *asistencia técnica* para ayudar a los condados a aplicar a los fondos federales.
- Decisión administrativa: enfocar la asistencia en los **300 condados más pobres** de EE.UU.

## Mecánica de la regla:

- Medida de pobreza: índice construido por la OEO usando datos del **Censo de 1960**.
- Umbral: tasa de pobreza del condado #300 (59.1984%).
- La asistencia consistía en talleres y apoyo logístico para preparar las propuestas.
- Sin esta asistencia, muchos condados pobres no aplicaban  $\Rightarrow$  discontinuidad grande en el gasto efectivo de Head Start.

## Por qué este detalle es oro para identificación:

- El umbral se fijó en 1965 sobre datos de 1960  $\Rightarrow$  los condados *no podían manipular* su tasa de pobreza para entrar.
- El argumento de Lee se cumple con fuerza máxima: el umbral es exógeno por construcción.

# Datos y diseño empírico

## Datos:

- Universo de condados de EE.UU. con datos de mortalidad y pobreza ( $N \approx 3.100$ ).
- Mortalidad por causas y edad de NCHS, 1973–1983.
- Censo de 1960 para tasa de pobreza y covariables.

# Datos y diseño empírico

## Datos:

- Universo de condados de EE.UU. con datos de mortalidad y pobreza ( $N \approx 3.100$ ).
- Mortalidad por causas y edad de NCHS, 1973–1983.
- Censo de 1960 para tasa de pobreza y covariables.

## Variables clave:

- $X_i$ : tasa de pobreza del condado  $i$  en 1960 (running variable).
- $D_i = \mathbf{1}\{X_i \geq c\}$ : = 1 si el condado recibió asistencia OEO ( $c = 59.1984\%$ ).
- $Y_i$ : mortalidad infantil (5–9 años) por causas afectables por Head Start.
- Outcome *placebo*: mortalidad por causas *no* afectables (lesiones, accidentes).

# Datos y diseño empírico

## Datos:

- Universo de condados de EE.UU. con datos de mortalidad y pobreza ( $N \approx 3.100$ ).
- Mortalidad por causas y edad de NCHS, 1973–1983.
- Censo de 1960 para tasa de pobreza y covariables.

## Variables clave:

- $X_i$ : tasa de pobreza del condado  $i$  en 1960 (running variable).
- $D_i = \mathbf{1}\{X_i \geq c\}$ : = 1 si el condado recibió asistencia OEO ( $c = 59.1984\%$ ).
- $Y_i$ : mortalidad infantil (5–9 años) por causas afectables por Head Start.
- Outcome *placebo*: mortalidad por causas *no* afectables (lesiones, accidentes).

## Estrategia de identificación:

- Comparar condados *justo a cada lado* del umbral (58% vs. 60% de pobreza).
- *Continuidad*: características de fondo continuas en  $X = c$  (verificable).
- *No manipulación*: garantizada por el diseño *ex post* de la regla.

# Resultados principales

**Primera etapa:** en condados apenas por debajo del umbral (con asistencia OEO), el gasto per cápita de Head Start es  $\approx 50\%$  mayor que en condados apenas por encima. La regla *sí* generó variación real en el tratamiento.



# Resultados principales

**Primera etapa:** en condados apenas por debajo del umbral (con asistencia OEO), el gasto per cápita de Head Start es  $\approx 50\%$  mayor que en condados apenas por encima. La regla *sí* generó variación real en el tratamiento.

## Forma reducida — mortalidad infantil:

- Salto negativo en mortalidad por causas afectables por Head Start:  $\approx -2$  muertes por 100.000 niños 5–9 años.
- Magnitud relativa:  $\approx 33\text{--}50\%$  del nivel medio para esas causas.
- Significativo bajo varios anchos de banda.

# Resultados principales

**Primera etapa:** en condados apenas por debajo del umbral (con asistencia OEO), el gasto per cápita de Head Start es  $\approx 50\%$  mayor que en condados apenas por encima. La regla *sí* generó variación real en el tratamiento.

## Forma reducida — mortalidad infantil:

- Salto negativo en mortalidad por causas afectables por Head Start:  $\approx -2$  muertes por 100.000 niños 5–9 años.
- Magnitud relativa:  $\approx 33\text{--}50\%$  del nivel medio para esas causas.
- Significativo bajo varios anchos de banda.

## Validación — outcomes placebo:

- Mortalidad por causas *no* afectables (lesiones, accidentes): salto  $\approx 0$ .
- Cohortes no expuestas (niños mayores en 1965): salto  $\approx 0$ .
- Otros programas federales: sin discontinuidad en  $c$ .

# Resultados principales

**Primera etapa:** en condados apenas por debajo del umbral (con asistencia OEO), el gasto per cápita de Head Start es  $\approx 50\%$  mayor que en condados apenas por encima. La regla *sí* generó variación real en el tratamiento.

## Forma reducida — mortalidad infantil:

- Salto negativo en mortalidad por causas afectables por Head Start:  $\approx -2$  muertes por 100.000 niños 5–9 años.
- Magnitud relativa:  $\approx 33\text{--}50\%$  del nivel medio para esas causas.
- Significativo bajo varios anchos de banda.

## Validación — outcomes placebo:

- Mortalidad por causas *no* afectables (lesiones, accidentes): salto  $\approx 0$ .
- Cohortes no expuestas (niños mayores en 1965): salto  $\approx 0$ .
- Otros programas federales: sin discontinuidad en  $c$ .

**Largo plazo:** evidencia sugestiva —no concluyente— de mejor logro educativo en cohortes expuestas. La señal es más limpia en mortalidad que en outcomes educativos (limitaciones de datos a nivel de condado).

# Roadmap

- 1 Sharp RD como solución al problema causal
  - La idea fundamental
  - Identificación: continuidad
  - Identificación: continuidad
- 2 Estimación: regresión local polinómica
  - De los límites a la regresión local
- 3 Pruebas de validación del diseño
- 4 Ludwig & Miller (2007): Head Start y Mortalidad Infantil
  - Este Paper
  - Contexto Institucional
  - Datos y Diseño
  - Resultados
- 5 Hands-on: Sharp RD en R con datos de Ludwig & Miller (2007)

# Datos disponibles

**Paquete RDHonest:** contiene los datos de L&M (2007) ya preparados como objeto `headst`.

**Variables clave en `RDHonest::headst`**

- `povrate`: tasa de pobreza del condado en 1960, *centrada en cero* (cutoff original = 59.1984%, ya restado).
- `treated = 1{povrate60 ≥ 59.1984}`: recibió asistencia técnica OEO.
- `mortHS`: mortalidad por 100.000 (5–9 años) por causas afectables por Head Start, promedio 1973–1983.
- `mortInj`: mortalidad por lesiones (outcome *placebo*).
- Covariables 1960: `urban`, `black`, `hs60` (educación previa), `pop` (población).

**Paquetes que usaremos:**

- `rdrobust` —estimación e inferencia robusta (Calonico et al.).
- `rddensity` —prueba de manipulación (Cattaneo, Jansson & Ma).
- `RDHonest` —para los datos.
- `tidyverse` — manipulación de datos y gráficos.
- `modelsummary` — tablas de resultados.

# Qué replicaremos hoy en R

**Figura 1.** `rdplot(mort_age59_related_postHS, pov_c, c=0, p=4)` — discontinuidad visual en mortalidad infantil alrededor del umbral OEO.

**Tabla 1.** Estadísticas descriptivas por lado del umbral (`group_by(treated)`) — diagnóstico informal de balance de covariables predeterminadas.

**Tabla 2.** `rdrobust(mort_age59_related_preHS, pov_c, c=0, p=4)` — mortalidad *pre-programa*: el coeficiente debe ser  $\approx 0$  (no había diferencias pre-existentes).

**Tabla 3.** Resultado principal — `rdrobust(mort_age59_related_postHS, pov_c, c=0, p={1,2,4})` — reportar *Conventional*, *Bias-Corrected* y *Robust* para cada grado.

## Validaciones:

- (A) `rdensity(pov_c, c=0)` — prueba McCrary: no debe haber salto en la densidad de `pov_c`.
- (B) `rdrobust(mort_age59_injury_postHS, pov_c, c=0, p=4)` — placebo por causas: coeficiente  $\approx 0$ .
- (C) `rdrobust(mort_age59_related_preHS, pov_c, c=0, p=4)` — placebo temporal: coeficiente  $\approx 0$ .

**Script de la sesión:** `rep_ludwig_miller2007.R` (disponible en el repositorio del curso).

# Cierre y conexión con la próxima semana

## Lo que vimos hoy:

- Sharp RD identifica el efecto *en el umbral* bajo continuidad.
- Estimación: regresión local polinómica + ancho de banda óptimo (CCT).
- Pruebas de validación (densidad, balance, placebos) son obligatorias.

**Un detalle de L&M que abre la puerta a la próxima semana:** la asistencia OEO sí fue *sharp* (totalmente determinada por el umbral), pero el *gasto efectivo* en Head Start solo aumentó parcialmente al cruzar  $c$ .

## La próxima semana — Fuzzy RD:

- ¿Y si cruzar el umbral cambia la *probabilidad* de tratamiento, no el tratamiento mismo?
- Cruce del umbral = instrumento  $\Rightarrow$  Fuzzy RD = IV local.
- Identifica el LATE *de los compliers en el umbral*.

*Pop-Eleches & Urquiola (2013) — “Going to a Better School”.*

# Referencias

## Paper de la semana

- Ludwig, J. & Miller, D. L. (2007). Does Head Start Improve Children's Life Chances? *Quarterly Journal of Economics*, 122(1), 159–208.

## Identificación y estimación en Sharp RD

- Lee, D. S. (2008). Randomized Experiments from Non-random Selection in U.S. House Elections. *Journal of Econometrics*, 142(2), 675–697.
- Imbens, G. & Kalyanaraman, K. (2012). Optimal Bandwidth Choice for the Regression Discontinuity Estimator. *Review of Economic Studies*, 79(3), 933–959.
- Calonico, S., Cattaneo, M. D. & Titiunik, R. (2014). Robust Nonparametric Confidence Intervals for Regression-Discontinuity Designs. *Econometrica*, 82(6), 2295–2326.
- Gelman, A. & Imbens, G. (2019). Why High-Order Polynomials Should Not Be Used in Regression Discontinuity Designs. *JBES*, 37(3), 447–456.

## Prueba de densidad

- Cattaneo, M. D., Jansson, M. & Ma, X. (2020). Simple Local Polynomial Density Estimators. *JASA*, 115(531), 1449–1455.

## Datos y extensión

- Cattaneo, M. D., Titiunik, R. & Vazquez-Bare, G. (2017). Comparing Inference Approaches for RD Designs. *JPAM*, 36(3), 643–681.