

Inferencia, Causalidad y Políticas Públicas

ECO-60116

Week 06: Datos Panel y Efectos Fijos

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

May 22, 2026

Roadmap

- 1 Datos panel y heterogeneidad no observada
 - La idea fundamental
- 2 El estimador within: efectos fijos
 - La transformación within y sus propiedades
- 3 Inferencia: errores estándar clusterizados
 - Correlación intra-unidad y cluster-robust SE
- 4 Limitaciones del estimador FE
 - Lo que FE no resuelve
- 5 Camacho & Mejía (2017): aspersiones y salud en Colombia
 - Este paper
 - Contexto Colombiano
 - Datos y diseño
 - Resultados
- 6 Hands-on: Panel FE en R con datos simulados

RECAP: Fuzzy RD

- **Motivación:** cumplimiento imperfecto del umbral — ser elegible $\neq$ ser tratado.
- **La idea:** Fuzzy RD = *IV local* en el umbral.
 - ▶ Instrumento: $Z_i = \mathbf{1}\{X_i \geq c\}$.
 - ▶ Variable endógena: D_i (recepción efectiva del tratamiento).
- **Estimación:** 2SLS con regresión local polinómica a cada lado del umbral.
 - ▶ 1ª etapa: $D_i = \pi_0 + \pi_1 Z_i + f(X_i - c) + \eta_i$.
 - ▶ Forma reducida: $Y_i = \rho_0 + \rho_1 Z_i + g(X_i - c) + \varepsilon_i$.
 - ▶ Wald local: $\hat{\tau}_{FRD} = \hat{\rho}_1 / \hat{\pi}_1$.

RECAP: Fuzzy RD

- **Motivación:** cumplimiento imperfecto del umbral — ser elegible $\neq$ ser tratado.
- **La idea:** Fuzzy RD = *IV local* en el umbral.
 - ▶ Instrumento: $Z_i = \mathbf{1}\{X_i \geq c\}$.
 - ▶ Variable endógena: D_i (recepción efectiva del tratamiento).
- **Estimación:** 2SLS con regresión local polinómica a cada lado del umbral.
 - ▶ 1ª etapa: $D_i = \pi_0 + \pi_1 Z_i + f(X_i - c) + \eta_i$.
 - ▶ Forma reducida: $Y_i = \rho_0 + \rho_1 Z_i + g(X_i - c) + \varepsilon_i$.
 - ▶ Wald local: $\hat{\tau}_{FRD} = \hat{\rho}_1 / \hat{\pi}_1$.
- **Interpretación:** LATE local — efecto sobre los *compliers en el umbral*.
- **Pruebas de validación:** densidad (McCrary), balance de covariables, umbrales placebo, primera etapa fuerte.

De RD a panel: el tiempo como recurso

Lo que hemos hecho hasta ahora: explotar variación cuasi-aleatoria *entre* unidades.

- RCT: aleatorización por diseño.
- IV: una fuente exógena (Z) que mueve el tratamiento.
- RD (sharp y fuzzy): el umbral genera comparables locales.

Pero a veces no hay umbral, ni instrumento, ni aleatorización.

De RD a panel: el tiempo como recurso

Lo que hemos hecho hasta ahora: explotar variación cuasi-aleatoria *entre* unidades.

- RCT: aleatorización por diseño.
- IV: una fuente exógena (Z) que mueve el tratamiento.
- RD (sharp y fuzzy): el umbral genera comparables locales.

Pero a veces no hay umbral, ni instrumento, ni aleatorización.

La pregunta de esta semana

¿Qué pasa si observamos a la *misma* unidad en varios momentos del tiempo?
¿Puede el *tiempo* ser un recurso para identificar efectos causales?

Respuesta breve: sí, si la fuente del sesgo no cambia en el tiempo.

Roadmap

- 1 Datos panel y heterogeneidad no observada
 - La idea fundamental
- 2 El estimador within: efectos fijos
 - La transformación within y sus propiedades
- 3 Inferencia: errores estándar clusterizados
 - Correlación intra-unidad y cluster-robust SE
- 4 Limitaciones del estimador FE
 - Lo que FE no resuelve
- 5 Camacho & Mejía (2017): aspersiones y salud en Colombia
 - Este paper
 - Contexto Colombiano
 - Datos y diseño
 - Resultados
- 6 Hands-on: Panel FE en R con datos simulados

La idea intuitiva

El problema clásico: comparar personas distintas que difieren en cosas no observadas.

Ejemplo: queremos saber si el salario aumenta con la experiencia laboral.

- Comparar a Juan (15 años de experiencia) con María (3 años) no funciona: Juan también tiene más *habilidad*, más *contactos*, vivió en mejor *vecindario*.
- Esos factores no observados están correlacionados con experiencia $\Rightarrow$ sesgo por variable omitida.

La idea intuitiva

El problema clásico: comparar personas distintas que difieren en cosas no observadas.

Ejemplo: queremos saber si el salario aumenta con la experiencia laboral.

- Comparar a Juan (15 años de experiencia) con María (3 años) no funciona: Juan también tiene más *habilidad*, más *contactos*, vivió en mejor *vecindario*.
- Esos factores no observados están correlacionados con experiencia $\Rightarrow$ sesgo por variable omitida.

El cambio de perspectiva: ¿y si observo a *Juan* en distintos momentos del tiempo?

- Juan con 5 años de experiencia $\rightarrow$ Juan con 6 años $\rightarrow$ Juan con 7 años.
- Su habilidad, sus contactos, su entorno familiar: **casi no cambian** año a año.
- Lo que cambia es la experiencia (y el salario).

La idea intuitiva

El problema clásico: comparar personas distintas que difieren en cosas no observadas.

Ejemplo: queremos saber si el salario aumenta con la experiencia laboral.

- Comparar a Juan (15 años de experiencia) con María (3 años) no funciona: Juan también tiene más *habilidad*, más *contactos*, vivió en mejor *vecindario*.
- Esos factores no observados están correlacionados con experiencia $\Rightarrow$ sesgo por variable omitida.

El cambio de perspectiva: ¿y si observo a *Juan* en distintos momentos del tiempo?

- Juan con 5 años de experiencia $\rightarrow$ Juan con 6 años $\rightarrow$ Juan con 7 años.
- Su habilidad, sus contactos, su entorno familiar: **casi no cambian** año a año.
- Lo que cambia es la experiencia (y el salario).

Comparar a Juan consigo mismo es como tener un grupo de control hecho a la medida.

¿Qué es un panel?

Un **panel** (o **datos longitudinales**) es un dataset donde observamos las mismas unidades i en múltiples periodos t .

Notación:

- $i = 1, 2, \dots, N$ indexa unidades (personas, firmas, municipios, países...).
- $t = 1, 2, \dots, T$ indexa periodos (años, meses, días...).
- Y_{it} , D_{it} , X_{it} : outcome, tratamiento, covariables en la unidad i y periodo t .

Balanceado vs. desbalanceado:

- *Balanceado*: todas las unidades aparecen en todos los periodos ($N \times T$ observaciones).
- *Desbalanceado*: algunas unidades faltan en algunos periodos — lo más común con datos administrativos.

Ejemplo: el paper de esta semana


Camacho & Mejía (2017) trabajan con un panel **desbalanceado** de ~ 9.4 millones de individuos colombianos, observados en distintos momentos entre 2003 y 2007 cada vez que asistieron a una consulta médica.

Heterogeneidad no observada e invariante en el tiempo

El modelo de fondo:

$$Y_{it} = \alpha + \beta D_{it} + \underbrace{u_i}_{\substack{\text{no observado} \\ \text{invariante en } t}} + \varepsilon_{it}$$

donde u_i recoge todo factor individual no observado que **no cambia en el tiempo**: habilidad, salud basal, genética, contexto familiar...



Lo crítico: u_i es el *mismo* en $t = 1$ y en $t = 2$. Es esa estabilidad la que vamos a explotar.

¿Por qué OLS pooled está sesgado?

OLS pooled: aplicar OLS al panel tratándolo como una cross-section, ignorando el índice t .

$$Y_{it} = \alpha + \beta D_{it} + \nu_{it}, \quad \text{donde } \nu_{it} = u_i + \varepsilon_{it}$$

El residual ν_{it} **contiene** la heterogeneidad invariante u_i .

¿Por qué OLS pooled está sesgado?

OLS pooled: aplicar OLS al panel tratándolo como una cross-section, ignorando el índice t .

$$Y_{it} = \alpha + \beta D_{it} + \nu_{it}, \quad \text{donde } \nu_{it} = u_i + \varepsilon_{it}$$

El residual ν_{it} **contiene** la heterogeneidad invariante u_i .

Sesgo por variable omitida: si $\text{Cov}(D_{it}, u_i) \neq 0$,

$$\hat{\beta}_{\text{pooled}} \xrightarrow{p} \beta + \frac{\text{Cov}(D_{it}, u_i)}{\text{Var}(D_{it})}$$

Y peor aún: aún con $\text{Cov}(D_{it}, u_i) = 0$, los residuales ν_{it} *están correlacionados entre sí* para la misma unidad i (porque u_i es el mismo en todo t) $\Rightarrow$ los errores estándar OLS son inválidos.

¿Por qué OLS pooled está sesgado?

OLS pooled: aplicar OLS al panel tratándolo como una cross-section, ignorando el índice t .

$$Y_{it} = \alpha + \beta D_{it} + \nu_{it}, \quad \text{donde } \nu_{it} = u_i + \varepsilon_{it}$$

El residual ν_{it} **contiene** la heterogeneidad invariante u_i .

Sesgo por variable omitida: si $\text{Cov}(D_{it}, u_i) \neq 0$,

$$\hat{\beta}_{\text{pooled}} \xrightarrow{p} \beta + \frac{\text{Cov}(D_{it}, u_i)}{\text{Var}(D_{it})}$$

Y peor aún: aún con $\text{Cov}(D_{it}, u_i) = 0$, los residuales ν_{it} *están correlacionados entre sí* para la misma unidad i (porque u_i es el mismo en todo t) $\Rightarrow$ los errores estándar OLS son inválidos.

La pregunta práctica: ¿cómo identificamos β sin observar u_i ?

Hoy entra en escena un paper

Camacho & Mejía (2017)

"The Health Consequences of Aerial Spraying of Illicit Crops: The Case of Colombia". Journal of Health Economics, 54: 147–160.

La pregunta: ¿las aspersiones aéreas con glifosato bajo Plan Colombia generan efectos negativos sobre la salud de la población?

Hoy entra en escena un paper

Camacho & Mejía (2017)

"The Health Consequences of Aerial Spraying of Illicit Crops: The Case of Colombia". Journal of Health Economics, 54: 147–160.

La pregunta: ¿las aspersiones aéreas con glifosato bajo Plan Colombia generan efectos negativos sobre la salud de la población?

El problema de identificación:

- Las áreas asperjadas son, por diseño, las áreas con cultivos de coca.
- Las áreas con coca son rurales, pobres, con peor salud basal.
- Comparar municipios asperjados vs. no asperjados $\Rightarrow$ sesgo masivo.

Hoy entra en escena un paper

Camacho & Mejía (2017)

"The Health Consequences of Aerial Spraying of Illicit Crops: The Case of Colombia".
Journal of Health Economics, 54: 147–160.

La pregunta: ¿las aspersiones aéreas con glifosato bajo Plan Colombia generan efectos negativos sobre la salud de la población?

El problema de identificación:

- Las áreas asperjadas son, por diseño, las áreas con cultivos de coca.
- Las áreas con coca son rurales, pobres, con peor salud basal.
- Comparar municipios asperjados vs. no asperjados $\Rightarrow$ sesgo masivo.

La solución: observar a la *misma persona* bajo distintos niveles de exposición a lo largo del tiempo, eliminando todo lo que no varía en t .

- i : individuo. t : fecha de consulta médica (2003–2007).
- D_{it} : km² asperjados en el municipio de residencia.
- Y_{it} : $1\{\text{consulta dermatológica, respiratoria o aborto}\}$.

Roadmap

- 1 Datos panel y heterogeneidad no observada
 - La idea fundamental
- 2 El estimador within: efectos fijos
 - La transformación within y sus propiedades
- 3 Inferencia: errores estándar clusterizados
 - Correlación intra-unidad y cluster-robust SE
- 4 Limitaciones del estimador FE
 - Lo que FE no resuelve
- 5 Camacho & Mejía (2017): aspersiones y salud en Colombia
 - Este paper
 - Contexto Colombiano
 - Datos y diseño
 - Resultados
- 6 Hands-on: Panel FE en R con datos simulados

La transformación within

La idea: restar a cada observación la media de su propia unidad —esto es la **transformación within** (o *centrado intra-unidad*).

Punto de partida: el modelo con heterogeneidad invariante.

$$Y_{it} = \alpha + \beta D_{it} + u_i + \varepsilon_{it} \quad (1)$$

Paso 1. Tomar el promedio dentro de cada unidad i a lo largo del tiempo:

$$\bar{Y}_i = \alpha + \beta \bar{D}_i + u_i + \bar{\varepsilon}_i \quad (2)$$

donde $\bar{Y}_i = \frac{1}{T_i} \sum_t Y_{it}$, y análogo para $\bar{D}_i$ y $\bar{\varepsilon}_i$.

Paso 2. Restar (2) de (1):

$$\underbrace{Y_{it} - \bar{Y}_i}_{\tilde{Y}_{it}} = \beta \underbrace{(D_{it} - \bar{D}_i)}_{\tilde{D}_{it}} + \underbrace{(\varepsilon_{it} - \bar{\varepsilon}_i)}_{\tilde{\varepsilon}_{it}}$$

La transformación within

La idea: restar a cada observación la media de su propia unidad —esto es la **transformación within** (o *centrado intra-unidad*).

Punto de partida: el modelo con heterogeneidad invariante.

$$Y_{it} = \alpha + \beta D_{it} + u_i + \varepsilon_{it} \quad (1)$$

Paso 1. Tomar el promedio dentro de cada unidad i a lo largo del tiempo:

$$\bar{Y}_i = \alpha + \beta \bar{D}_i + u_i + \bar{\varepsilon}_i \quad (2)$$

donde $\bar{Y}_i = \frac{1}{T_i} \sum_t Y_{it}$, y análogo para $\bar{D}_i$ y $\bar{\varepsilon}_i$.

Paso 2. Restar (2) de (1):

$$\underbrace{Y_{it} - \bar{Y}_i}_{\tilde{Y}_{it}} = \beta \underbrace{(D_{it} - \bar{D}_i)}_{\tilde{D}_{it}} + \underbrace{(\varepsilon_{it} - \bar{\varepsilon}_i)}_{\tilde{\varepsilon}_{it}}$$

¿Y u_i ? Como $u_i = \bar{u}_i$ (es constante en t), **se cancela**.

$$\tilde{Y}_{it} = \beta \tilde{D}_{it} + \tilde{\varepsilon}_{it}$$

OLS sobre las variables centradas $\Rightarrow$ **estimador within** (= efectos fijos).

Tres formas equivalentes de estimar $\hat{\beta}_{FE}$

Los tres procedimientos siguientes producen **numéricamente el mismo** $\hat{\beta}$:

1. Centrar dentro de la unidad (within) y correr OLS.

- Construir $\tilde{Y}_{it}$ y $\tilde{D}_{it}$ unidad por unidad, luego regresar.
- Útil para ver *qué hace* el método. Engorroso en la práctica.

2. Regresión con dummies de unidad (LSDV).

$$Y_{it} = \beta D_{it} + \sum_{j=1}^N \mu_j \mathbf{1}\{i = j\} + \varepsilon_{it}$$

- Incluir N dummies absorbe los u_i .
- Inviabile si N es grande ($N = 9.4M$ en C&M...).

3. Comando dedicado (lo estándar hoy).

- En R: `feols(y ~ d | id, data = panel)` — absorbe los FE sin estimarlos.
- En Stata: `reghdfe y d, absorb(id)`.

Las tres rutas dan idéntico $\hat{\beta}$. Lo que cambia es la facilidad de cómputo.

El supuesto clave: exogeneidad estricta

Para que $\hat{\beta}_{FE}$ sea consistente necesitamos:

$$\mathbb{E}[\varepsilon_{it} \mid D_{i1}, D_{i2}, \dots, D_{iT}, u_i] = 0 \quad \text{para todo } t.$$

¿Qué quiere decir esto?

- El error ε_{it} es ortogonal al tratamiento *en todos* los periodos, no solo el contemporáneo.
- **Permite** correlación arbitraria entre D_{it} y u_i (eso es justo lo que queremos).
- **No permite:** que un Y pasado influya un D futuro (causalidad inversa diferida).
- **No permite:** que las unidades anticipen D futuro y ajusten su comportamiento hoy.

El supuesto clave: exogeneidad estricta

Para que $\hat{\beta}_{FE}$ sea consistente necesitamos:

$$\mathbb{E}[\varepsilon_{it} \mid D_{i1}, D_{i2}, \dots, D_{iT}, u_i] = 0 \quad \text{para todo } t.$$

¿Qué quiere decir esto?

- El error ε_{it} es ortogonal al tratamiento *en todos* los periodos, no solo el contemporáneo.
- **Permite** correlación arbitraria entre D_{it} y u_i (eso es justo lo que queremos).
- **No permite:** que un Y pasado influya un D futuro (causalidad inversa diferida).
- **No permite:** que las unidades anticipen D futuro y ajusten su comportamiento hoy.

En Camacho & Mejía: las aspersiones aéreas *no se anuncian* previamente.

- Los habitantes no pueden anticipar cuándo serán expuestos.
- Plausible que los ε_{it} (otros shocks de salud) sean ortogonales a las decisiones de aspersión.
- Es el argumento “cuasi-experimental” del paper.

Efectos fijos de tiempo y *two-way* FE

Análogo simétrico: algunos shocks afectan a *todas* las unidades en un mismo periodo (recesiones, cambios regulatorios nacionales, climáticos. . .).

Modelo extendido:

$$Y_{it} = \alpha + \beta D_{it} + u_i + \delta_t + \varepsilon_{it}$$

- u_i : heterogeneidad invariante en el tiempo, propia de la unidad.
- δ_t : shock común a todas las unidades en t .

Efectos fijos de tiempo y *two-way* FE

Análogo simétrico: algunos shocks afectan a *todas* las unidades en un mismo periodo (recesiones, cambios regulatorios nacionales, climáticos. . .).

Modelo extendido:

$$Y_{it} = \alpha + \beta D_{it} + u_i + \delta_t + \varepsilon_{it}$$

- u_i : heterogeneidad invariante en el tiempo, propia de la unidad.
- δ_t : shock común a todas las unidades en t .

Two-way fixed effects:

$\hat{\beta}_{TWFE}$ absorbe ambos: unidad y tiempo.

- En R: `feols(y ~ d | id + year, data = panel)`.
- Se identifica con variación *within* de *ambas* dimensiones.

Efectos fijos de tiempo y *two-way* FE

Análogo simétrico: algunos shocks afectan a *todas* las unidades en un mismo periodo (recesiones, cambios regulatorios nacionales, climáticos. . .).

Modelo extendido:

$$Y_{it} = \alpha + \beta D_{it} + u_i + \delta_t + \varepsilon_{it}$$

- u_i : heterogeneidad invariante en el tiempo, propia de la unidad.
- δ_t : shock común a todas las unidades en t .

Two-way fixed effects:

$\hat{\beta}_{TWFE}$ absorbe ambos: unidad y tiempo.

- En R: `feols(y ~ d | id + year, data = panel)`.
- Se identifica con variación *within* de *ambas* dimensiones.

Camacho & Mejía usan exactamente esto: FE de individuo + FE de año + FE de mes. Esto absorbe la salud basal individual y las estaciones de enfermedades respiratorias o las cosechas anuales.

¿Qué identifican los efectos fijos?

Solo la variación *intra*-unidad (dentro de cada i).

Si X_i es **invariante** en el tiempo (género, raza, lugar de nacimiento, año de fundación de una firma...), al aplicar la transformación within:

$$\tilde{X}_i = X_i - \bar{X}_i = 0 \quad \forall t.$$

X_i **desaparece** del modelo. Su coeficiente **no es identificable** bajo FE de unidad.

¿Qué identifican los efectos fijos?

Solo la variación *intra*-unidad (dentro de cada i).

Si X_i es **invariante** en el tiempo (género, raza, lugar de nacimiento, año de fundación de una firma...), al aplicar la transformación within:

$$\tilde{X}_i = X_i - \bar{X}_i = 0 \quad \forall t.$$

X_i **desaparece** del modelo. Su coeficiente **no es identificable** bajo FE de unidad.

Implicaciones:

- Si todo el interés es estimar el efecto de una variable que *no varía* dentro de las unidades, FE no sirve.
- Si D varía *poco* dentro de las unidades, $\hat{\beta}_{FE}$ tendrá *varianza alta*.
- Los coeficientes de FE no se interpretan: son “parámetros incidentales”.

¿Qué identifican los efectos fijos?

Solo la variación *intra*-unidad (dentro de cada i).

Si X_i es **invariante** en el tiempo (género, raza, lugar de nacimiento, año de fundación de una firma. . .), al aplicar la transformación within:

$$\tilde{X}_i = X_i - \bar{X}_i = 0 \quad \forall t.$$

X_i **desaparece** del modelo. Su coeficiente **no es identificable** bajo FE de unidad.

Implicaciones:

- Si todo el interés es estimar el efecto de una variable que *no varía* dentro de las unidades, FE no sirve.
- Si D varía *poco* dentro de las unidades, $\hat{\beta}_{FE}$ tendrá *varianza alta*.
- Los coeficientes de FE no se interpretan: son “parámetros incidentales”.

Lectura honesta: FE no es magia. Cambia la pregunta:

“¿Cuál es el efecto de D ?” $\rightarrow$ “¿Cuál es el efecto de cambios dentro de cada unidad en D ?”

Roadmap

- 1 Datos panel y heterogeneidad no observada
 - La idea fundamental
- 2 El estimador within: efectos fijos
 - La transformación within y sus propiedades
- 3 Inferencia: errores estándar clusterizados
 - Correlación intra-unidad y cluster-robust SE
- 4 Limitaciones del estimador FE
 - Lo que FE no resuelve
- 5 Camacho & Mejía (2017): aspersiones y salud en Colombia
 - Este paper
 - Contexto Colombiano
 - Datos y diseño
 - Resultados
- 6 Hands-on: Panel FE en R con datos simulados

El problema: residuales correlacionados dentro de la unidad

Punto recordado: en el modelo $Y_{it} = \alpha + \beta D_{it} + u_i + \varepsilon_{it}$, los residuales OLS contienen el componente u_i común a todos los periodos de la unidad i .

Consecuencia: los residuales están *serialmente correlacionados* dentro de cada unidad.

$$\text{Cov}(\nu_{it}, \nu_{is}) \neq 0 \quad \text{para } t \neq s, \quad \text{mismo } i.$$

Por qué importa: la fórmula clásica de errores estándar de OLS supone observaciones independientes. Si las observaciones están correlacionadas *dentro* de la unidad, los SE clásicos **subestiman** la varianza verdadera.

El problema: residuales correlacionados dentro de la unidad

Punto recordado: en el modelo $Y_{it} = \alpha + \beta D_{it} + u_i + \varepsilon_{it}$, los residuales OLS contienen el componente u_i común a todos los periodos de la unidad i .

Consecuencia: los residuales están *serialmente correlacionados* dentro de cada unidad.

$$\text{Cov}(\nu_{it}, \nu_{is}) \neq 0 \quad \text{para } t \neq s, \quad \text{mismo } i.$$

Por qué importa: la fórmula clásica de errores estándar de OLS supone observaciones independientes. Si las observaciones están correlacionadas *dentro* de la unidad, los SE clásicos **subestiman** la varianza verdadera.

Bertrand, Duflo & Mullainathan (2004), QJE: en aplicaciones panel/DiD reales, los SE no clusterizados pueden *sobrestimar* la significancia por **10x o más**.

- Un coeficiente con $t\text{-stat} = 8$ podría tener un $t\text{-stat}$ verdadero de ≈ 2 .
- Conclusiones espurias se vuelven la regla, no la excepción.

Cluster-robust standard errors

La solución: ajustar la varianza permitiendo correlación arbitraria *dentro* de cada cluster, asumiendo independencia *entre* clusters.

Idea: la fórmula sándwich agrupada

$$\widehat{\text{Var}}(\hat{\beta}) = (X'X)^{-1} \left(\sum_{g=1}^G X'_g \hat{v}_g \hat{v}'_g X_g \right) (X'X)^{-1}$$

donde g indexa clusters y $\hat{v}_g$ es el vector de residuales del cluster g .

Cluster-robust standard errors

La solución: ajustar la varianza permitiendo correlación arbitraria *dentro* de cada cluster, asumiendo independencia *entre* clusters.

Idea: la fórmula sándwich agrupada

$$\widehat{\text{Var}}(\hat{\beta}) = (X'X)^{-1} \left(\sum_{g=1}^G X'_g \hat{v}_g \hat{v}'_g X_g \right) (X'X)^{-1}$$

donde g indexa clusters y $\hat{v}_g$ es el vector de residuales del cluster g .

En la práctica:

- En R: `feols(y ~ d | id, cluster = ~ id)`.
- En Stata: `xtreg y d, fe vce(cluster id)`.

¿A qué nivel agrupar? Al *nivel de variación* del tratamiento.

- En C&M, s_{mt} varía a nivel *municipio-tiempo*, no individuo $\Rightarrow$ cluster al **nivel del municipio**, no del individuo.
- Regla general (Abadie, Athey, Imbens & Wooldridge, 2023): clusterizar al nivel donde la asignación al tratamiento es correlacionada.

¿Cuántos clusters son suficientes?

La asintótica de cluster-robust depende del número de *clusters* G , no del tamaño total $N \cdot T$.

Regla de pulgar: $G \geq 30$ –40 clusters para que la aproximación funcione razonablemente bien (Cameron & Miller, 2015).

¿Cuántos clusters son suficientes?

La asintótica de cluster-robust depende del número de *clusters* G , no del tamaño total $N \cdot T$.

Regla de pulgar: $G \geq 30$ –40 clusters para que la aproximación funcione razonablemente bien (Cameron & Miller, 2015).

Cuando G es chico:

- Los SE clusterizados están *a su vez* sesgados hacia abajo.
- Alternativas: *wild cluster bootstrap* (Cameron, Gelbach & Miller, 2008), corrección con grados de libertad, inferencia exacta Conley.

Ejemplos típicos:

- Panel de los 32 departamentos colombianos $\rightarrow G = 32$ es *justo* en el límite.
- Panel de 1.100+ municipios $\rightarrow G$ amplio, asintótica creíble.
- C&M: ~ 1.100 municipios $\Rightarrow$ holgadamente en la zona asintótica.

Roadmap

- 1 Datos panel y heterogeneidad no observada
 - La idea fundamental
- 2 El estimador within: efectos fijos
 - La transformación within y sus propiedades
- 3 Inferencia: errores estándar clusterizados
 - Correlación intra-unidad y cluster-robust SE
- 4 Limitaciones del estimador FE
 - Lo que FE no resuelve
- 5 Camacho & Mejía (2017): aspersiones y salud en Colombia
 - Este paper
 - Contexto Colombiano
 - Datos y diseño
 - Resultados
- 6 Hands-on: Panel FE en R con datos simulados

Lo que FE *no* resuelve

1. Heterogeneidad no observada que **SÍ** varía en el tiempo.

$$Y_{it} = \alpha + \beta D_{it} + u_i + \underbrace{w_{it}}_{\text{no observado, varía en } t} + \varepsilon_{it}$$

- La transformación within elimina u_i , pero *no* a w_{it} .
- Si $\text{Cov}(D_{it}, w_{it}) \neq 0$: el sesgo persiste.
- Ejemplo: cambios locales en acceso a salud que coinciden con cambios en aspersiones.

Lo que FE *no* resuelve

1. Heterogeneidad no observada que **SÍ** varía en el tiempo.

$$Y_{it} = \alpha + \beta D_{it} + u_i + \underbrace{w_{it}}_{\text{no observado, varía en } t} + \varepsilon_{it}$$

- La transformación within elimina u_i , pero *no* a w_{it} .
- Si $\text{Cov}(D_{it}, w_{it}) \neq 0$: el sesgo persiste.
- Ejemplo: cambios locales en acceso a salud que coinciden con cambios en aspersiones.

2. Causalidad inversa (simultaneidad).

- Si Y_{it} afecta a D_{it} , $\hat{\beta}_{FE}$ sigue siendo inconsistente.
- Ejemplo clásico: gasto en policía $\rightarrow$ crimen, pero crimen $\rightarrow$ gasto en policía.
- FE no rompe esta retroalimentación; típicamente hay que recurrir a IV.

Lo que FE *no* resuelve

1. Heterogeneidad no observada que **SÍ** varía en el tiempo.

$$Y_{it} = \alpha + \beta D_{it} + u_i + \underbrace{w_{it}}_{\text{no observado, varía en } t} + \varepsilon_{it}$$

- La transformación within elimina u_i , pero *no* a w_{it} .
- Si $\text{Cov}(D_{it}, w_{it}) \neq 0$: el sesgo persiste.
- Ejemplo: cambios locales en acceso a salud que coinciden con cambios en aspersiones.

2. Causalidad inversa (simultaneidad).

- Si Y_{it} afecta a D_{it} , $\hat{\beta}_{FE}$ sigue siendo inconsistente.
- Ejemplo clásico: gasto en policía $\rightarrow$ crimen, pero crimen $\rightarrow$ gasto en policía.
- FE no rompe esta retroalimentación; típicamente hay que recurrir a IV.

FE resuelve un tipo específico de endogeneidad: la asociada a heterogeneidad fija no observada. No es una bala de plata.

Los costos del estimador FE

1. Error de medida en D se amplifica.

- Si D_{it} se mide con ruido, la transformación within *aumenta* la proporción “señal/ruido” destruida.
- Resultado: $\hat{\beta}_{FE}$ está más atenuado (sesgado hacia 0) que el correspondiente OLS.

Los costos del estimador FE

1. Error de medida en D se amplifica.

- Si D_{it} se mide con ruido, la transformación within *aumenta* la proporción “señal/ruido” destruida.
- Resultado: $\hat{\beta}_{FE}$ está más atenuado (sesgado hacia 0) que el correspondiente OLS.

2. Varianza alta cuando D varía poco within.

- Identificación viene solo de $\tilde{D}_{it} = D_{it} - \bar{D}_i$.
- Si la mayoría de la variación de D es entre unidades (*between*), $\hat{\beta}_{FE}$ tiene varianza grande.
- Caso extremo: si D_i es constante en t para cada i (e.g., el género), FE *no* identifica β .

Los costos del estimador FE

1. Error de medida en D se amplifica.

- Si D_{it} se mide con ruido, la transformación within *aumenta* la proporción “señal/ruido” destruida.
- Resultado: $\hat{\beta}_{FE}$ está más atenuado (sesgado hacia 0) que el correspondiente OLS.

2. Varianza alta cuando D varía poco within.

- Identificación viene solo de $\tilde{D}_{it} = D_{it} - \bar{D}_i$.
- Si la mayoría de la variación de D es entre unidades (*between*), $\hat{\beta}_{FE}$ tiene varianza grande.
- Caso extremo: si D_i es constante en t para cada i (e.g., el género), FE *no* identifica β .

3. Reconocido por los propios autores. C&M (2017):

- No capturan efectos de *largo plazo* (datos solo cubren 2003–2007).
- Identifican efectos *a corto plazo* en personas que acuden al médico (selección de muestra).

¿Qué viene la próxima semana?

Caso especial del TWFE: ¿qué pasa cuando el tratamiento es *binario* y tiene una *fecha de inicio*?

Por ejemplo: una política se implementa en $t = t^*$ en el grupo A y nunca en el grupo B .

$$D_{it} = \begin{cases} 1 & \text{si } i \in A \text{ y } t \geq t^* \\ 0 & \text{en otro caso.} \end{cases}$$

Aplicar el TWFE a este caso:

$$Y_{it} = \alpha + \beta D_{it} + u_i + \delta_t + \varepsilon_{it}$$

es exactamente **Diferencias en Diferencias** (DiD).

¿Qué viene la próxima semana?

Caso especial del TWFE: ¿qué pasa cuando el tratamiento es *binario* y tiene una *fecha de inicio*?

Por ejemplo: una política se implementa en $t = t^*$ en el grupo A y nunca en el grupo B .

$$D_{it} = \begin{cases} 1 & \text{si } i \in A \text{ y } t \geq t^* \\ 0 & \text{en otro caso.} \end{cases}$$

Aplicar el TWFE a este caso:

$$Y_{it} = \alpha + \beta D_{it} + u_i + \delta_t + \varepsilon_{it}$$

es exactamente **Diferencias en Diferencias** (DiD).

Lo que cambia en la lectura:

- El supuesto identificador deja de ser “exogeneidad estricta” y se vuelve **tendencias paralelas**.
- Se vuelve más fácil pensar visualmente: dos curvas en el tiempo, una salta en t^* , la otra no.

Card & Krueger (1994): salarios mínimos en NJ vs. PA.

Roadmap

- 1 Datos panel y heterogeneidad no observada
 - La idea fundamental
- 2 El estimador within: efectos fijos
 - La transformación within y sus propiedades
- 3 Inferencia: errores estándar clusterizados
 - Correlación intra-unidad y cluster-robust SE
- 4 Limitaciones del estimador FE
 - Lo que FE no resuelve
- 5 Camacho & Mejía (2017): aspersiones y salud en Colombia
 - Este paper
 - Contexto Colombiano
 - Datos y diseño
 - Resultados
- 6 Hands-on: Panel FE en R con datos simulados

Este paper

Referencia

Camacho, A. & Mejía, D. (2017). The Health Consequences of Aerial Spraying of Illicit Crops: The Case of Colombia. *Journal of Health Economics*, 54: 147–160.

Pregunta: ¿las aspersiones aéreas con glifosato bajo Plan Colombia tienen efectos adversos sobre la salud individual?

Contribución metodológica:

- Primer paper en usar un cuasi-experimento para estimar el efecto causal del glifosato sobre salud en un país productor de coca.
- Combina un panel administrativo masivo (RIPS) con registros GPS de aspersiones.
- Usa FE individual para aislar heterogeneidad invariante (salud basal, genética, ubicación).

Resultado central (anticipo): la exposición al glifosato *aumenta* la probabilidad de consultas dermatológicas, respiratorias y abortos espontáneos, controlando por toda heterogeneidad fija.

Roadmap

- 1 Datos panel y heterogeneidad no observada
 - La idea fundamental
- 2 El estimador within: efectos fijos
 - La transformación within y sus propiedades
- 3 Inferencia: errores estándar clusterizados
 - Correlación intra-unidad y cluster-robust SE
- 4 Limitaciones del estimador FE
 - Lo que FE no resuelve
- 5 Camacho & Mejía (2017): aspersiones y salud en Colombia
 - Este paper
 - **Contexto Colombiano**
 - Datos y diseño
 - Resultados
- 6 Hands-on: Panel FE en R con datos simulados

Plan Colombia y las aspersiones aéreas

Plan Colombia (1999–). Estrategia conjunta Colombia–Estados Unidos contra la producción y tráfico de drogas.

- Inversión EE.UU.: ~US\$540 millones/año (2000–2008).
- Inversión Colombia: ~US\$812 millones/año.
- $\approx 1.2\%$ del PIB anual colombiano $\Rightarrow$ la intervención antidrogas más grande de la historia.

Aspersiones aéreas: la estrategia central.

- Avionetas operadas por contratistas estadounidenses (e.g., DynCorp).
- Roundup (glifosato + surfactante POEA) sobre cultivos detectados por satélite.
- Promedio: 128 mil ha/año asperjadas. Pico: 172 mil ha en 2006.
- Suspendido en 2015 tras la clasificación del glifosato como “probablemente cancerígeno” por la IARC/OMS.

La controversia:

- ONG y comunidades reportaban efectos adversos en salud.
- Evidencia previa: estudios de campo y de laboratorio, sin identificación causal limpia.
- Confundidor obvio: el cultivo de coca *en sí mismo* usa precursores químicos.

Roadmap

- 1 Datos panel y heterogeneidad no observada
 - La idea fundamental
- 2 El estimador within: efectos fijos
 - La transformación within y sus propiedades
- 3 Inferencia: errores estándar clusterizados
 - Correlación intra-unidad y cluster-robust SE
- 4 Limitaciones del estimador FE
 - Lo que FE no resuelve
- 5 Camacho & Mejía (2017): aspersiones y salud en Colombia
 - Este paper
 - Contexto Colombiano
 - Datos y diseño
 - Resultados
- 6 Hands-on: Panel FE en R con datos simulados

Datos: tres fuentes combinadas

1. RIPS (Registro Individual de Prestación de Servicios de Salud).

- Ministerio de Salud, 2003–2007.
- Toda consulta, urgencia, hospitalización y procedimiento en Colombia.
- ~45 millones de registros individuo–tiempo $\Rightarrow$ ~9.4 millones de personas únicas.
- Información: fecha, municipio, diagnóstico CIE-10, edad, sexo, aseguramiento.

2. Registros de aspersión (Policía Antinarcóticos).

- GPS a bordo de las avionetas $\Rightarrow$ ubicación y momento exactos.
- Datos *diarios* a nivel municipal.

3. Cultivo de coca (SIMCI, ONU).

- Imágenes satelitales anuales.
- Hectáreas de coca por municipio.

Controles municipales (CEDE, Uniandes): población, ingresos tributarios, ruralidad, gasto público en salud.

Especificación e identificación

$$y_{imt} = \alpha + \beta s_{mt} + \gamma' X_{mt} + \mu_i + \delta_t + \varepsilon_{imt}$$

- y_{imt} : $\mathbf{1}\{\text{consulta dermatológica o respiratoria}\}$ (o medida de aborto) para individuo i residente en municipio m en periodo t .
- s_{mt} : km^2 asperjados en m durante la ventana de exposición relevante.
- X_{mt} : cultivo de coca y controles socioeconómicos municipales.
- μ_i : **FE individual** (absorbe salud basal, genética, sexo, ubicación inicial...).
- δ_t : **FE de año y de mes** (absorbe estacionalidad, shocks nacionales).

El argumento de identificación (literal del paper):

“Comparamos la prevalencia de estas condiciones médicas para la misma persona bajo distintos niveles de exposición al herbicida usado en el programa de aspersión aérea durante un periodo de 5 años.”

Especificación e identificación

$$y_{imt} = \alpha + \beta s_{mt} + \gamma' X_{mt} + \mu_i + \delta_t + \varepsilon_{imt}$$

- y_{imt} : $\mathbf{1}\{\text{consulta dermatológica o respiratoria}\}$ (o medida de aborto) para individuo i residente en municipio m en periodo t .
- s_{mt} : km^2 asperjados en m durante la ventana de exposición relevante.
- X_{mt} : cultivo de coca y controles socioeconómicos municipales.
- μ_i : **FE individual** (absorbe salud basal, genética, sexo, ubicación inicial...).
- δ_t : **FE de año y de mes** (absorbe estacionalidad, shocks nacionales).

El argumento de identificación (literal del paper):

“Comparamos la prevalencia de estas condiciones médicas para la misma persona bajo distintos niveles de exposición al herbicida usado en el programa de aspersión aérea durante un periodo de 5 años.”

Detalle sutil: s_{mt} varía a nivel municipio–tiempo, no individuo. La variación intra-individuo viene de cambios temporales en el municipio de residencia (válido si el individuo no migra).

Roadmap

- 1 Datos panel y heterogeneidad no observada
 - La idea fundamental
- 2 El estimador within: efectos fijos
 - La transformación within y sus propiedades
- 3 Inferencia: errores estándar clusterizados
 - Correlación intra-unidad y cluster-robust SE
- 4 Limitaciones del estimador FE
 - Lo que FE no resuelve
- 5 Camacho & Mejía (2017): aspersiones y salud en Colombia
 - Este paper
 - Contexto Colombiano
 - Datos y diseño
 - Resultados
- 6 Hands-on: Panel FE en R con datos simulados

Resultados principales

Tres outcomes de salud de corto plazo:

1. Diagnósticos dermatológicos (ventana: 15 días post-exposición).

- $\hat{\beta} > 0$, significativo al 1%.
- Robusto al control por cultivo de coca y a la inclusión de FE individuales.

2. Diagnósticos respiratorios (ventana: 15 días).

- $\hat{\beta} > 0$, significativo al 1%.
- Magnitudes pequeñas pero precisamente estimadas (muestra masiva).

3. Abortos espontáneos (ventana: 9 meses, construido a partir de visitas prenatales sin parto registrado).

- $\hat{\beta} > 0$, significativo.
- Consistente con literatura médica previa.

Robustez y lectura honesta

Chequeos de robustez del paper:

- **Submuestra de no migrantes:** descarta que el efecto venga de movimiento residencial endógeno.
- **Submuestras por ingreso municipal:** verifican que el efecto no se concentra solo en municipios pobres.
- **Controles flexibles por área cultivada con coca:** aíslan el efecto del herbicida del efecto del cultivo *per se*.
- **Ventanas alternativas de exposición:** resultados estables al variar el horizonte temporal.

Robustez y lectura honesta

Chequeos de robustez del paper:

- **Submuestra de no migrantes:** descarta que el efecto venga de movimiento residencial endógeno.
- **Submuestras por ingreso municipal:** verifican que el efecto no se concentra solo en municipios pobres.
- **Controles flexibles por área cultivada con coca:** aíslan el efecto del herbicida del efecto del cultivo *per se*.
- **Ventanas alternativas de exposición:** resultados estables al variar el horizonte temporal.

Lectura honesta de los autores:

- No capturan efectos de **largo plazo** (datos solo cubren 2003–2007).
- Resultados válidos solo para población que **acude a servicios de salud** ⇒ selección de muestra.
- No identifican el mecanismo biológico exacto (toxicidad directa vs. POEA vs. estrés psicológico).

El FE individual es lo más cercano a un RCT en este contexto, pero no resuelve todos los problemas.

Roadmap

- 1 Datos panel y heterogeneidad no observada
 - La idea fundamental
- 2 El estimador within: efectos fijos
 - La transformación within y sus propiedades
- 3 Inferencia: errores estándar clusterizados
 - Correlación intra-unidad y cluster-robust SE
- 4 Limitaciones del estimador FE
 - Lo que FE no resuelve
- 5 Camacho & Mejía (2017): aspersiones y salud en Colombia
 - Este paper
 - Contexto Colombiano
 - Datos y diseño
 - Resultados
- 6 Hands-on: Panel FE en R con datos simulados

La simulación: un panel sintético tipo C&M

¿Por qué simular en lugar de replicar? Los datos RIPS son restringidos (Ministerio de Salud). La simulación permite *conocer* el parámetro verdadero β y verificar la mecánica del estimador.

Diseño del DGP:

- $N = 1,000$ individuos, $T = 5$ periodos $\Rightarrow$ 5.000 observaciones.
- $u_i \sim \mathcal{N}(0, 1)$, *invariante* en t ("salud basal").
- $s_{it} = 0.5 u_i + \eta_{it}$, con $\eta_{it} \sim \mathcal{N}(0, 1)$ ($\Rightarrow \text{Cov}(s, u) > 0$).
- X_{it} : control que varía en el tiempo (e.g., cultivo de coca).
- Modelo verdadero: $y_{it} = 0 + \underbrace{2}_{\beta} \cdot s_{it} + u_i + \delta_t + \varepsilon_{it}$.

Paquetes que usaremos:

- `fixest` — estimación con FE y SE clusterizados (Bergé).
- `modelsummary` — tablas comparativas.
- `ggplot2` y `dplyr` — visualización y manipulación.

Script de la sesión: `simulacion_panel_fe.R` (disponible en el repositorio del curso).

Qué estimaremos hoy en R

Comparación de cuatro especificaciones (con $\beta_{\text{verdadero}} = 2$):

Modelo 1 — OLS pooled (sesgado).

- `feols(y ~ s + x, data = panel).`
- Esperado: $\hat{\beta} > 2$ (sesgo positivo por $\text{Cov}(s, u) > 0$).

Modelo 2 — FE de unidad.

- `feols(y ~ s + x | id, data = panel).`
- Esperado: $\hat{\beta} \approx 2$.

Modelo 3 — Two-way FE (especificación tipo C&M).

- `feols(y ~ s + x | id + t, cluster = ~ id).`
- Esperado: $\hat{\beta} \approx 2$, SE más honesto.

Modelo 4 — Transformación within manual (verificación de equivalencia).

- Construir $\tilde{y}_{it}$ y $\tilde{s}_{it}$ a mano, luego `lm`.
- Esperado: idéntico al Modelo 2 hasta corrección de grados de libertad.

Comparación de errores estándar: naive vs. HC1 vs. cluster por id. Mostrar cuánto se *subestima* el SE naive frente al clusterizado.

Cierre y conexión con la próxima semana

Lo que vimos hoy:

- Datos panel = misma unidad observada en múltiples periodos.
- El *within estimator* elimina heterogeneidad invariante en el tiempo.
- TWFE absorbe simultáneamente u_i y δ_t .
- Inferencia: cluster-robust al nivel de variación del tratamiento.
- FE no resuelve confundidores variantes en el tiempo ni causalidad inversa.

Un detalle de C&M que abre la puerta a la próxima semana: su tratamiento s_{mt} es *continuo* y varía suavemente. ¿Y si el tratamiento fuera una *política* con fecha de inicio clara?

La próxima semana — Diferencias en Diferencias (DiD):

- Caso especial del TWFE con tratamiento binario y fecha de adopción.
- Supuesto identificador: *tendencias paralelas*.
- Visualmente más intuitivo: dos curvas, una salta en t^* , la otra no.

Card & Krueger (1994) — “Minimum Wages and Employment”.

Referencias

Paper de la semana

- Camacho, A. & Mejía, D. (2017). The Health Consequences of Aerial Spraying of Illicit Crops: The Case of Colombia. *Journal of Health Economics*, 54, 147–160. (Versión working paper en acceso abierto: CGD Working Paper 408, 2015.)

Lecturas del curso

- Cunningham, S. (2021). *Causal Inference: The Mixtape*, cap. 8.
- Angrist, J. D. & Pischke, J.-S. (2009). *Mostly Harmless Econometrics*, cap. 5.

Estimación panel y efectos fijos

- Wooldridge, J. M. (2010). *Econometric Analysis of Cross Section and Panel Data*, 2ª ed., cap. 10–11. MIT Press.
- Bergé, L. (2018). Efficient Estimation of Maximum Likelihood Models with Multiple Fixed-Effects: The R Package FENmlm. CREA Discussion Paper 2018-13.

Inferencia clusterizada

- Bertrand, M., Duflo, E. & Mullainathan, S. (2004). How Much Should We Trust Differences-in-Differences Estimates? *QJE*, 119(1), 249–275.
- Cameron, A. C. & Miller, D. L. (2015). A Practitioner's Guide to Cluster-Robust Inference. *Journal of Human Resources*, 50(2), 317–372.
- Abadie, A., Athey, S., Imbens, G. & Wooldridge, J. (2023). When Should You Adjust Standard Errors for Clustering? *QJE*, 138(1), 1–35.