

Inferencia, Causalidad y Políticas Públicas

ECO-60116

Week 06: Datos Panel y Efectos Fijos

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

May 22, 2026

Roadmap

- 1 Datos panel y heterogeneidad no observada
 - La idea fundamental
- 2 El estimador within: efectos fijos
 - Cómo eliminamos la heterogeneidad fija
 - Qué identifica y bajo qué supuestos
- 3 Inferencia: errores estándar clusterizados
 - Correlación intra-unidad y cluster-robust SE
- 4 Limitaciones del estimador FE
 - Lo que FE no resuelve
- 5 Camacho & Mejía (2017): aspersiones y salud en Colombia
 - Este paper
 - Contexto Colombiano
 - Datos y diseño
 - Resultados
- 6 Hands-on: Panel FE en R con datos simulados

RECAP: Fuzzy RD

- **Motivación:** cumplimiento imperfecto del umbral — ser elegible $\neq$ ser tratado.
- **La idea:** Fuzzy RD = *IV local* en el umbral.
 - ▶ Instrumento: $Z_i = \mathbf{1}\{X_i \geq c\}$.
 - ▶ Variable endógena: D_i (recepción efectiva del tratamiento).
- **Estimación:** 2SLS con regresión local polinómica a cada lado del umbral.
 - ▶ 1ª etapa: $D_i = \pi_0 + \pi_1 Z_i + f(X_i - c) + \eta_i$.
 - ▶ Forma reducida: $Y_i = \rho_0 + \rho_1 Z_i + g(X_i - c) + \varepsilon_i$.
 - ▶ Wald local: $\hat{\tau}_{FRD} = \hat{\rho}_1 / \hat{\pi}_1$.

RECAP: Fuzzy RD

- **Motivación:** cumplimiento imperfecto del umbral — ser elegible $\neq$ ser tratado.
- **La idea:** Fuzzy RD = *IV local* en el umbral.
 - ▶ Instrumento: $Z_i = \mathbf{1}\{X_i \geq c\}$.
 - ▶ Variable endógena: D_i (recepción efectiva del tratamiento).
- **Estimación:** 2SLS con regresión local polinómica a cada lado del umbral.
 - ▶ 1ª etapa: $D_i = \pi_0 + \pi_1 Z_i + f(X_i - c) + \eta_i$.
 - ▶ Forma reducida: $Y_i = \rho_0 + \rho_1 Z_i + g(X_i - c) + \varepsilon_i$.
 - ▶ Wald local: $\hat{\tau}_{FRD} = \hat{\rho}_1 / \hat{\pi}_1$.
- **Interpretación:** LATE local — efecto sobre los *compliers en el umbral*.
- **Pruebas de validación:** densidad (McCrary), balance de covariables, umbrales placebo, primera etapa fuerte.

De RD a panel: el tiempo como recurso

Lo que hemos hecho hasta ahora: explotar variación cuasi-aleatoria *entre* unidades.

- RCT: aleatorización por diseño.
- IV: una fuente exógena (Z) que mueve el tratamiento.
- RD (sharp y fuzzy): el umbral genera comparables locales.

Pero a veces no hay umbral, ni instrumento, ni aleatorización.

De RD a panel: el tiempo como recurso

Lo que hemos hecho hasta ahora: explotar variación cuasi-aleatoria *entre* unidades.

- RCT: aleatorización por diseño.
- IV: una fuente exógena (Z) que mueve el tratamiento.
- RD (sharp y fuzzy): el umbral genera comparables locales.

Pero a veces no hay umbral, ni instrumento, ni aleatorización.

La pregunta de esta semana

¿Qué pasa si observamos a la *misma* unidad en varios momentos del tiempo?
¿Puede el *tiempo* ser un recurso para identificar efectos causales?

Respuesta breve: sí, si la fuente del sesgo no cambia en el tiempo.

Roadmap

- 1 Datos panel y heterogeneidad no observada
 - La idea fundamental
- 2 El estimador within: efectos fijos
 - Cómo eliminamos la heterogeneidad fija
 - Qué identifica y bajo qué supuestos
- 3 Inferencia: errores estándar clusterizados
 - Correlación intra-unidad y cluster-robust SE
- 4 Limitaciones del estimador FE
 - Lo que FE no resuelve
- 5 Camacho & Mejía (2017): aspersiones y salud en Colombia
 - Este paper
 - Contexto Colombiano
 - Datos y diseño
 - Resultados
- 6 Hands-on: Panel FE en R con datos simulados

La idea intuitiva

El problema clásico: comparar personas distintas que difieren en cosas no observadas.

Ejemplo: queremos saber si el salario aumenta con la experiencia laboral.

- Comparar a Juan (15 años de experiencia) con María (3 años) no funciona: Juan también tiene más *habilidad*, más *contactos*, vivió en mejor *vecindario*.
- Esos factores no observados están correlacionados con experiencia $\Rightarrow$ sesgo por variable omitida.

El cambio de perspectiva: ¿y si observo a *Juan* en distintos momentos del tiempo?

- Juan con 5 años de experiencia $\rightarrow$ Juan con 6 años $\rightarrow$ Juan con 7 años.
- Su habilidad, sus contactos, su entorno familiar: **casi no cambian** año a año.
- Lo que cambia es la experiencia (y el salario).

Comparar a Juan consigo mismo es como tener un grupo de control hecho a la medida.

¿Qué es un panel?

Un **panel** (o **datos longitudinales**) es un dataset donde observamos las mismas unidades i en múltiples periodos t .

Notación:

- $i = 1, 2, \dots, N$ indexa unidades (personas, firmas, municipios, países...).
- $t = 1, 2, \dots, T$ indexa periodos (años, meses, días...).
- Y_{it} , D_{it} , X_{it} : outcome, tratamiento, covariables en la unidad i y periodo t .

Balanceado vs. desbalanceado:

- *Balanceado*: todas las unidades aparecen en todos los periodos ($N \times T$ observaciones).
- *Desbalanceado*: algunas unidades faltan en algunos periodos — lo más común con datos administrativos.

Ejemplo: el paper de esta semana


Camacho & Mejía (2017) trabajan con un panel **desbalanceado** de ~ 9.4 millones de individuos colombianos, observados en distintos momentos entre 2003 y 2007 cada vez que asistieron a una consulta médica.

Heterogeneidad no observada e invariante en el tiempo

El modelo de fondo:

$$Y_{it} = \alpha + \beta D_{it} + \underbrace{u_i}_{\substack{\text{no observado} \\ \text{invariante en } t}} + \varepsilon_{it}$$

donde u_i recoge todo factor individual no observado que **no cambia en el tiempo**: habilidad, salud basal, genética, contexto familiar...



Lo crítico: u_i es el *mismo* en $t = 1$ y en $t = 2$. Es esa estabilidad la que vamos a explotar.

¿Por qué OLS pooled está sesgado?

OLS pooled: aplicar OLS al panel tratándolo como una cross-section, ignorando el índice t .

$$Y_{it} = \alpha + \beta D_{it} + \nu_{it}, \quad \text{donde } \nu_{it} = u_i + \varepsilon_{it}$$

El residual ν_{it} **contiene** la heterogeneidad invariante u_i .

Sesgo por variable omitida: si $\text{Cov}(D_{it}, u_i) \neq 0$,

$$\hat{\beta}_{\text{pooled}} \xrightarrow{p} \beta + \frac{\text{Cov}(D_{it}, u_i)}{\text{Var}(D_{it})}$$

Y peor aún: aún con $\text{Cov}(D_{it}, u_i) = 0$, los residuales ν_{it} *están correlacionados entre sí* para la misma unidad i (porque u_i es el mismo en todo t) $\Rightarrow$ los errores estándar OLS son inválidos.

La pregunta práctica: ¿cómo identificamos β sin observar u_i ?

Hoy entra en escena un paper

Camacho & Mejía (2017)

"The Health Consequences of Aerial Spraying of Illicit Crops: The Case of Colombia". Journal of Health Economics, 54: 147–160.

La pregunta: ¿las aspersiones aéreas con glifosato bajo Plan Colombia generan efectos negativos sobre la salud de la población?

Hoy entra en escena un paper

Camacho & Mejía (2017)

"The Health Consequences of Aerial Spraying of Illicit Crops: The Case of Colombia". Journal of Health Economics, 54: 147–160.

La pregunta: ¿las aspersiones aéreas con glifosato bajo Plan Colombia generan efectos negativos sobre la salud de la población?

El problema de identificación:

- Las áreas asperjadas son, por diseño, las áreas con cultivos de coca.
- Las áreas con coca son rurales, pobres, con peor salud basal.
- Comparar municipios asperjados vs. no asperjados $\Rightarrow$ sesgo masivo.

Hoy entra en escena un paper

Camacho & Mejía (2017)

"The Health Consequences of Aerial Spraying of Illicit Crops: The Case of Colombia". Journal of Health Economics, 54: 147–160.

La pregunta: ¿las aspersiones aéreas con glifosato bajo Plan Colombia generan efectos negativos sobre la salud de la población?

El problema de identificación:

- Las áreas asperjadas son, por diseño, las áreas con cultivos de coca.
- Las áreas con coca son rurales, pobres, con peor salud basal.
- Comparar municipios asperjados vs. no asperjados $\Rightarrow$ sesgo masivo.

La solución: observar a la *misma persona* bajo distintos niveles de exposición a lo largo del tiempo, eliminando todo lo que no varía en t .

- i : individuo. t : fecha de consulta médica (2003–2007).
- D_{it} : km² asperjados en el municipio de residencia.
- Y_{it} : $1\{\text{consulta dermatológica, respiratoria o aborto}\}$.

Roadmap

- 1 Datos panel y heterogeneidad no observada
 - La idea fundamental
- 2 El estimador within: efectos fijos
 - Cómo eliminamos la heterogeneidad fija
 - Qué identifica y bajo qué supuestos
- 3 Inferencia: errores estándar clusterizados
 - Correlación intra-unidad y cluster-robust SE
- 4 Limitaciones del estimador FE
 - Lo que FE no resuelve
- 5 Camacho & Mejía (2017): aspersiones y salud en Colombia
 - Este paper
 - Contexto Colombiano
 - Datos y diseño
 - Resultados
- 6 Hands-on: Panel FE en R con datos simulados

La idea: ¿cómo sacamos algo que no observamos?

El obstáculo: la heterogeneidad fija u_i (habilidad, salud basal...) sesga el estimador, pero *no la observamos*. No podemos “controlar por” una variable que no medimos.

La idea clave: no necesitamos *medir* u_i ; basta con *deshacernos* de él.

- u_i tiene una propiedad especial: **es el mismo en todos los periodos** de la unidad i .
- Todo lo que sea *constante dentro de la unidad* se puede borrar comparando a la unidad *consigo misma* a lo largo del tiempo.

La idea: ¿cómo sacamos algo que no observamos?

El obstáculo: la heterogeneidad fija u_i (habilidad, salud basal...) sesga el estimador, pero *no la observamos*. No podemos “controlar por” una variable que no medimos.

La idea clave: no necesitamos *medir* u_i ; basta con *deshacernos* de él.

- u_i tiene una propiedad especial: **es el mismo en todos los periodos** de la unidad i .
- Todo lo que sea *constante dentro de la unidad* se puede borrar comparando a la unidad *consigo misma* a lo largo del tiempo.

Si a cada observación de Juan le resto el “Juan promedio”, lo que queda son sus *desviaciones* en el tiempo —y ahí u_i ya no está.

Esa resta tiene nombre: la transformación within. Veámosla en detalle.

La transformación within

La idea: restar a cada observación la media de su propia unidad —esto es la **transformación within** (o *centrado intra-unidad*).

Punto de partida: el modelo con heterogeneidad invariante.

$$Y_{it} = \alpha + \beta D_{it} + u_i + \varepsilon_{it} \quad (1)$$

Paso 1. Tomar el promedio dentro de cada unidad i a lo largo del tiempo:

$$\bar{Y}_i = \alpha + \beta \bar{D}_i + u_i + \bar{\varepsilon}_i \quad (2)$$

donde $\bar{Y}_i = \frac{1}{T_i} \sum_t Y_{it}$, y análogo para $\bar{D}_i$ y $\bar{\varepsilon}_i$.

Paso 2. Restar (2) de (1):

$$\underbrace{Y_{it} - \bar{Y}_i}_{\tilde{Y}_{it}} = \beta \underbrace{(D_{it} - \bar{D}_i)}_{\tilde{D}_{it}} + \underbrace{(\varepsilon_{it} - \bar{\varepsilon}_i)}_{\tilde{\varepsilon}_{it}}$$

¿ u_i ? Como $u_i = \bar{u}_i$ (es constante en t), **se cancela**.

$$\tilde{Y}_{it} = \beta \tilde{D}_{it} + \tilde{\varepsilon}_{it}$$


OLS sobre las variables centradas $\Rightarrow$ **estimador within** (= efectos fijos).

Qué hace la transformación within (visualmente)

Cada color es una unidad i ; cada punto, una observación (D_{it}, Y_{it}) . El within *centra* cada nube en su propia media.

Datos crudos


la recta *pooled* (gris) confunde *between* con *within*



Pendiente *between* < 0

Datos centrados (within)

$$\tilde{D}_{it} = D_{it} - \bar{D}_i, \quad \tilde{Y}_{it} = Y_{it} - \bar{Y}_i$$



Pendiente *within* > 0 (la verdadera)

La lección: FE descarta la variación *between* —entre unidades, donde vive el sesgo de u_i — y usa solo la variación *within*, dentro de cada unidad.

Tres formas equivalentes de estimar $\hat{\beta}_{FE}$

Los tres procedimientos siguientes producen **numéricamente el mismo** $\hat{\beta}$:

1. Centrar dentro de la unidad (within) y correr OLS.

- Construir $\tilde{Y}_{it}$ y $\tilde{D}_{it}$ unidad por unidad, luego regresar.
- Útil para ver *qué hace* el método. Engorroso en la práctica.

2. Regresión con dummies de unidad (LSDV).

$$Y_{it} = \beta D_{it} + \sum_{j=1}^N \mu_j \mathbf{1}\{i = j\} + \varepsilon_{it}$$

- Incluir N dummies absorbe los u_i .
- Inviabile si N es grande ($N = 9.4M$ en C&M...).

3. Comando dedicado (lo estándar hoy).

- En R: `feols(y ~ d | id, data = panel)` — absorbe los FE sin estimarlos.
- En Stata: `reghdfe y d, absorb(id)`.

Las tres rutas dan idéntico $\hat{\beta}$. Lo que cambia es la facilidad de cómputo.

Efectos fijos de tiempo y *two-way* FE

Análogo simétrico: así como absorbemos lo fijo de cada unidad, podemos absorber lo común a todas las unidades en un mismo periodo (recesiones, cambios regulatorios nacionales, climáticos. . .).

Modelo extendido:

$$Y_{it} = \alpha + \beta D_{it} + u_i + \delta_t + \varepsilon_{it}$$

- u_i : heterogeneidad invariante en el tiempo, propia de la unidad.
- δ_t : shock común a todas las unidades en t .

Efectos fijos de tiempo y *two-way* FE

Análogo simétrico: así como absorbemos lo fijo de cada unidad, podemos absorber lo común a todas las unidades en un mismo periodo (recesiones, cambios regulatorios nacionales, climáticos. . .).

Modelo extendido:

$$Y_{it} = \alpha + \beta D_{it} + u_i + \delta_t + \varepsilon_{it}$$

- u_i : heterogeneidad invariante en el tiempo, propia de la unidad.
- δ_t : shock común a todas las unidades en t .

Two-way fixed effects:

$\hat{\beta}_{TWFE}$ absorbe ambos: unidad y tiempo.

- En R: `feols(y ~ d | id + year, data = panel)`.
- Se identifica con variación *within* de *ambas* dimensiones.

Efectos fijos de tiempo y *two-way* FE

Análogo simétrico: así como absorbemos lo fijo de cada unidad, podemos absorber lo común a todas las unidades en un mismo periodo (recesiones, cambios regulatorios nacionales, climáticos. . .).

Modelo extendido:

$$Y_{it} = \alpha + \beta D_{it} + u_i + \delta_t + \varepsilon_{it}$$

- u_i : heterogeneidad invariante en el tiempo, propia de la unidad.
- δ_t : shock común a todas las unidades en t .

Two-way fixed effects:

$\hat{\beta}_{TWFE}$ absorbe ambos: unidad y tiempo.

- En R: `feols(y ~ d | id + year, data = panel)`.
- Se identifica con variación *within* de *ambas* dimensiones.

Camacho & Mejía usan exactamente esto: FE de individuo + FE de año + FE de mes. Esto absorbe la salud basal individual y las estaciones de enfermedades respiratorias o las cosechas anuales.

Primeras diferencias: la otra forma de eliminar u_i

La idea: el within elimina u_i *centrando cada unidad en su media*; primeras diferencias (FD) lo elimina *diferenciando* (restando el periodo anterior). Mismo objetivo, otra ruta.

Punto de partida: el mismo modelo con heterogeneidad invariante.

$$Y_{it} = \alpha + \beta D_{it} + u_i + \varepsilon_{it} \quad (1)$$

Restar el periodo anterior ($t - 1$), con $\Delta Y_{it} \equiv Y_{it} - Y_{i,t-1}$:

$$\Delta Y_{it} = \beta \Delta D_{it} + \Delta \varepsilon_{it}$$

α y u_i **se cancelan**, porque son constantes en el tiempo.

Primeras diferencias: la otra forma de eliminar u_i

La idea: el within elimina u_i *centrando cada unidad en su media*; primeras diferencias (FD) lo elimina *diferenciando* (restando el periodo anterior). Mismo objetivo, otra ruta.

Punto de partida: el mismo modelo con heterogeneidad invariante.

$$Y_{it} = \alpha + \beta D_{it} + u_i + \varepsilon_{it} \quad (1)$$

Restar el periodo anterior ($t - 1$), con $\Delta Y_{it} \equiv Y_{it} - Y_{i,t-1}$:

$$\Delta Y_{it} = \beta \Delta D_{it} + \Delta \varepsilon_{it}$$

α y u_i **se cancelan**, porque son constantes en el tiempo.

$$\Delta Y_{it} = \beta \Delta D_{it} + \Delta \varepsilon_{it}$$

El resultado clave ($T = 2$): con solo dos periodos, FD y within (FE) dan numéricamente el mismo $\hat{\beta}$ —con $T = 2$, centrar cada unidad en su media equivale, salvo un factor de escala, a tomar la primera diferencia—. No hay que elegir.

Dos formas de borrar lo que no cambia: restarle a cada unidad su media, o restarle su pasado.

¿Within o primeras diferencias? ($T > 2$)

Con más de dos periodos son estimadores **distintos**. Ambos son consistentes bajo exogeneidad estricta; difieren en *eficiencia* según la correlación serial de ε_{it} .

- Si ε_{it} **no tiene correlación serial** (el supuesto clásico): el **within es más eficiente**. Diferenciar introduce un error MA(1) que el propio FD se autogenera.
- Si ε_{it} **es una caminata aleatoria**: entonces $\Delta\varepsilon_{it}$ es ruido blanco $\Rightarrow$ **FD es más eficiente**.

¿Within o primeras diferencias? ($T > 2$)

Con más de dos periodos son estimadores **distintos**. Ambos son consistentes bajo exogeneidad estricta; difieren en *eficiencia* según la correlación serial de ε_{it} .

- Si ε_{it} **no tiene correlación serial** (el supuesto clásico): el **within es más eficiente**. Diferenciar introduce un error MA(1) que el propio FD se autogenera.
- Si ε_{it} **es una caminata aleatoria**: entonces $\Delta\varepsilon_{it}$ es ruido blanco $\Rightarrow$ **FD es más eficiente**.

Lectura honesta (Angrist & Pischke, cap. 5): como la verdad rara vez está en un extremo, corre *ambos* y compáralos.

- Coinciden $\Rightarrow$ tranquilidad.
- Divergen mucho $\Rightarrow$ síntoma de que la exogeneidad estricta falla: dinámica, anticipación o error de medida. Es un *diagnóstico*, no solo una alternativa.

¿Within o primeras diferencias? ($T > 2$)

Con más de dos periodos son estimadores **distintos**. Ambos son consistentes bajo exogeneidad estricta; difieren en *eficiencia* según la correlación serial de ε_{it} .

- Si ε_{it} **no tiene correlación serial** (el supuesto clásico): el **within es más eficiente**. Diferenciar introduce un error MA(1) que el propio FD se autogenera.
- Si ε_{it} **es una caminata aleatoria**: entonces $\Delta\varepsilon_{it}$ es ruido blanco $\Rightarrow$ **FD es más eficiente**.

Lectura honesta (Angrist & Pischke, cap. 5): como la verdad rara vez está en un extremo, corre *ambos* y compáralos.

- Coinciden $\Rightarrow$ tranquilidad.
- Divergen mucho $\Rightarrow$ síntoma de que la exogeneidad estricta falla: dinámica, anticipación o error de medida. Es un *diagnóstico*, no solo una alternativa.

La conexión con la próxima semana: si D es *binario* con un antes/después, la primera diferencia del grupo tratado menos la del control es exactamente **Diferencias en Diferencias**.

(Nota sobre C&M: su panel es desbalanceado, con fechas de consulta irregulares; FD exige periodos adyacentes regulares, por eso usan FE.)

Roadmap

- 1 Datos panel y heterogeneidad no observada
 - La idea fundamental
- 2 El estimador within: efectos fijos
 - Cómo eliminamos la heterogeneidad fija
 - Qué identifica y bajo qué supuestos
- 3 Inferencia: errores estándar clusterizados
 - Correlación intra-unidad y cluster-robust SE
- 4 Limitaciones del estimador FE
 - Lo que FE no resuelve
- 5 Camacho & Mejía (2017): aspersiones y salud en Colombia
 - Este paper
 - Contexto Colombiano
 - Datos y diseño
 - Resultados
- 6 Hands-on: Panel FE en R con datos simulados

El supuesto clave: exogeneidad estricta

Para que $\hat{\beta}_{FE}$ sea consistente necesitamos:

$$\mathbb{E}[\varepsilon_{it} \mid D_{i1}, D_{i2}, \dots, D_{iT}, u_i] = 0 \quad \text{para todo } t.$$

¿Qué quiere decir esto?

- El error ε_{it} es ortogonal al tratamiento *en todos* los periodos, no solo el contemporáneo.
- **Permite** correlación arbitraria entre D_{it} y u_i (eso es justo lo que queremos).
- **No permite:** que un Y pasado influya un D futuro (causalidad inversa diferida).
- **No permite:** que las unidades anticipen D futuro y ajusten su comportamiento hoy.

El supuesto clave: exogeneidad estricta

Para que $\hat{\beta}_{FE}$ sea consistente necesitamos:

$$\mathbb{E}[\varepsilon_{it} \mid D_{i1}, D_{i2}, \dots, D_{iT}, u_i] = 0 \quad \text{para todo } t.$$

¿Qué quiere decir esto?

- El error ε_{it} es ortogonal al tratamiento *en todos* los periodos, no solo el contemporáneo.
- **Permite** correlación arbitraria entre D_{it} y u_i (eso es justo lo que queremos).
- **No permite:** que un Y pasado influya un D futuro (causalidad inversa diferida).
- **No permite:** que las unidades anticipen D futuro y ajusten su comportamiento hoy.

En Camacho & Mejía: las aspersiones aéreas *no se anuncian* previamente.

- Los habitantes no pueden anticipar cuándo serán expuestos.
- Plausible que los ε_{it} (otros shocks de salud) sean ortogonales a las decisiones de aspersión.
- Es el argumento “cuasi-experimental” del paper.

¿Qué identifican los efectos fijos?

Solo la variación *intra*-unidad (dentro de cada i).

Si X_i es **invariante** en el tiempo (género, raza, lugar de nacimiento, año de fundación de una firma. . .), al aplicar la transformación within:

$$\tilde{X}_i = X_i - \bar{X}_i = 0 \quad \forall t.$$

X_i **desaparece** del modelo. Su coeficiente **no es identificable** bajo FE de unidad.

¿Qué identifican los efectos fijos?

Solo la variación *intra*-unidad (dentro de cada i).

Si X_i es **invariante** en el tiempo (género, raza, lugar de nacimiento, año de fundación de una firma...), al aplicar la transformación within:

$$\tilde{X}_i = X_i - \bar{X}_i = 0 \quad \forall t.$$

X_i **desaparece** del modelo. Su coeficiente **no es identificable** bajo FE de unidad.

Implicaciones:

- Si todo el interés es estimar el efecto de una variable que *no varía* dentro de las unidades, FE no sirve.
- Si D varía *poco* dentro de las unidades, $\hat{\beta}_{FE}$ tendrá *varianza alta*.
- Los coeficientes de FE no se interpretan: son “parámetros incidentales”.

¿Qué identifican los efectos fijos?

Solo la variación *intra*-unidad (dentro de cada i).

Si X_i es **invariante** en el tiempo (género, raza, lugar de nacimiento, año de fundación de una firma. . .), al aplicar la transformación within:

$$\tilde{X}_i = X_i - \bar{X}_i = 0 \quad \forall t.$$

X_i **desaparece** del modelo. Su coeficiente **no es identificable** bajo FE de unidad.

Implicaciones:

- Si todo el interés es estimar el efecto de una variable que *no varía* dentro de las unidades, FE no sirve.
- Si D varía *poco* dentro de las unidades, $\hat{\beta}_{FE}$ tendrá *varianza alta*.
- Los coeficientes de FE no se interpretan: son “parámetros incidentales”.

Lectura honesta: FE no es magia. Cambia la pregunta:

“¿Cuál es el efecto de D ?” $\rightarrow$ “¿Cuál es el efecto de cambios dentro de cada unidad en D ?”

Roadmap

- 1 Datos panel y heterogeneidad no observada
 - La idea fundamental
- 2 El estimador within: efectos fijos
 - Cómo eliminamos la heterogeneidad fija
 - Qué identifica y bajo qué supuestos
- 3 Inferencia: errores estándar clusterizados
 - Correlación intra-unidad y cluster-robust SE
- 4 Limitaciones del estimador FE
 - Lo que FE no resuelve
- 5 Camacho & Mejía (2017): aspersiones y salud en Colombia
 - Este paper
 - Contexto Colombiano
 - Datos y diseño
 - Resultados
- 6 Hands-on: Panel FE en R con datos simulados

El problema, en intuición: las cinco visitas de Juan

Volvamos a Juan, que aparece en nuestro panel **cinco veces** (una por periodo). Supongamos que Juan es, por su naturaleza, una persona *más sana* que el promedio.

¿Qué les pasa a sus cinco residuales?

- En cada visita, el modelo *subpredice* su salud (Juan está siempre por encima de lo esperado).
- Sus cinco residuales **se inclinan todos hacia el mismo lado**: no son cinco sorpresas independientes.

El problema, en intuición: las cinco visitas de Juan

Volvamos a Juan, que aparece en nuestro panel **cinco veces** (una por periodo). Supongamos que Juan es, por su naturaleza, una persona *más sana* que el promedio.

¿Qué les pasa a sus cinco residuales?

- En cada visita, el modelo *subpredice* su salud (Juan está siempre por encima de lo esperado).
- Sus cinco residuales **se inclinan todos hacia el mismo lado**: no son cinco sorpresas independientes.

La consecuencia, en una frase:

Las cinco filas de Juan **no son cinco datos nuevos**; son casi el *mismo* dato repetido cinco veces.


Y esto vale para cada persona del panel. La pregunta natural: ¿cuánta información realmente tengo?

¿Cuánta información tengo en realidad?

Cada punto es un residual; cada color, una persona observada 5 veces. Lo que OLS *supone* frente a lo que de verdad ocurre:

Lo que OLS supone


residuales independientes, sin patrón por persona



$N \cdot T = 5,000$ datos independientes

Lo que de verdad ocurre

cada persona se agrupa de un lado



información efectiva $\approx N = 1,000$ personas

La lección: OLS cuenta cada fila como un dato nuevo. Si las filas de cada persona son redundantes, mi muestra *efectiva* es mucho menor $\Rightarrow$ los SE clásicos salen **artificialmente pequeños**.

El problema, en formalismo

De dónde viene: en $Y_{it} = \alpha + \beta D_{it} + u_i + \varepsilon_{it}$, el residual OLS arrastra el componente u_i , común a *todos* los periodos de la unidad i .

Formalmente: los residuales están *serialmente correlacionados* dentro de cada unidad.

$$\text{Cov}(\nu_{it}, \nu_{is}) \neq 0 \quad \text{para } t \neq s, \quad \text{misma unidad } i.$$

La fórmula clásica de SE supone $\text{Cov}(\nu_{it}, \nu_{is}) = 0$ (independencia). Al no cumplirse, los SE clásicos **subestiman** la varianza verdadera —justo lo que vimos con Juan.

El problema, en formalismo

De dónde viene: en $Y_{it} = \alpha + \beta D_{it} + u_i + \varepsilon_{it}$, el residual OLS arrastra el componente u_i , común a *todos* los periodos de la unidad i .

Formalmente: los residuales están *serialmente correlacionados* dentro de cada unidad.

$$\text{Cov}(\nu_{it}, \nu_{is}) \neq 0 \quad \text{para } t \neq s, \quad \text{misma unidad } i.$$

La fórmula clásica de SE supone $\text{Cov}(\nu_{it}, \nu_{is}) = 0$ (independencia). Al no cumplirse, los SE clásicos **subestiman** la varianza verdadera —justo lo que vimos con Juan.

¿Qué tan grave es? Bertrand, Duflo & Mullainathan (2004), QJE:

- En aplicaciones panel/DiD reales, los SE no clusterizados *sobrestiman* la significancia por **10x o más**.
- Un coeficiente con $t\text{-stat} = 8$ podría tener un $t\text{-stat}$ verdadero de ≈ 2 : conclusiones espurias como regla, no excepción.

Cluster-robust standard errors

La solución: ajustar la varianza permitiendo correlación arbitraria *dentro* de cada cluster, asumiendo independencia *entre* clusters.

Idea: la fórmula sándwich agrupada

$$\widehat{\text{Var}}(\hat{\beta}) = (X'X)^{-1} \left(\sum_{g=1}^G X'_g \hat{v}_g \hat{v}'_g X_g \right) (X'X)^{-1}$$

donde g indexa clusters y $\hat{v}_g$ es el vector de residuales del cluster g .

Cluster-robust standard errors

La solución: ajustar la varianza permitiendo correlación arbitraria *dentro* de cada cluster, asumiendo independencia *entre* clusters.

Idea: la fórmula sándwich agrupada

$$\widehat{\text{Var}}(\hat{\beta}) = (X'X)^{-1} \left(\sum_{g=1}^G X'_g \hat{v}_g \hat{v}'_g X_g \right) (X'X)^{-1}$$

donde g indexa clusters y $\hat{v}_g$ es el vector de residuales del cluster g .

En la práctica:

- En R: `feols(y ~ d | id, cluster = ~ id)`.
- En Stata: `xtreg y d, fe vce(cluster id)`.

¿A qué nivel agrupar? Al *nivel de variación* del tratamiento.

- En C&M, s_{mt} varía a nivel *municipio-tiempo*, no individuo $\Rightarrow$ cluster al **nivel del municipio**, no del individuo.
- Regla general (Abadie, Athey, Imbens & Wooldridge, 2023): clusterizar al nivel donde la asignación al tratamiento es correlacionada.

¿Cuántos clusters son suficientes?

La asintótica de cluster-robust depende del número de *clusters* G , no del tamaño total $N \cdot T$.

Regla de pulgar: $G \geq 30$ –40 clusters para que la aproximación funcione razonablemente bien (Cameron & Miller, 2015).

Cuando G es chico:

- Los SE clusterizados están *a su vez* sesgados hacia abajo.
- Alternativas: *wild cluster bootstrap* (Cameron, Gelbach & Miller, 2008), corrección con grados de libertad, inferencia exacta Conley.

Ejemplos típicos:

- Panel de los 32 departamentos colombianos $\rightarrow G = 32$ es *justo* en el límite.
- Panel de 1.100+ municipios $\rightarrow G$ amplio, asintótica creíble.
- C&M: ~ 1.100 municipios $\Rightarrow$ holgadamente en la zona asintótica.

Roadmap

- 1 Datos panel y heterogeneidad no observada
 - La idea fundamental
- 2 El estimador within: efectos fijos
 - Cómo eliminamos la heterogeneidad fija
 - Qué identifica y bajo qué supuestos
- 3 Inferencia: errores estándar clusterizados
 - Correlación intra-unidad y cluster-robust SE
- 4 Limitaciones del estimador FE
 - Lo que FE no resuelve
- 5 Camacho & Mejía (2017): aspersiones y salud en Colombia
 - Este paper
 - Contexto Colombiano
 - Datos y diseño
 - Resultados
- 6 Hands-on: Panel FE en R con datos simulados

Lo que FE *no* resuelve

1. Heterogeneidad no observada que **SÍ** varía en el tiempo.

$$Y_{it} = \alpha + \beta D_{it} + u_i + \underbrace{w_{it}}_{\text{no observado, varía en } t} + \varepsilon_{it}$$

- El within elimina u_i , pero *no* a w_{it} . Si $\text{Cov}(D_{it}, w_{it}) \neq 0$, el sesgo persiste.
- Ejemplo: cambios locales en acceso a salud que coinciden con cambios en aspersiones.

Lo que FE *no* resuelve

1. Heterogeneidad no observada que **SÍ** varía en el tiempo.

$$Y_{it} = \alpha + \beta D_{it} + u_i + \underbrace{w_{it}}_{\text{no observado, varía en } t} + \varepsilon_{it}$$

- El within elimina u_i , pero *no* a w_{it} . Si $\text{Cov}(D_{it}, w_{it}) \neq 0$, el sesgo persiste.
- Ejemplo: cambios locales en acceso a salud que coinciden con cambios en aspersiones.

2. Causalidad inversa (simultaneidad).

- Si Y_{it} *afecta* a D_{it} , $\hat{\beta}_{FE}$ sigue inconsistente; FE no rompe la retroalimentación (suele recurrirse a IV).
- Ejemplo clásico: gasto en policía $\rightarrow$ crimen, pero crimen $\rightarrow$ gasto en policía.

Lo que FE *no* resuelve

1. Heterogeneidad no observada que **SÍ** varía en el tiempo.

$$Y_{it} = \alpha + \beta D_{it} + u_i + \underbrace{w_{it}}_{\text{no observado, varía en } t} + \varepsilon_{it}$$

- El within elimina u_i , pero *no* a w_{it} . Si $\text{Cov}(D_{it}, w_{it}) \neq 0$, el sesgo persiste.
- Ejemplo: cambios locales en acceso a salud que coinciden con cambios en aspersiones.

2. Causalidad inversa (simultaneidad).

- Si Y_{it} *afecta* a D_{it} , $\hat{\beta}_{FE}$ sigue inconsistente; FE no rompe la retroalimentación (suele recurrirse a IV).
- Ejemplo clásico: gasto en policía $\rightarrow$ crimen, pero crimen $\rightarrow$ gasto en policía.

3. Dinámica: dependencia de estado.

- Si el modelo verdadero incluye $Y_{i,t-1}$, la transformación within deja la dependiente rezagada (ya centrada) correlacionada con el error $\Rightarrow$ *sesgo de Nickell*, de orden $1/T$ (grave en paneles cortos).
- Salida: GMM dinámico (Arellano & Bond, 1991), no FE estándar.

Lo que FE *no* resuelve

1. Heterogeneidad no observada que **SÍ** varía en el tiempo.

$$Y_{it} = \alpha + \beta D_{it} + u_i + \underbrace{w_{it}}_{\text{no observado, varía en } t} + \varepsilon_{it}$$

- El within elimina u_i , pero *no* a w_{it} . Si $\text{Cov}(D_{it}, w_{it}) \neq 0$, el sesgo persiste.
- Ejemplo: cambios locales en acceso a salud que coinciden con cambios en aspersiones.

2. Causalidad inversa (simultaneidad).

- Si Y_{it} *afecta* a D_{it} , $\hat{\beta}_{FE}$ sigue inconsistente; FE no rompe la retroalimentación (suele recurrirse a IV).
- Ejemplo clásico: gasto en policía $\rightarrow$ crimen, pero crimen $\rightarrow$ gasto en policía.

3. Dinámica: dependencia de estado.

- Si el modelo verdadero incluye $Y_{i,t-1}$, la transformación within deja la dependiente rezagada (ya centrada) correlacionada con el error $\Rightarrow$ *sesgo de Nickell*, de orden $1/T$ (grave en paneles cortos).
- Salida: GMM dinámico (Arellano & Bond, 1991), no FE estándar.

FE resuelve un tipo de endogeneidad: la de heterogeneidad fija no observada. No es una bala de plata.

Los costos del estimador FE

1. Error de medida en D se amplifica.

- Si D_{it} se mide con ruido, la transformación within *aumenta* la proporción “señal/ruido” destruida.
- Resultado: $\hat{\beta}_{FE}$ está más atenuado (sesgado hacia 0) que el correspondiente OLS.

Los costos del estimador FE

1. Error de medida en D se amplifica.

- Si D_{it} se mide con ruido, la transformación within *aumenta* la proporción “señal/ruido” destruida.
- Resultado: $\hat{\beta}_{FE}$ está más atenuado (sesgado hacia 0) que el correspondiente OLS.

2. Varianza alta cuando D varía poco within.

- Identificación viene solo de $\tilde{D}_{it} = D_{it} - \bar{D}_i$.
- Si la mayoría de la variación de D es entre unidades (*between*), $\hat{\beta}_{FE}$ tiene varianza grande.
- Caso extremo: si D_i es constante en t para cada i (e.g., el género), FE *no* identifica β .

Roadmap

- 1 Datos panel y heterogeneidad no observada
 - La idea fundamental
- 2 El estimador within: efectos fijos
 - Cómo eliminamos la heterogeneidad fija
 - Qué identifica y bajo qué supuestos
- 3 Inferencia: errores estándar clusterizados
 - Correlación intra-unidad y cluster-robust SE
- 4 Limitaciones del estimador FE
 - Lo que FE no resuelve
- 5 Camacho & Mejía (2017): aspersiones y salud en Colombia
 - Este paper
 - Contexto Colombiano
 - Datos y diseño
 - Resultados
- 6 Hands-on: Panel FE en R con datos simulados

Este paper

Retomamos el paper que presentamos al inicio de la clase —ahora con la maquinaria de FE en la mano— para entrar en su diseño con detalle.

Contribución metodológica:

- Primer paper en usar un cuasi-experimento para estimar el efecto causal del glifosato sobre salud en un país productor de coca.
- Combina un panel administrativo masivo (RIPS) con registros GPS de aspersiones.
- Usa FE individual para aislar heterogeneidad invariante (salud basal, genética, ubicación).

Resultado central (anticipo): la exposición al glifosato *aumenta* la probabilidad de consultas dermatológicas, respiratorias y abortos espontáneos, controlando por toda heterogeneidad fija.

Plan Colombia y las aspersiones aéreas

Plan Colombia (1999–). Estrategia conjunta Colombia–Estados Unidos contra la producción y tráfico de drogas.

- Inversión EE.UU.: ~US\$540 millones/año (2000–2008).
- Inversión Colombia: ~US\$812 millones/año.
- $\approx 1.2\%$ del PIB anual colombiano $\Rightarrow$ la intervención antidrogas más grande de la historia.

Aspersiones aéreas: la estrategia central.

- Avionetas operadas por contratistas estadounidenses (e.g., DynCorp).
- Roundup (glifosato + surfactante POEA) sobre cultivos detectados por satélite.
- Promedio: 128 mil ha/año asperjadas. Pico: 172 mil ha en 2006.
- Suspendido en 2015 tras la clasificación del glifosato como “probablemente cancerígeno” por la IARC/OMS.

La controversia:

- ONG y comunidades reportaban efectos adversos en salud.
- Evidencia previa: estudios de campo y de laboratorio, sin identificación causal limpia.
- Confundidor obvio: el cultivo de coca *en sí mismo* usa precursores químicos.

Datos: tres fuentes combinadas

1. RIPS (Registro Individual de Prestación de Servicios de Salud).

- Ministerio de Salud, 2003–2007.
- Toda consulta, urgencia, hospitalización y procedimiento en Colombia.
- ~45 millones de registros individuo–tiempo $\Rightarrow$ ~9.4 millones de personas únicas.
- Información: fecha, municipio, diagnóstico CIE-10, edad, sexo, aseguramiento.

2. Registros de aspersión (Policía Antinarcóticos).

- GPS a bordo de las avionetas $\Rightarrow$ ubicación y momento exactos.
- Datos *diarios* a nivel municipal.

3. Cultivo de coca (SIMCI, ONU).

- Imágenes satelitales anuales.
- Hectáreas de coca por municipio.

Controles municipales (CEDE, Uniandes): población, ingresos tributarios, ruralidad, gasto público en salud.

Especificación e identificación

$$y_{imt} = \alpha + \beta s_{mt} + \gamma' X_{mt} + \mu_i + \tau_{a(t)} + \lambda_{r(t)} + \varepsilon_{imt}$$

- y_{imt} : **1**{consulta dermatológica o respiratoria} (o medida de aborto) para individuo i residente en municipio m en periodo t .
- s_{mt} : km² asperjados en m durante la ventana de exposición relevante.
- X_{mt} : cultivo de coca y controles socioeconómicos municipales.
- μ_i : **FE individual** (absorbe salud basal, genética, sexo, ubicación inicial...).
- $\tau_{a(t)}$ y $\lambda_{r(t)}$: **FE de año y de mes** —dos conjuntos separados de dummies— que absorben tendencias anuales y estacionalidad.

El argumento de identificación (literal del paper):

“Comparamos la prevalencia de estas condiciones médicas para la misma persona bajo distintos niveles de exposición al herbicida usado en el programa de aspersión aérea durante un periodo de 5 años.”

Especificación e identificación

$$y_{imt} = \alpha + \beta s_{mt} + \gamma' X_{mt} + \mu_i + \tau_{a(t)} + \lambda_{r(t)} + \varepsilon_{imt}$$

- y_{imt} : **1**{consulta dermatológica o respiratoria} (o medida de aborto) para individuo i residente en municipio m en periodo t .
- s_{mt} : km² asperjados en m durante la ventana de exposición relevante.
- X_{mt} : cultivo de coca y controles socioeconómicos municipales.
- μ_i : **FE individual** (absorbe salud basal, genética, sexo, ubicación inicial...).
- $\tau_{a(t)}$ y $\lambda_{r(t)}$: **FE de año y de mes** —dos conjuntos separados de dummies— que absorben tendencias anuales y estacionalidad.

El argumento de identificación (literal del paper):

“Comparamos la prevalencia de estas condiciones médicas para la misma persona bajo distintos niveles de exposición al herbicida usado en el programa de aspersión aérea durante un periodo de 5 años.”

Detalle sutil: s_{mt} varía a nivel municipio–tiempo, no individuo. La variación intra-individuo viene de cambios temporales en el municipio de residencia (válido si el individuo no migra).

Resultados principales

Tres outcomes de salud de corto plazo:

1. Diagnósticos dermatológicos (ventana: 15 días post-exposición).

- $\hat{\beta} > 0$, significativo al 1%.
- Robusto al control por cultivo de coca y a la inclusión de FE individuales.

2. Diagnósticos respiratorios (ventana: 15 días).

- $\hat{\beta} > 0$, significativo al 1%.
- Magnitudes pequeñas pero precisamente estimadas (muestra masiva).

3. Abortos espontáneos (ventana: 9 meses, construido a partir de visitas prenatales sin parto registrado).

- $\hat{\beta} > 0$, significativo.
- Consistente con literatura médica previa.

Robustez y lectura honesta

Chequeos de robustez del paper:

- **Submuestra de no migrantes:** descarta que el efecto venga de movimiento residencial endógeno.
- **Submuestras por ingreso municipal:** verifican que el efecto no se concentra solo en municipios pobres.
- **Controles flexibles por área cultivada con coca:** aíslan el efecto del herbicida del efecto del cultivo *per se*.
- **Ventanas alternativas de exposición:** resultados estables al variar el horizonte temporal.

Robustez y lectura honesta

Chequeos de robustez del paper:

- **Submuestra de no migrantes:** descarta que el efecto venga de movimiento residencial endógeno.
- **Submuestras por ingreso municipal:** verifican que el efecto no se concentra solo en municipios pobres.
- **Controles flexibles por área cultivada con coca:** aíslan el efecto del herbicida del efecto del cultivo *per se*.
- **Ventanas alternativas de exposición:** resultados estables al variar el horizonte temporal.

Lectura honesta de los autores:

- No capturan efectos de **largo plazo** (datos solo cubren 2003–2007).
- Resultados válidos solo para población que **acude a servicios de salud** ⇒ selección de muestra.
- No identifican el mecanismo biológico exacto (toxicidad directa vs. POEA vs. estrés psicológico).

El FE individual es lo más cercano a un RCT en este contexto, pero no resuelve todos los problemas.

Roadmap

- 1 Datos panel y heterogeneidad no observada
 - La idea fundamental
- 2 El estimador within: efectos fijos
 - Cómo eliminamos la heterogeneidad fija
 - Qué identifica y bajo qué supuestos
- 3 Inferencia: errores estándar clusterizados
 - Correlación intra-unidad y cluster-robust SE
- 4 Limitaciones del estimador FE
 - Lo que FE no resuelve
- 5 Camacho & Mejía (2017): aspersiones y salud en Colombia
 - Este paper
 - Contexto Colombiano
 - Datos y diseño
 - Resultados
- 6 Hands-on: Panel FE en R con datos simulados

La simulación: un panel sintético tipo C&M

¿Por qué simular en lugar de replicar? Los datos RIPS son restringidos (Ministerio de Salud). La simulación permite *conocer* el parámetro verdadero β y verificar la mecánica del estimador.

Diseño del DGP (tratamiento a nivel municipio–tiempo, como en C&M):

- $N = 1,000$ individuos repartidos en $M = 50$ municipios, $T = 5$ periodos.
- Salud basal del municipio $a_m \sim \mathcal{N}(0, 1)$ (invariante); la del individuo la hereda:
 $u_i = a_{m(i)} + v_i$.
- Tratamiento *común dentro del municipio*: $s_{mt} = 0.5 a_m + \eta_{mt}$ ($\Rightarrow \text{Cov}(s, u) > 0$ vía a_m , fuente del sesgo del pooled).
- Control que varía en el tiempo $coca_{it}$, y error $AR(1)$ dentro del individuo $\Rightarrow$ vuelve inválidos los SE naive.
- Modelo verdadero: $y_{it} = 0 + \underbrace{2}_{\beta} \cdot s_{m(i),t} + 0.3 coca_{it} + u_i + \delta_t + \varepsilon_{it}$.

El tratamiento es común a todo el municipio $\Rightarrow$ el nivel de clustering es el *municipio*, no el individuo ($M = 50 \Rightarrow G = 50$, sobre la regla de 30–40).

Scripts: `generate_data_panel_fe.R` (genera el CSV) y `replication_panel_fe.R` (análisis). **Paquetes:** `fixest` y `tidyverse`.

Qué estimaremos hoy en R

Comparación de cuatro especificaciones (con $\beta_{\text{verdadero}} = 2$):

Modelo 1 — OLS pooled (sesgado).

- `feols(y ~ s + coca, data = df).`
- Esperado: $\hat{\beta} > 2$ (sesgo positivo por $\text{Cov}(s, u) > 0$).

Modelo 2 — FE de unidad.

- `feols(y ~ s + coca | id, data = df).`
- Esperado: $\hat{\beta} \approx 2$.

Modelo 3 — Two-way FE (especificación tipo C&M).

- `feols(y ~ s + coca | id + t, cluster = ~ mun).`
- Clusterizamos por **municipio** —el nivel de variación del tratamiento—, no por individuo.

Modelo 4 — Transformación within manual (verificación).

- Centrar $\tilde{y}_{it}$, $\tilde{s}_{it}$, $\widetilde{coca}_{it}$ en su media de unidad y correr `feols(... -1)`: $\hat{\beta}$ idéntico al Modelo 2 (los SE difieren por los grados de libertad).

Comparación de SE (sobre el Modelo 2): naive vs. HC1 vs. cluster por id vs. cluster por mun. Clusterizar por id casi no mueve el SE; por mun —donde el tratamiento es común— lo aumenta. Ese es el correcto.

Cierre y conexión con la próxima semana

Lo que vimos hoy:

- Datos panel = misma unidad observada en múltiples periodos.
- El *within estimator* elimina heterogeneidad invariante en el tiempo.
- TWFE absorbe simultáneamente u_i y δ_t .
- Inferencia: cluster-robust al nivel de variación del tratamiento.
- FE no resuelve confundidores variantes en el tiempo ni causalidad inversa.

Un detalle de C&M que abre la puerta a la próxima semana: su tratamiento s_{mt} es *continuo* y varía suavemente. ¿Y si el tratamiento fuera una *política* con fecha de inicio clara?

La próxima semana — Diferencias en Diferencias (DiD):

- Caso especial del TWFE con tratamiento binario y fecha de adopción.
- Supuesto identificador: *tendencias paralelas*.
- Visualmente más intuitivo: dos curvas, una salta en t^* , la otra no.

Card & Krueger (1994) — “Minimum Wages and Employment”.

Referencias

Paper de la semana

- Camacho, A. & Mejía, D. (2017). The Health Consequences of Aerial Spraying of Illicit Crops: The Case of Colombia. *Journal of Health Economics*, 54, 147–160. (Versión working paper en acceso abierto: CGD Working Paper 408, 2015.)

Lecturas del curso

- Cunningham, S. (2021). *Causal Inference: The Mixtape*, cap. 8.
- Angrist, J. D. & Pischke, J.-S. (2009). *Mostly Harmless Econometrics*, cap. 5.

Estimación panel y efectos fijos

- Wooldridge, J. M. (2010). *Econometric Analysis of Cross Section and Panel Data*, 2ª ed., cap. 10–11. MIT Press.
- Bergé, L. (2018). Efficient Estimation of Maximum Likelihood Models with Multiple Fixed-Effects: The R Package FENmlm. CREA Discussion Paper 2018-13.

Inferencia clusterizada

- Bertrand, M., Duflo, E. & Mullainathan, S. (2004). How Much Should We Trust Differences-in-Differences Estimates? *QJE*, 119(1), 249–275.
- Cameron, A. C. & Miller, D. L. (2015). A Practitioner's Guide to Cluster-Robust Inference. *Journal of Human Resources*, 50(2), 317–372.
- Abadie, A., Athey, S., Imbens, G. & Wooldridge, J. (2023). When Should You Adjust Standard Errors for Clustering? *QJE*, 138(1), 1–35.