

# Inferencia, Causalidad y Políticas Públicas

## ECO-60116

Week 06: Diferencias en Diferencias (DiD)

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

October 3, 2025

# Roadmap

1 Recap: Datos Panel

2 Diferencias En Diferencias

- Motivación
- Estimador de D&D
- Supuestos de D&D

3 Metodos de Estimación: D&D

4 Extensiones de D&D

# Estructura de Datos Panel

**Definición:** Un **panel de datos** contiene observaciones de múltiples unidades (individuos, regiones, empresas, etc.) a lo largo del tiempo.

## Notación:

- $i = 1, \dots, N$ : unidades (e.g., distritos)
- $t = 1, \dots, T$ : periodos de tiempo
- $y_{it}$ : variable dependiente
- $x_{it}$ : covariables (pueden ser variantes o invariantes en el tiempo)

## Tipos:

- **Balanceado:** todas las unidades observadas en todos los periodos
- **Desbalanceado:** faltan observaciones para algunas unidades o periodos

**Ejemplo:** Mortalidad por cólera en distritos de Londres para 1849 y 1854

# Modelo Lineal Básico en Datos Panel

## Modelo base:

$$y_{it} = \beta_0 + \beta_1 x_{it} + \epsilon_{it}$$

**Asunción clave:**  $\mathbb{E}[\epsilon_{it} \mid x_{it}] = 0$

**Problema típico:** Si hay variables omitidas correlacionadas con  $x_{it}$  y constantes en el tiempo para cada unidad  $\rightarrow$  sesgo de variable omitida.

## Soluciones posibles:

- Modelo de efectos fijos (captura heterogeneidad no observada constante en el tiempo)
- Modelo de efectos aleatorios (si la heterogeneidad es no correlacionada con los regresores)

**Motivación:** Necesitamos separar efectos de interés (e.g., política) de diferencias estructurales entre unidades.

# Modelo con Efectos Fijos

## Modelo con efectos fijos unitarios:

$$y_{it} = \alpha_i + \beta x_{it} + \epsilon_{it}$$

donde  $\alpha_i$  captura características inobservables constantes en el tiempo para cada unidad  $i$

### Interpretación:

- $\alpha_i$ : heterogeneidad inobservable (e.g., calidad del sistema de agua en un distrito)
- El modelo utiliza solo **variación dentro de la unidad** para identificar  $\beta$

### Estimación:

- **Transformación within:** resta del promedio temporal
- **Dummy variables:** una por cada unidad (menos una)

**Extensión:** Efectos fijos también pueden incluir el tiempo:

$$y_{it} = \alpha_i + \lambda_t + \beta x_{it} + \epsilon_{it}$$

donde  $\lambda_t$  capta shocks agregados comunes (e.g., epidemia o cambio institucional)

# Roadmap

- 1 Recap: Datos Panel
- 2 **Diferencias En Diferencias**
  - **Motivación**
  - Estimador de D&D
  - Supuestos de D&D
- 3 Metodos de Estimación: D&D
- 4 Extensiones de D&D

# Motivación

- A mediados del siglo XIX, Londres enfrentó múltiples epidemias de cólera. En ese momento, los médicos desconocían su origen y no sabían cómo detener su propagación.

# Motivación

- A mediados del siglo XIX, Londres enfrentó múltiples epidemias de cólera. En ese momento, los médicos desconocían su origen y no sabían cómo detener su propagación.
- La explicación dominante era la **teoría miasmática**, según la cual la enfermedad se transmitía a través de gases fétidos o tóxicos provenientes de materia en descomposición.



# Motivación

- A mediados del siglo XIX, Londres enfrentó múltiples epidemias de cólera. En ese momento, los médicos desconocían su origen y no sabían cómo detener su propagación.
- La explicación dominante era la **teoría miasmática**, según la cual la enfermedad se transmitía a través de gases fétidos o tóxicos provenientes de materia en descomposición.
- El médico y epidemiólogo **John Snow** (1813–1858) cuestionó esta teoría, argumentando que las medidas tomadas para evitar la exposición a los “miasmas” no habían sido efectivas.

# Motivación

- A mediados del siglo XIX, Londres enfrentó múltiples epidemias de cólera. En ese momento, los médicos desconocían su origen y no sabían cómo detener su propagación.
- La explicación dominante era la **teoría miasmática**, según la cual la enfermedad se transmitía a través de gases fétidos o tóxicos provenientes de materia en descomposición.
- El médico y epidemiólogo **John Snow** (1813–1858) cuestionó esta teoría, argumentando que las medidas tomadas para evitar la exposición a los “miasmas” no habían sido efectivas.
- Snow propuso una hipótesis alternativa: el cólera se transmitía a través del consumo de agua contaminada del sistema de acueducto.
  - ▶ Sostenía que las excreciones humanas contenían un agente infeccioso (aunque aún no identificado), el cual contaminaba las fuentes de agua potable.
  - ▶ El ciclo de consumo y reinfección a partir de esa agua explicaba la propagación sostenida de la epidemia.

# El experimento natural

- ¿Cómo probar empíricamente la hipótesis de transmisión por agua contaminada?

# El experimento natural

- ¿Cómo probar empíricamente la hipótesis de transmisión por agua contaminada?
- La **estrategia de identificación** de John Snow se basó en lo que hoy conocemos como un **experimento natural**.

# El experimento natural

- ¿Cómo probar empíricamente la hipótesis de transmisión por agua contaminada?
- La **estrategia de identificación** de John Snow se basó en lo que hoy conocemos como un **experimento natural**.
  - ▶ Un **experimento natural** ocurre cuando factores fuera del control del investigador –a diferencia de un experimento aleatorizado– generan **asignaciones al tratamiento** de forma potencialmente **exógena**.

# El experimento natural

- ¿Cómo probar empíricamente la hipótesis de transmisión por agua contaminada?
- La **estrategia de identificación** de John Snow se basó en lo que hoy conocemos como un **experimento natural**.
  - ▶ Un **experimento natural** ocurre cuando factores fuera del control del investigador –a diferencia de un experimento aleatorizado– generan **asignaciones al tratamiento** de forma potencialmente **exógena**.
- En la Londres de mediados del siglo XIX, el suministro de agua estaba a cargo de múltiples compañías privadas.

# El experimento natural

- ¿Cómo probar empíricamente la hipótesis de transmisión por agua contaminada?
- La **estrategia de identificación** de John Snow se basó en lo que hoy conocemos como un **experimento natural**.
  - ▶ Un **experimento natural** ocurre cuando factores fuera del control del investigador –a diferencia de un experimento aleatorizado– generan **asignaciones al tratamiento** de forma potencialmente **exógena**.
- En la Londres de mediados del siglo XIX, el suministro de agua estaba a cargo de múltiples compañías privadas.
- La mayoría de ellas obtenían el agua del río Támesis, altamente contaminado con aguas residuales.

# El experimento natural

- ¿Cómo probar empíricamente la hipótesis de transmisión por agua contaminada?
- La **estrategia de identificación** de John Snow se basó en lo que hoy conocemos como un **experimento natural**.
  - ▶ Un **experimento natural** ocurre cuando factores fuera del control del investigador –a diferencia de un experimento aleatorizado– generan **asignaciones al tratamiento** de forma potencialmente **exógena**.
- En la Londres de mediados del siglo XIX, el suministro de agua estaba a cargo de múltiples compañías privadas.
- La mayoría de ellas obtenían el agua del río Támesis, altamente contaminado con aguas residuales.
- Pero había una excepción clave...



## El experimento natural (cont.)

- En 1852, una de las compañías proveedoras de agua, *Lambeth Company*, trasladó su punto de captación río arriba del Támesis, a una zona más limpia, ubicada por encima del vertimiento de aguas residuales.

## El experimento natural (cont.)

- En 1852, una de las compañías proveedoras de agua, *Lambeth Company*, trasladó su punto de captación río arriba del Támesis, a una zona más limpia, ubicada por encima del vertimiento de aguas residuales.
- En contraste, otras compañías —particularmente la *Southwark and Vauxhall Company*— mantuvieron su punto de recolección río abajo, justo donde el río estaba contaminado con desechos humanos.

## El experimento natural (cont.)

- En 1852, una de las compañías proveedoras de agua, *Lambeth Company*, trasladó su punto de captación río arriba del Támesis, a una zona más limpia, ubicada por encima del vertimiento de aguas residuales.
- En contraste, otras compañías —particularmente la *Southwark and Vauxhall Company*— mantuvieron su punto de recolección río abajo, justo donde el río estaba contaminado con desechos humanos.
- La hipótesis de Snow era clara: si el cólera se transmitía por el agua, los hogares abastecidos por *Lambeth* deberían tener tasas de mortalidad por cólera más bajas que aquellos atendidos por *Southwark and Vauxhall*, bajo condiciones similares.

## El experimento natural (cont.)

- En 1852, una de las compañías proveedoras de agua, *Lambeth Company*, trasladó su punto de captación río arriba del Támesis, a una zona más limpia, ubicada por encima del vertimiento de aguas residuales.
- En contraste, otras compañías —particularmente la *Southwark and Vauxhall Company*— mantuvieron su punto de recolección río abajo, justo donde el río estaba contaminado con desechos humanos.
- La hipótesis de Snow era clara: si el cólera se transmitía por el agua, los hogares abastecidos por *Lambeth* deberían tener tasas de mortalidad por cólera más bajas que aquellos atendidos por *Southwark and Vauxhall*, bajo condiciones similares.
- Su estrategia: comparar tasas de mortalidad por cólera entre distritos abastecidos por cada compañía durante el brote de 1854.

## Evidencia: diferencias en tasas de mortalidad por cólera

Tasas de mortalidad por cólera (por 100.000 habitantes)		
Compañía de agua	Tasas 1849	Tasas 1854
Lambeth Company	847	193
Southwark & Vauxhall Company	1,349	1,466
Diferencia entre distritos		-1,273

*Fuente: Adaptado de John Snow (1854).*

- Los distritos que recibían el suministro de agua de Southwark and Vauxhall Company tuvieron una tasa de mortalidad 7.5 veces mayor relativo a los distritos que recibían el suministro de Lambeth company.
- En primera medida esto parece una evidencia contundente, pero no se puede descartar problemas de selección.

# Roadmap

1 Recap: Datos Panel

2 Diferencias En Diferencias

- Motivación
- Estimador de D&D
- Supuestos de D&D

3 Metodos de Estimación: D&D

4 Extensiones de D&D

## Resultados potenciales: caso John Snow

Supuesto de identificación de Snow en términos de resultados potenciales:

$$y_d = \begin{cases} y_d^1 & \text{tasa de mortalidad del distrito } d \text{ si recibe agua limpia} \\ y_d^0 & \text{tasa de mortalidad del distrito } d \text{ si recibe agua contaminada} \end{cases}$$

## Resultados potenciales: caso John Snow

Supuesto de identificación de Snow en términos de resultados potenciales:

$$y_d = \begin{cases} y_d^1 & \text{tasa de mortalidad del distrito } d \text{ si recibe agua limpia} \\ y_d^0 & \text{tasa de mortalidad del distrito } d \text{ si recibe agua contaminada} \end{cases}$$

### Asignación al tratamiento:

$D_d = 1$  si el proveedor de agua del distrito  $d$  es *Lambeth company* y

$D_d = 0$  si el proveedor es *Southwark and Vauxhall Company*.



## Resultados potenciales: caso John Snow

Supuesto de identificación de Snow en términos de resultados potenciales:

$$y_d = \begin{cases} y_d^1 & \text{tasa de mortalidad del distrito } d \text{ si recibe agua limpia} \\ y_d^0 & \text{tasa de mortalidad del distrito } d \text{ si recibe agua contaminada} \end{cases}$$

### Asignación al tratamiento:

$D_d = 1$  si el proveedor de agua del distrito  $d$  es *Lambeth company* y

$D_d = 0$  si el proveedor es *Southwark and Vauxhall Company*.

### El efecto causal de interés:

$$\tau = y_d^1 - y_d^0$$

# Resultados potenciales: caso John Snow

Supuesto de identificación de Snow en términos de resultados potenciales:

$$y_d = \begin{cases} y_d^1 & \text{tasa de mortalidad del distrito } d \text{ si recibe agua limpia} \\ y_d^0 & \text{tasa de mortalidad del distrito } d \text{ si recibe agua contaminada} \end{cases}$$

## Asignación al tratamiento:

$D_d = 1$  si el proveedor de agua del distrito  $d$  es *Lambeth company* y

$D_d = 0$  si el proveedor es *Southwark and Vauxhall Company*.

## El efecto causal de interés:

$$\tau = y_d^1 - y_d^0$$

**Problema fundamental de la inferencia causal:** para cada distrito  $d$  sólo observamos uno de los dos estados:

$$y_d = D_d \cdot y_d^1 + (1 - D_d) \cdot y_d^0$$

# Resultados potenciales: caso John Snow

## Estimador Ingenuo de Snow:

$$\tau_{\text{Snow}} = \mathbb{E}[y_d | D_d = 1] - \mathbb{E}[y_d | D_d = 0]$$

# Resultados potenciales: caso John Snow

## Estimador Ingenuo de Snow:

$$\tau_{\text{Snow}} = \mathbb{E}[y_d | D_d = 1] - \mathbb{E}[y_d | D_d = 0]$$

Pero sabemos que esto es igual a:

$$\begin{aligned} \mathbb{E}[y_d | D_d = 1] - \mathbb{E}[y_d | D_d = 0] &= \underbrace{\mathbb{E}[y_d^1 | D_d = 1] - \mathbb{E}[y_d^0 | D_d = 1]}_{\tau} \\ &+ \underbrace{\mathbb{E}[y_d^0 | D_d = 1] - \mathbb{E}[y_d^0 | D_d = 0]}_{\text{Sesgo de selección}} \end{aligned}$$

# Resultados potenciales: caso John Snow

## Estimador Ingenuo de Snow:

$$\tau_{\text{Snow}} = \mathbb{E}[y_d | D_d = 1] - \mathbb{E}[y_d | D_d = 0]$$

Pero sabemos que esto es igual a:

$$\begin{aligned} \mathbb{E}[y_d | D_d = 1] - \mathbb{E}[y_d | D_d = 0] &= \underbrace{\mathbb{E}[y_d^1 | D_d = 1] - \mathbb{E}[y_d^0 | D_d = 1]}_{\tau} \\ &\quad + \underbrace{\mathbb{E}[y_d^0 | D_d = 1] - \mathbb{E}[y_d^0 | D_d = 0]}_{\text{Sesgo de selección}} \end{aligned}$$

**Interpretación:**  $\tau_{\text{Snow}} = \tau$  únicamente si no hay diferencias sistemáticas entre los distritos que son abastecidos por cada una de las compañías.

$$\mathbb{E}[y_d^0 | D_d = 1] = \mathbb{E}[y_d^0 | D_d = 0]$$

# Intuición de diferencias en diferencias

- **No** podemos asumir que los distritos tratados y no tratados eran comparables en 1854.

# Intuición de diferencias en diferencias

- **No** podemos asumir que los distritos tratados y no tratados eran comparables en 1854.
- Pero podemos usar información previa al tratamiento (por ejemplo, año 1849, antes del cambio de fuente de agua en 1852) para controlar por diferencias estructurales entre grupos.

# Intuición de diferencias en diferencias

- **No** podemos asumir que los distritos tratados y no tratados eran comparables en 1854.
- Pero podemos usar información previa al tratamiento (por ejemplo, año 1849, antes del cambio de fuente de agua en 1852) para controlar por diferencias estructurales entre grupos.
- “*Ser tratado*” significa que el distrito pasó a recibir agua limpia a partir de 1852 (*Lambeth Company*). “*Control*” significa que el distrito continuó recibiendo agua contaminada (*Southwark & Vauxhall Company*).
- **Supuesto clave de identificación:** en ausencia de tratamiento, la evolución de las tasas de mortalidad habría sido la misma para ambos grupos:

$$\mathbb{E}[y_d^0(1854) - y_d^0(1849) \mid D_d = 1] = \mathbb{E}[y_d^0(1854) - y_d^0(1849) \mid D_d = 0]$$

- *Este supuesto se conoce como el supuesto de **tendencias paralelas**.*



# Intuición de diferencias en diferencias

- **No** podemos asumir que los distritos tratados y no tratados eran comparables en 1854.
- Pero podemos usar información previa al tratamiento (por ejemplo, año 1849, antes del cambio de fuente de agua en 1852) para controlar por diferencias estructurales entre grupos.
- “*Ser tratado*” significa que el distrito pasó a recibir agua limpia a partir de 1852 (*Lambeth Company*). “*Control*” significa que el distrito continuó recibiendo agua contaminada (*Southwark & Vauxhall Company*).
- **Supuesto clave de identificación:** en ausencia de tratamiento, la evolución de las tasas de mortalidad habría sido la misma para ambos grupos:
$$\mathbb{E}[y_d^0(1854) - y_d^0(1849) \mid D_d = 1] = \mathbb{E}[y_d^0(1854) - y_d^0(1849) \mid D_d = 0]$$
- *Este supuesto se conoce como el supuesto de **tendencias paralelas**.*
- **Implicación:** podemos comparar la evolución en el tiempo del grupo tratado (agua limpia desde 1852) con la del grupo control (agua contaminada) para identificar  $\tau$ .

# Estimador de diferencias en diferencias (D&D)

**Observaciones:** disponemos de tasas de mortalidad en dos momentos del tiempo (1849 y 1854), para dos grupos de distritos:

- $D_d = 1$ : distritos abastecidos por *Lambeth Company* (agua limpia en 1854)
- $D_d = 0$ : distritos abastecidos por *Southwark & Vauxhall Company* (agua contaminada en ambos años)

**Estimador de DiD:**

$$\tau_{\text{DiD}} = \underbrace{\mathbb{E}[y_d \mid D_d = 1, t = 1854] - \mathbb{E}[y_d \mid D_d = 1, t = 1849]}_{\text{Cambio en el grupo tratado}} - \underbrace{(\mathbb{E}[y_d \mid D_d = 0, t = 1854] - \mathbb{E}[y_d \mid D_d = 0, t = 1849])}_{\text{Cambio en el grupo control}}$$

**Bajo el supuesto de tendencias paralelas:**

$$\tau_{\text{DiD}} = \mathbb{E}[y_d^1(1854) - y_d^0(1854) \mid D_d = 1] = \tau$$

# Estimador de D&D para tasas de mortalidad por cólera

## Tasas de mortalidad por cólera (por 100.000 habitantes)

Compañía de agua	Tasas 1849	Tasas 1854	Cambio (1854-1849)
Lambeth Company	847	193	-653
Southwark & Vauxhall Company	1,349	1,466	118
Diferencia en Diferencias			-771

Fuente: Adaptado de *John Snow (1854)*.

## Estimador de diferencias en diferencias:

$$\begin{aligned}\tau_{DiD} &= (193 - 847) - (1466 - 1349) \\ &= -653 - 118 = \boxed{-771}\end{aligned}$$

*Interpretación:* el acceso a agua limpia está asociado con una reducción de 771 muertes por cólera por cada 100.000 habitantes.

# Roadmap

1 Recap: Datos Panel

2 Diferencias En Diferencias

- Motivación
- Estimador de D&D
- Supuestos de D&D

3 Metodos de Estimación: D&D

4 Extensiones de D&D

# Supuesto de tendencias paralelas

- Implica que, en ausencia del tratamiento, la evolución de la variable de interés habría sido la misma en ambos grupos.
- Puede **validarse parcialmente** si contamos con datos para varios **periodos pre-tratamiento**.
- Supongamos que los resultados potenciales en ausencia de tratamiento se pueden escribir como:

$$\mathbb{E}[y_{d,st}^0 \mid s, t] = \phi_t + \eta_s$$


donde:

- ▶  $\phi_t$ : efecto común a todos los grupos en el tiempo (cambio agregado)
- ▶  $\eta_s$ : diferencias fijas entre unidades (estados, distritos, etc.)
- Entonces, para cualquier periodo  $t$  pre-tratamiento:


$$\mathbb{E}[y_{ist}^0 \mid s = L] - \mathbb{E}[y_{ist}^0 \mid s = SV] = (\phi_t + \eta_L) - (\phi_t + \eta_{SV}) = \eta_L - \eta_{SV}$$

- **Conclusión:** la diferencia entre los grupos es constante en el tiempo antes del tratamiento. Eso es lo que se denomina **tendencias paralelas**.

## Representación gráfica: Grupo tratado (Lambeth)




## Representación gráfica: Grupo tratado vs. control



El valor esperado de la tasa de mortalidad en el periodo pre no es igual en los dos grupos.

## Representación gráfica: Contrafactual



En ausencia del tratamiento, el cambio esperado en la variable dependiente del grupo de tratamiento es igual al cambio observado en esa variable para el grupo de control.



# Roadmap

- 1 Recap: Datos Panel
- 2 Diferencias En Diferencias
  - Motivación
  - Estimador de D&D
  - Supuestos de D&D
- 3 Metodos de Estimación: D&D
- 4 Extensiones de D&D

# Modelo de regresión lineal

$$y_{dt} = \beta_0 + \beta_1 \text{Post}_t + \beta_2 D_d + \beta_3 (D_d \times \text{Post}_t) + \epsilon_{dt}$$

- $y_{dt}$ : Tasa de mortalidad por cólera en el distrito  $d$  y periodo  $t$ .
- $d$ : Distritos de Londres (e.g., Lambeth o Southwark & Vauxhall).
- $t$ : Puede tomar dos valores: 1849 y 1854.
- $\text{Post}_t$ : Indicador temporal. Toma valor 1 si el año es posterior al tratamiento (1854), y 0 si es antes (1849).
- $D_d$ : Indicador de tratamiento. Toma valor 1 si el distrito es tratado (Lambeth), y 0 si es control (Southwark & Vauxhall).
- $D_d \times \text{Post}_t$ : Término de interacción que captura el efecto diferencial del tratamiento en el tiempo, es decir, la estimación DiD.

# Modelo de regresión lineal

$$y_{dt} = \beta_0 + \beta_1 \text{Post}_t + \beta_2 D_d + \beta_3 (D_d \times \text{Post}_t) + \epsilon_{dt}$$

## Valores esperados del modelo:

- 1  $\mathbb{E}[y_{dt} | \text{Post} = 1, D_d = 1] = \beta_0 + \beta_1 + \beta_2 + \beta_3$
- 2  $\mathbb{E}[y_{dt} | \text{Post} = 0, D_d = 1] = \beta_0 + \beta_2$
- 3  $\mathbb{E}[y_{dt} | \text{Post} = 1, D_d = 0] = \beta_0 + \beta_1$
- 4  $\mathbb{E}[y_{dt} | \text{Post} = 0, D_d = 0] = \beta_0$

# Modelo de regresión lineal

$$y_{dt} = \beta_0 + \beta_1 \text{Post}_t + \beta_2 D_d + \beta_3 (D_d \times \text{Post}_t) + \epsilon_{dt}$$

## Valores esperados del modelo:

- 1  $\mathbb{E}[y_{dt} | \text{Post} = 1, D_d = 1] = \beta_0 + \beta_1 + \beta_2 + \beta_3$
- 2  $\mathbb{E}[y_{dt} | \text{Post} = 0, D_d = 1] = \beta_0 + \beta_2$
- 3  $\mathbb{E}[y_{dt} | \text{Post} = 1, D_d = 0] = \beta_0 + \beta_1$
- 4  $\mathbb{E}[y_{dt} | \text{Post} = 0, D_d = 0] = \beta_0$

## Diferencias en el tiempo para cada grupo ( $\Delta_t \mathbb{E}[Y_{dt} | D_d]$ ):

- a.  $(1) - (2) = \beta_1 + \beta_3$
- b.  $(3) - (4) = \beta_1$

# Modelo de regresión lineal

$$y_{dt} = \beta_0 + \beta_1 \text{Post}_t + \beta_2 D_d + \beta_3 (D_d \times \text{Post}_t) + \epsilon_{dt}$$

## Valores esperados del modelo:

- 1  $\mathbb{E}[y_{dt} | \text{Post} = 1, D_d = 1] = \beta_0 + \beta_1 + \beta_2 + \beta_3$
- 2  $\mathbb{E}[y_{dt} | \text{Post} = 0, D_d = 1] = \beta_0 + \beta_2$
- 3  $\mathbb{E}[y_{dt} | \text{Post} = 1, D_d = 0] = \beta_0 + \beta_1$
- 4  $\mathbb{E}[y_{dt} | \text{Post} = 0, D_d = 0] = \beta_0$

## Diferencias en el tiempo para cada grupo ( $\Delta_t \mathbb{E}[Y_{dt} | D_d]$ ):

- a.  $(1) - (2) = \beta_1 + \beta_3$
- b.  $(3) - (4) = \beta_1$

## Estimador de D&D ( $\Delta_t \mathbb{E}[Y_{dt} | D_d = 1] - \Delta_t \mathbb{E}[Y_{dt} | D_d = 0]$ ):

- $\tau_{\text{DiD}} \equiv (a) - (b) = \beta_3$

# Algunas ventajas del modelo de regresión

- ❶ Podemos agregar controles si son necesarios.
  - ▶ Controles que hacen que el supuesto de **tendencias paralelas** sea más plausible.
  - ▶ Reducen la varianza residual  $\implies$  mejora la precisión del estimador.
  - ▶ Evitar usar variables de control que puedan estar afectadas por el tratamiento.
- ❷ Permite calcular errores estándar directamente.
- ❸ Se puede generalizar a más de dos periodos. Esto a su vez permite testear **parcialmente** el supuesto de tendencias paralelas (próxima clase).
- ❹ Se puede generalizar a tratamientos que no son dicotómicos. Por ejemplo, diferentes intensidades del tratamiento.

# Modelo TWFE (Two-Way Fixed Effects)

## Extensión del modelo DiD con múltiples unidades y periodos:

$$y_{it} = \alpha_i + \lambda_t + \tau \cdot D_{it} + \varepsilon_{it} \quad (1)$$

- $y_{it}$ : resultado de interés para la unidad  $i$  en el periodo  $t$
- $\alpha_i$ : efectos fijos por unidad (capturan diferencias constantes entre unidades)
- $\lambda_t$ : efectos fijos por periodo (capturan shocks comunes en el tiempo)
- $D_{it}$ : indicador de tratamiento (1 si la unidad  $i$  está tratada en  $t$ , 0 si no)
- $\tau$ : estimador del efecto promedio del tratamiento
- $\varepsilon_{it}$ : término de error idiosincrático

**Supuesto clave:** **Tendencias paralelas entre unidades tratadas y no tratadas** antes del tratamiento.

**Estimación:** por Mínimos Cuadrados Ordinarios (OLS) con efectos fijos de unidad y de tiempo.

# Roadmap

- 1 Recap: Datos Panel
- 2 Diferencias En Diferencias
  - Motivación
  - Estimador de D&D
  - Supuestos de D&D
- 3 Metodos de Estimación: D&D
- 4 Extensiones de D&D



# D&D con variación en el momento del tratamiento

En muchos casos el tratamiento no ocurre al mismo tiempo para todas las unidades:

- Departamentos que implementan una reforma laboral en distintos años.
- Distritos escolares que adoptan tecnología en diferentes momentos.
- Ciudades que reciben infraestructura o inversión de manera gradual.

El modelo TWFE tradicional combina comparaciones entre unidades tratadas en distintos momentos. Esto puede llevar a estimaciones sesgadas si tratamiento es:

- **Heterogéneos en el tiempo:** el efecto cambia según cuánto tiempo ha pasado desde la intervención.
- **Heterogéneos entre unidades:** algunas unidades responden más que otras.

**Solución:** Usar estimadores que separan los efectos por cohorte de tratamiento y tiempo (e.g. Callaway & Sant'Anna, 2021; Sun & Abraham, 2021). Ver [Callaway & Sant'Anna, 2021](#)

# D&D con múltiples períodos de tiempo

En estudios empíricos aplicados, a menudo se dispone de datos panel con varios periodos antes y después del tratamiento.

## **Ventajas:**

- Permite validar el supuesto de tendencias paralelas observando la evolución pre-tratamiento.
- Facilita la estimación de efectos dinámicos del tratamiento (e.g., efectos acumulados, persistentes o retardados).
- Mejora la eficiencia al aprovechar más información temporal.

## **Ejemplos:**

- Evaluar el impacto de una política fiscal usando datos de ingresos municipales entre 2000 y 2020.
- Estimar efectos de una reforma educativa implementada en 2012 observando puntajes escolares desde 2005.

**Precaución:** Si el tratamiento varía en el tiempo entre unidades, se deben considerar los sesgos del estimador TWFE. En ese caso, usar métodos alternativos (e.g., Callaway-Sant'Anna, event studies). Ver [Callaway-Sant'Anna](#).

# TWFE con varios tratamientos

En algunos estudios, las unidades pueden recibir más de un tratamiento a lo largo del tiempo, o diferentes tipos de tratamiento:

- Una ciudad implementa primero un toque de queda y luego una política de cierre de escuelas.
- Un país adopta diferentes componentes de una reforma tributaria en distintos años.

**Problema:** El estimador TWFE tradicional puede:

- Promediar **efectos de tratamientos diferentes** de forma no interpretable.
- Generar **comparaciones inválidas** entre grupos ya tratados vs. recién tratados.

**Alternativas:**

- Modelos de efectos heterogéneos por tipo y momento del tratamiento.
- Métodos como Callaway-Sant'Anna (2021) o Gardner (2022) que permiten descomposición adecuada. [Ver](#)