

Inferencia, Causalidad y Políticas Públicas

ECO-60116

Week 08: Event Study

Eduard F. Martinez Gonzalez, Ph.D.

Departamento de Economía, Universidad Icesi

May 22, 2026

Roadmap

1 De DiD a Event Study

- El hilo conductor: Jacobson, LaLonde y Sullivan (1993)
- La especificación event-study

2 Pre-tendencias como prueba del supuesto de paralelas

- Intuición y uso
- Límites del test de pre-tendencias

3 Tratamientos escalonados y el problema TWFE

- La descomposición de Goodman-Bacon (2021)

4 Estimadores robustos modernos

- Sun y Abraham (2021)
- Callaway y Sant'Anna (2021)

5 Hands-on: Event Study en R

RECAP: Diferencias en Diferencias

El estimador DiD canónico (2 grupos, 2 períodos):

$$\hat{\beta}^{DiD} = \underbrace{(\bar{Y}_{T,post} - \bar{Y}_{T,pre})}_{\text{cambio en tratados}} - \underbrace{(\bar{Y}_{C,post} - \bar{Y}_{C,pre})}_{\text{cambio en controles}}$$

RECAP: Diferencias en Diferencias

El estimador DiD canónico (2 grupos, 2 períodos):

$$\hat{\beta}^{DiD} = \underbrace{(\bar{Y}_{T,post} - \bar{Y}_{T,pre})}_{\text{cambio en tratados}} - \underbrace{(\bar{Y}_{C,post} - \bar{Y}_{C,pre})}_{\text{cambio en controles}}$$

Bajo el supuesto de **tendencias paralelas**:

$$\mathbb{E}[Y_{T,post}(0) - Y_{T,pre}(0)] = \mathbb{E}[Y_{C,post}(0) - Y_{C,pre}(0)]$$

RECAP: Diferencias en Diferencias

El estimador DiD canónico (2 grupos, 2 períodos):

$$\hat{\beta}^{DiD} = \underbrace{(\bar{Y}_{T,post} - \bar{Y}_{T,pre})}_{\text{cambio en tratados}} - \underbrace{(\bar{Y}_{C,post} - \bar{Y}_{C,pre})}_{\text{cambio en controles}}$$

Bajo el supuesto de **tendencias paralelas**:

$$\mathbb{E}[Y_{T,post}(0) - Y_{T,pre}(0)] = \mathbb{E}[Y_{C,post}(0) - Y_{C,pre}(0)]$$

Dos limitaciones del DiD 2×2:

- **Estático:** estima un único efecto promedio — ¿el efecto crece, decae o es inmediato?
- **Simultáneo:** supone que todas las unidades se tratan al mismo tiempo. En la práctica, el tratamiento suele llegar en momentos distintos (*staggered adoption*).

RECAP: Diferencias en Diferencias

El estimador DiD canónico (2 grupos, 2 períodos):

$$\hat{\beta}^{DiD} = \underbrace{(\bar{Y}_{T,post} - \bar{Y}_{T,pre})}_{\text{cambio en tratados}} - \underbrace{(\bar{Y}_{C,post} - \bar{Y}_{C,pre})}_{\text{cambio en controles}}$$

Bajo el supuesto de **tendencias paralelas**:

$$\mathbb{E}[Y_{T,post}(0) - Y_{T,pre}(0)] = \mathbb{E}[Y_{C,post}(0) - Y_{C,pre}(0)]$$

Dos limitaciones del DiD 2×2:

- **Estático:** estima un único efecto promedio — ¿el efecto crece, decae o es inmediato?
- **Simultáneo:** supone que todas las unidades se tratan al mismo tiempo. En la práctica, el tratamiento suele llegar en momentos distintos (*staggered adoption*).

La pregunta de hoy

¿Cómo extender DiD para recuperar la **dinámica del efecto** y qué ocurre con el TWFE cuando el tratamiento es escalonado?

Roadmap

1 De DiD a Event Study

- El hilo conductor: Jacobson, LaLonde y Sullivan (1993)
- La especificación event-study

2 Pre-tendencias como prueba del supuesto de paralelas

- Intuición y uso
- Límites del test de pre-tendencias

3 Tratamientos escalonados y el problema TWFE

- La descomposición de Goodman-Bacon (2021)

4 Estimadores robustos modernos

- Sun y Abraham (2021)
- Callaway y Sant'Anna (2021)

5 Hands-on: Event Study en R

El hilo conductor de esta semana

Para anclar cada concepto en un caso real, usaremos como hilo conductor:

Jacobson, LaLonde y Sullivan (1993)

"Earnings Losses of Displaced Workers"
American Economic Review, 83(4): 685–709.

La pregunta: ¿cuánto pierden en ingresos los trabajadores desplazados por el cierre o contracción severa de su empresa? ¿Y cuándo empieza ese proceso?

El hilo conductor de esta semana

Para anclar cada concepto en un caso real, usaremos como hilo conductor:

Jacobson, LaLonde y Sullivan (1993)

"Earnings Losses of Displaced Workers"
American Economic Review, 83(4): 685–709.

La pregunta: ¿cuánto pierden en ingresos los trabajadores desplazados por el cierre o contracción severa de su empresa? ¿Y cuándo empieza ese proceso?

Contexto: Pennsylvania, décadas de 1970 y 1980. Cierre masivo de plantas en acero, vidrio y manufactura.

El hilo conductor de esta semana

Para anclar cada concepto en un caso real, usaremos como hilo conductor:

Jacobson, LaLonde y Sullivan (1993)

"Earnings Losses of Displaced Workers"
American Economic Review, 83(4): 685–709.

La pregunta: ¿cuánto pierden en ingresos los trabajadores desplazados por el cierre o contracción severa de su empresa? ¿Y cuándo empieza ese proceso?

Contexto: Pennsylvania, décadas de 1970 y 1980. Cierre masivo de plantas en acero, vidrio y manufactura.

El problema de identificación: comparar desplazados con no-desplazados es inválido — las empresas que cierran son peores que el promedio (sesgo por variable omitida).

El hilo conductor de esta semana

Para anclar cada concepto en un caso real, usaremos como hilo conductor:

Jacobson, LaLonde y Sullivan (1993)

"Earnings Losses of Displaced Workers"
American Economic Review, 83(4): 685–709.

La pregunta: ¿cuánto pierden en ingresos los trabajadores desplazados por el cierre o contracción severa de su empresa? ¿Y cuándo empieza ese proceso?

Contexto: Pennsylvania, décadas de 1970 y 1980. Cierre masivo de plantas en acero, vidrio y manufactura.

El problema de identificación: comparar desplazados con no-desplazados es inválido — las empresas que cierran son peores que el promedio (sesgo por variable omitida).

- D_{it} : = 1 si el trabajador i fue desplazado (y $t \geq g_i$, su año de desplazamiento).
- Y_{it} : ingresos anuales (log) del trabajador i en el año t .
- **Estrategia:** comparar al *mismo* trabajador antes y después del desplazamiento, controlando por tendencias agregadas mediante efectos fijos.

Roadmap

1 De DiD a Event Study

- El hilo conductor: Jacobson, LaLonde y Sullivan (1993)
- La especificación event-study

2 Pre-tendencias como prueba del supuesto de paralelas

- Intuición y uso
- Límites del test de pre-tendencias

3 Tratamientos escalonados y el problema TWFE

- La descomposición de Goodman-Bacon (2021)

4 Estimadores robustos modernos

- Sun y Abraham (2021)
- Callaway y Sant'Anna (2021)

5 Hands-on: Event Study en R

De la dummy única a la ventana de eventos

El DiD con datos panel estima un único β :

$$Y_{it} = \alpha_i + \lambda_t + \beta D_{it} + \varepsilon_{it}$$

Esto impone que el efecto es **constante** en todos los períodos post-tratamiento.

De la dummy única a la ventana de eventos

El DiD con datos panel estima un único β :

$$Y_{it} = \alpha_i + \lambda_t + \beta D_{it} + \varepsilon_{it}$$

Esto impone que el efecto es **constante** en todos los períodos post-tratamiento.

La extensión natural: reemplazar la dummy de tratamiento por dummies relativas al evento:

$$D_{it}^k = \mathbf{1}\{t - T_i^* = k\}, \quad k \in \{-K, \dots, -2, -1, 0, 1, \dots, M\}$$

donde T_i^* es el período de tratamiento de la unidad i y k es la distancia relativa al evento.

De la dummy única a la ventana de eventos

El DiD con datos panel estima un único β :

$$Y_{it} = \alpha_i + \lambda_t + \beta D_{it} + \varepsilon_{it}$$

Esto impone que el efecto es **constante** en todos los períodos post-tratamiento.

La extensión natural: reemplazar la dummy de tratamiento por dummies relativas al evento:

$$D_{it}^k = \mathbf{1}\{t - T_i^* = k\}, \quad k \in \{-K, \dots, -2, -1, 0, 1, \dots, M\}$$

donde T_i^* es el período de tratamiento de la unidad i y k es la distancia relativa al evento.

La regresión event-study:

$$Y_{it} = \alpha_i + \lambda_t + \sum_{\substack{k=-K \\ k \neq -1}}^M \beta_k D_{it}^k + \varepsilon_{it}$$

- α_i : efecto fijo de unidad (absorbe niveles permanentes).
- λ_t : efecto fijo de período (absorbe tendencias comunes).
- $k < 0$: coeficientes **pre-tratamiento** (*leads*).
- $k \geq 0$: coeficientes **post-tratamiento** (*lags*).

La categoría de referencia: por qué $k = -1$

Para identificar el modelo se omite una categoría. La convención estándar es $k = -1$ (el período inmediatamente anterior al evento).

La categoría de referencia: por qué $k = -1$

Para identificar el modelo se omite una categoría. La convención estándar es $k = -1$ (el período inmediatamente anterior al evento).

¿Por qué $k = -1$ y no $k = 0$?

- Los coeficientes $\hat{\beta}_k$ se interpretan como el efecto *relativo* al período $k = -1$.
- $k = -1$ es el “último período normal” antes del evento: la unidad tratada aún no ha recibido el tratamiento, y no debería haber anticipación.
- Normalizar en $k = -1$ hace que la gráfica sea intuitiva: lo que cae por debajo de cero es una pérdida relativa a ese período basal.

La categoría de referencia: por qué $k = -1$

Para identificar el modelo se omite una categoría. La convención estándar es $k = -1$ (el período inmediatamente anterior al evento).


¿Por qué $k = -1$ y no $k = 0$?

- Los coeficientes $\hat{\beta}_k$ se interpretan como el efecto *relativo* al período $k = -1$.
- $k = -1$ es el “último período normal” antes del evento: la unidad tratada aún no ha recibido el tratamiento, y no debería haber anticipación.
- Normalizar en $k = -1$ hace que la gráfica sea intuitiva: lo que cae por debajo de cero es una pérdida relativa a ese período basal.

¿Qué miden los coeficientes?

- $\hat{\beta}_{-3} \neq 0$: el resultado ya difería *3 períodos antes* del evento — señal de tendencias no paralelas o anticipación.
- $\hat{\beta}_0$: efecto del tratamiento en el período del evento.
- $\hat{\beta}_3$: efecto **3 períodos después** — captura la dinámica.

Lectura de la gráfica event-study



Zona pre-tratamiento ($k < -1$):

- Coeficientes deben ser estadísticamente cercanos a cero.
- Evidencia de que tratados y controles tenían trayectorias similares antes del evento.
- Prueba visual del supuesto de tendencias paralelas.

Zona post-tratamiento ($k \geq 0$):

- Revela la *dinámica* del efecto causal.
- ¿Es inmediato? ¿Crece? ¿Se desvanece?

Roadmap

1 De DiD a Event Study

- El hilo conductor: Jacobson, LaLonde y Sullivan (1993)
- La especificación event-study

2 Pre-tendencias como prueba del supuesto de paralelas

- Intuición y uso
- Límites del test de pre-tendencias

3 Tratamientos escalonados y el problema TWFE

- La descomposición de Goodman-Bacon (2021)

4 Estimadores robustos modernos

- Sun y Abraham (2021)
- Callaway y Sant'Anna (2021)

5 Hands-on: Event Study en R

El test de pre-tendencias: intuición

La lógica: si el supuesto de tendencias paralelas se cumpliera en ausencia de tratamiento, los tratados y controles habrían seguido trayectorias similares antes del evento.

El test de pre-tendencias: intuición

La lógica: si el supuesto de tendencias paralelas se cumpliera en ausencia de tratamiento, los tratados y controles habrían seguido trayectorias similares antes del evento.

Formalmente, bajo tendencias paralelas:

$$\mathbb{E}[Y_{it}(0) - Y_{it'}(0) \mid i \in \text{tratados}] = \mathbb{E}[Y_{it}(0) - Y_{it'}(0) \mid i \in \text{controles}]$$

para cualquier par de períodos t, t' **previos** al tratamiento.

El test de pre-tendencias: intuición

La lógica: si el supuesto de tendencias paralelas se cumpliera en ausencia de tratamiento, los tratados y controles habrían seguido trayectorias similares antes del evento.

Formalmente, bajo tendencias paralelas:

$$\mathbb{E}[Y_{it}(0) - Y_{it'}(0) \mid i \in \text{tratados}] = \mathbb{E}[Y_{it}(0) - Y_{it'}(0) \mid i \in \text{controles}]$$

para cualquier par de períodos t, t' **previos** al tratamiento.

La implicación testeable: en los períodos $k < -1$, los coeficientes $\hat{\beta}_k$ deben ser estadísticamente indistinguibles de cero.

- $\hat{\beta}_k \approx 0$ para todo $k < -1 \Rightarrow$ no se rechaza tendencias paralelas (evidencia *consistente* con el supuesto).
- $\hat{\beta}_k \neq 0$ para algún $k < -1 \Rightarrow$ violación aparente de tendencias paralelas o anticipación del tratamiento.

El test de pre-tendencias: intuición

La lógica: si el supuesto de tendencias paralelas se cumpliera en ausencia de tratamiento, los tratados y controles habrían seguido trayectorias similares antes del evento.

Formalmente, bajo tendencias paralelas:

$$\mathbb{E}[Y_{it}(0) - Y_{it'}(0) \mid i \in \text{tratados}] = \mathbb{E}[Y_{it}(0) - Y_{it'}(0) \mid i \in \text{controles}]$$

para cualquier par de períodos t, t' **previos** al tratamiento.

La implicación testeable: en los períodos $k < -1$, los coeficientes $\hat{\beta}_k$ deben ser estadísticamente indistinguibles de cero.

- $\hat{\beta}_k \approx 0$ para todo $k < -1 \Rightarrow$ no se rechaza tendencias paralelas (evidencia *consistente* con el supuesto).
- $\hat{\beta}_k \neq 0$ para algún $k < -1 \Rightarrow$ violación aparente de tendencias paralelas o anticipación del tratamiento.

En la práctica: muchos papers reportan un F-test conjunto sobre todos los $\hat{\beta}_k$ con $k < -1$ como estadístico de validación formal.

Jacobson et al.: la gráfica que cambió el debate

Jacobson et al. estiman la ventana:

$$\log(\text{earnings}_{it}) = \alpha_i + \lambda_t + \sum_{k=-8}^5 \beta_k D_{it}^k + \varepsilon_{it}$$

para trabajadores de plantas con alta tasa de separación (Pennsylvania, 1974–1986).

Jacobson et al.: la gráfica que cambió el debate

Jacobson et al. estiman la ventana:

$$\log(\text{earnings}_{it}) = \alpha_i + \lambda_t + \sum_{k=-8}^5 \beta_k D_{it}^k + \varepsilon_{it}$$

para trabajadores de plantas con alta tasa de separación (Pennsylvania, 1974–1986).

Hallazgo pre-tratamiento ($k < 0$): los ingresos de los desplazados empiezan a caer **3–4 períodos antes** del evento, lo cual viola la forma estándar de pre-tendencias planas.

Jacobson et al.: la gráfica que cambió el debate

Jacobson et al. estiman la ventana:

$$\log(\text{earnings}_{it}) = \alpha_i + \lambda_t + \sum_{k=-8}^5 \beta_k D_{it}^k + \varepsilon_{it}$$

para trabajadores de plantas con alta tasa de separación (Pennsylvania, 1974–1986).

Hallazgo pre-tratamiento ($k < 0$): los ingresos de los desplazados empiezan a caer 3–4 períodos antes del evento, lo cual viola la forma estándar de pre-tendencias planas.

¿Qué explica los pre-trends negativos?

- Los autores argumentan que la caída pre-evento refleja el deterioro de la empresa antes del cierre (*firm-level distress*), no un cambio en las perspectivas individuales del trabajador.
- Los trabajadores no anticipaban su propio desplazamiento: la señal es de la firma, no del individuo.

Jacobson et al.: la gráfica que cambió el debate

Jacobson et al. estiman la ventana:

$$\log(\text{earnings}_{it}) = \alpha_i + \lambda_t + \sum_{k=-8}^5 \beta_k D_{it}^k + \varepsilon_{it}$$

para trabajadores de plantas con alta tasa de separación (Pennsylvania, 1974–1986).

Hallazgo pre-tratamiento ($k < 0$): los ingresos de los desplazados empiezan a caer 3–4 períodos antes del evento, lo cual viola la forma estándar de pre-tendencias planas.

¿Qué explica los pre-trends negativos?

- Los autores argumentan que la caída pre-evento refleja el deterioro de la empresa antes del cierre (*firm-level distress*), no un cambio en las perspectivas individuales del trabajador.
- Los trabajadores no anticipaban su propio desplazamiento: la señal es de la firma, no del individuo.

Hallazgo post-tratamiento ($k \geq 0$): caída adicional de $\approx 25\%$ en el período del evento; recuperación muy lenta ($\approx -15\%$ aún seis períodos después).

Jacobson et al.: la gráfica que cambió el debate

Jacobson et al. estiman la ventana:

$$\log(\text{earnings}_{it}) = \alpha_i + \lambda_t + \sum_{k=-8}^5 \beta_k D_{it}^k + \varepsilon_{it}$$

para trabajadores de plantas con alta tasa de separación (Pennsylvania, 1974–1986).

Hallazgo pre-tratamiento ($k < 0$): los ingresos de los desplazados empiezan a caer 3–4 períodos antes del evento, lo cual viola la forma estándar de pre-tendencias planas.

¿Qué explica los pre-trends negativos?

- Los autores argumentan que la caída pre-evento refleja el deterioro de la empresa antes del cierre (*firm-level distress*), no un cambio en las perspectivas individuales del trabajador.
- Los trabajadores no anticipaban su propio desplazamiento: la señal es de la firma, no del individuo.

Hallazgo post-tratamiento ($k \geq 0$): caída adicional de $\approx 25\%$ en el período del evento; recuperación muy lenta ($\approx -15\%$ aún seis períodos después).

Lección metodológica

Pre-tendencias no planas no invalidan automáticamente el diseño, pero **sí exigen explicación**. La historia causal debe ser coherente con el patrón pre-tratamiento observado.

Roadmap

1 De DiD a Event Study

- El hilo conductor: Jacobson, LaLonde y Sullivan (1993)
- La especificación event-study

2 Pre-tendencias como prueba del supuesto de paralelas

- Intuición y uso
- Límites del test de pre-tendencias

3 Tratamientos escalonados y el problema TWFE

- La descomposición de Goodman-Bacon (2021)

4 Estimadores robustos modernos

- Sun y Abraham (2021)
- Callaway y Sant'Anna (2021)

5 Hands-on: Event Study en R

Los límites del test visual: Roth (2022) — I

El test de pre-tendencias es hoy estándar, pero tiene limitaciones importantes.

Los límites del test visual: Roth (2022) — I

El test de pre-tendencias es hoy estándar, pero tiene limitaciones importantes.

Problema 1 — Bajo poder estadístico:

- El test tiene poder limitado para detectar tendencias no paralelas, especialmente con muestras pequeñas o pocos períodos pre-tratamiento.
- *No rechazar $H_0: \hat{\beta}_k = 0$ para $k < -1$ no equivale a confirmar tendencias paralelas. La ausencia de evidencia no es evidencia de ausencia.*

Los límites del test visual: Roth (2022) — I

El test de pre-tendencias es hoy estándar, pero tiene limitaciones importantes.

Problema 1 — Bajo poder estadístico:

- El test tiene poder limitado para detectar tendencias no paralelas, especialmente con muestras pequeñas o pocos períodos pre-tratamiento.
- *No rechazar H_0 : $\hat{\beta}_k = 0$ para $k < -1$ no equivale a confirmar tendencias paralelas. La ausencia de evidencia no es evidencia de ausencia.*

Problema 2 — Selección sobre la prueba:

- Si el investigador descarta especificaciones con pre-tendencias visibles, *selecciona* sobre estimaciones que “pasan” la prueba por accidente de muestreo.
- Esto introduce un sesgo de publicación endógeno al propio proceso de estimación.

Los límites del test visual: Roth (2022) — II

Problema 3 — Período observable vs. supuesto completo:

- El supuesto de paralelas requiere trayectorias iguales en *todos* los períodos sin tratamiento, no solo en el tramo pre-tratamiento observado.
- Pre-trends planos en $[-K, -1]$ son perfectamente consistentes con tendencias divergentes en $[0, M]$.

Los límites del test visual: Roth (2022) — II

Problema 3 — Período observable vs. supuesto completo:

- El supuesto de paralelas requiere trayectorias iguales en *todos* los períodos sin tratamiento, no solo en el tramo pre-tratamiento observado.
- Pre-trends planos en $[-K, -1]$ son perfectamente consistentes con tendencias divergentes en $[0, M]$.

Implicación práctica: el test de pre-tendencias es informativo sobre el pasado, no garantiza que la tendencia habría continuado siendo paralela en el período post-tratamiento.

Los límites del test visual: Roth (2022) — II

Problema 3 — Período observable vs. supuesto completo:

- El supuesto de paralelas requiere trayectorias iguales en *todos* los períodos sin tratamiento, no solo en el tramo pre-tratamiento observado.
- Pre-trends planos en $[-K, -1]$ son perfectamente consistentes con tendencias divergentes en $[0, M]$.

Implicación práctica: el test de pre-tendencias es informativo sobre el pasado, no garantiza que la tendencia habría continuado siendo paralela en el período post-tratamiento.

Conclusión

El test de pre-tendencias es **necesario pero no suficiente**. No reemplaza el argumento econométrico e institucional a favor del supuesto de tendencias paralelas. Si los pre-trends no son planos, se exige explicación (como en Jacobson et al.); si lo son, no se puede concluir validez automáticamente.

Roadmap

1 De DiD a Event Study

- El hilo conductor: Jacobson, LaLonde y Sullivan (1993)
- La especificación event-study

2 Pre-tendencias como prueba del supuesto de paralelas

- Intuición y uso
- Límites del test de pre-tendencias

3 Tratamientos escalonados y el problema TWFE

- La descomposición de Goodman-Bacon (2021)

4 Estimadores robustos modernos

- Sun y Abraham (2021)
- Callaway y Sant'Anna (2021)

5 Hands-on: Event Study en R

El problema con adopción escalonada

En el DiD canónico, todas las unidades se tratan al mismo tiempo ($T^* = g$ para todas). En la práctica, el tratamiento llega en momentos distintos:

El problema con adopción escalonada

En el DiD canónico, todas las unidades se tratan al mismo tiempo ($T^* = g$ para todas). En la práctica, el tratamiento llega en momentos distintos:

Ejemplos de adopción escalonada:

- **Jacobson et al.:** cada trabajador es desplazado en un año distinto (1974, 1975, ..., 1986). Cohortes de tratamiento escalonadas.
- Reformas laborales adoptadas por distintos estados en años diferentes.
- Programas sociales que se expanden municipio a municipio.

El problema con adopción escalonada

En el DiD canónico, todas las unidades se tratan al mismo tiempo ($T^* = g$ para todas). En la práctica, el tratamiento llega en momentos distintos:

Ejemplos de adopción escalonada:

- **Jacobson et al.:** cada trabajador es desplazado en un año distinto (1974, 1975, ..., 1986). Cohortes de tratamiento escalonadas.
- Reformas laborales adoptadas por distintos estados en años diferentes.
- Programas sociales que se expanden municipio a municipio.

La tentación natural: estimar el TWFE con la dummy de tratamiento acumulado:

$$Y_{it} = \alpha_i + \lambda_t + \beta D_{it} + \varepsilon_{it}, \quad D_{it} = \mathbf{1}\{t \geq g_i\}$$

El problema: con adopción escalonada, $\hat{\beta}^{TWFE}$ ya *no* es simplemente el ATT. Goodman-Bacon (2021) muestra exactamente **qué se está estimando**.

La descomposición de Goodman-Bacon (2021)

Con adopción escalonada, el estimador TWFE es una **suma ponderada** de todos los estimadores DiD 2×2 posibles, uno por cada par de grupos de timing.

La descomposición de Goodman-Bacon (2021)

Con adopción escalonada, el estimador TWFE es una **suma ponderada** de todos los estimadores DiD 2×2 posibles, uno por cada par de grupos de timing.

Teorema (Goodman-Bacon, 2021):

$$\hat{\beta}^{TWFE} = \sum_{k \neq U} w_{kU} \hat{\beta}_{k,U}^{2 \times 2} + \sum_{\substack{k, l: \\ g_k < g_l}} \left(w_{kl}^{\text{early}} \hat{\beta}_{kl}^{2 \times 2, \text{early}} + w_{kl}^{\text{late}} \hat{\beta}_{kl}^{2 \times 2, \text{late}} \right)$$

donde los tres tipos de comparaciones son:

Tipo	Tratado	Control
(i)	Grupo k (tratado en g_k)	Nunca tratados U
(ii) <i>early vs. late</i>	Grupo k temprano ($g_k < g_l$)	Grupo l tardío
(iii) <i>late vs. early</i>	Grupo l tardío	Grupo k ya tratado

La descomposición de Goodman-Bacon (2021)

Con adopción escalonada, el estimador TWFE es una **suma ponderada** de todos los estimadores DiD 2×2 posibles, uno por cada par de grupos de timing.

Teorema (Goodman-Bacon, 2021):

$$\hat{\beta}^{TWFE} = \sum_{k \neq U} w_{kU} \hat{\beta}_{k,U}^{2 \times 2} + \sum_{\substack{k, l: \\ g_k < g_l}} \left(w_{kl}^{\text{early}} \hat{\beta}_{kl}^{2 \times 2, \text{early}} + w_{kl}^{\text{late}} \hat{\beta}_{kl}^{2 \times 2, \text{late}} \right)$$

donde los tres tipos de comparaciones son:

Tipo	Tratado	Control
(i)	Grupo k (tratado en g_k)	Nunca tratados U
(ii) <i>early vs. late</i>	Grupo k temprano ($g_k < g_l$)	Grupo l tardío
(iii) <i>late vs. early</i>	Grupo l tardío	Grupo k ya tratado

Los pesos w son funciones del tamaño relativo de los grupos y de la varianza de D_{it} dentro de cada comparación: grupos grandes en períodos centrales reciben mayor peso.

El problema de los pesos negativos

Las comparaciones de tipo (i) y (ii) son **limpias**: el grupo de control no ha sido tratado en ningún período relevante.

El problema de los pesos negativos

Las comparaciones de tipo (i) y (ii) son **limpias**: el grupo de control no ha sido tratado en ningún período relevante.

La comparación problemática es el tipo (iii): el grupo *early-treated* sirve como control para el grupo *late-treated*. Pero en ese tramo, el “control” ya ha sido tratado.

El problema de los pesos negativos

Las comparaciones de tipo (i) y (ii) son **limpias**: el grupo de control no ha sido tratado en ningún período relevante.

La comparación problemática es el tipo (iii): el grupo *early-treated* sirve como control para el grupo *late-treated*. Pero en ese tramo, el “control” ya ha sido tratado.

¿Qué mide el DiD de tipo (iii)?

$$\hat{\beta}_{kl}^{2 \times 2, \text{late}} = \underbrace{(\bar{Y}_{l, \text{post}} - \bar{Y}_{l, \text{pre}})}_{\text{cambio en grupo } l} - \underbrace{(\bar{Y}_{k, \text{post}} - \bar{Y}_{k, \text{pre}})}_{\text{cambio en grupo } k \text{ ya tratado}}$$

Si los efectos del tratamiento **crecen en el tiempo**, el cambio de k captura el crecimiento del efecto, no una tendencia contrafactual. Esto **contamina** la estimación para l .

El problema de los pesos negativos

Las comparaciones de tipo (i) y (ii) son **limpias**: el grupo de control no ha sido tratado en ningún período relevante.

La comparación problemática es el tipo (iii): el grupo *early-treated* sirve como control para el grupo *late-treated*. Pero en ese tramo, el “control” ya ha sido tratado.

¿Qué mide el DiD de tipo (iii)?

$$\hat{\beta}_{kl}^{2 \times 2, \text{late}} = \underbrace{(\bar{Y}_{l, \text{post}} - \bar{Y}_{l, \text{pre}})}_{\text{cambio en grupo } l} - \underbrace{(\bar{Y}_{k, \text{post}} - \bar{Y}_{k, \text{pre}})}_{\text{cambio en grupo } k \text{ ya tratado}}$$

Si los efectos del tratamiento **crecen en el tiempo**, el cambio de k captura el crecimiento del efecto, no una tendencia contrafactual. Esto **contamina** la estimación para l .


El mecanismo algebraico: por el teorema de Frisch-Waugh-Lovell, $\hat{\beta}^{TWFE}$ se puede escribir como:

$$\hat{\beta}^{TWFE} = \frac{\sum_{i,t} \tilde{D}_{it} Y_{it}}{\sum_{i,t} \tilde{D}_{it}^2}, \quad \tilde{D}_{it} = D_{it} - \bar{D}_{i\cdot} - \bar{D}_{\cdot t} + \bar{D}_{\cdot\cdot}$$

Para una unidad k ya tratada en períodos tardíos, cuando $\bar{D}_{\cdot t}$ sube porque otras unidades se tratan, $\tilde{D}_{kt}$ puede ser **negativo**: las observaciones de k en esos períodos reciben un peso negativo en la suma. Con efectos heterogéneos, esto puede dar el signo equivocado.

El “control contaminado”: visualización

Tres grupos de timing. Eje horizontal: tiempo (t). Barras: estado de tratamiento.



El TWFE combina ambas comparaciones con pesos positivos. Si los efectos de A crecen en el tiempo, la comparación B vs. A está contaminada y el estimador puede dar el signo equivocado.

Roadmap

1 De DiD a Event Study

- El hilo conductor: Jacobson, LaLonde y Sullivan (1993)
- La especificación event-study

2 Pre-tendencias como prueba del supuesto de paralelas

- Intuición y uso
- Límites del test de pre-tendencias

3 Tratamientos escalonados y el problema TWFE

- La descomposición de Goodman-Bacon (2021)

4 Estimadores robustos modernos

- Sun y Abraham (2021)
- Callaway y Sant'Anna (2021)

5 Hands-on: Event Study en R

La lógica común de los estimadores modernos

Todos los estimadores robustos a heterogeneidad de efectos comparten una lógica:
construir solo comparaciones limpias; nunca usar un grupo ya tratado como control.

La lógica común de los estimadores modernos

Todos los estimadores robustos a heterogeneidad de efectos comparten una lógica: **construir solo comparaciones limpias**; nunca usar un grupo ya tratado como control.

La idea central: en lugar de un único $\hat{\beta}$, estimar efectos **heterogéneos por cohorte y período**, $ATT(g, t)$, y luego agregarlos:

$$ATT(g, t) = \mathbb{E}[Y_{it}(g) - Y_{it}(0) \mid G_i = g]$$

donde $G_i = g$ indica que la unidad i fue tratada por primera vez en el período g .

La lógica común de los estimadores modernos

Todos los estimadores robustos a heterogeneidad de efectos comparten una lógica: **construir solo comparaciones limpias**; nunca usar un grupo ya tratado como control.

La idea central: en lugar de un único $\hat{\beta}$, estimar efectos **heterogéneos por cohorte y período**, $ATT(g, t)$, y luego agregarlos:

$$ATT(g, t) = \mathbb{E}[Y_{it}(g) - Y_{it}(0) \mid G_i = g]$$

donde $G_i = g$ indica que la unidad i fue tratada por primera vez en el período g .

Dos implementaciones principales:

- 1 **Sun & Abraham (2021)** — estimador por interacción de cohortes; implementado en `fixest::sunab`.
- 2 **Callaway & Sant'Anna (2021)** — estimación semi-paramétrica de $ATT(g, t)$ cohorte a cohorte; implementado en `did`.

La lógica común de los estimadores modernos

Todos los estimadores robustos a heterogeneidad de efectos comparten una lógica: **construir solo comparaciones limpias**; nunca usar un grupo ya tratado como control.

La idea central: en lugar de un único $\hat{\beta}$, estimar efectos **heterogéneos por cohorte y período**, $ATT(g, t)$, y luego agregarlos:

$$ATT(g, t) = \mathbb{E}[Y_{it}(g) - Y_{it}(0) \mid G_i = g]$$

donde $G_i = g$ indica que la unidad i fue tratada por primera vez en el período g .

Dos implementaciones principales:

- 1 **Sun & Abraham (2021)** — estimador por interacción de cohortes; implementado en `fixest::sunab`.
- 2 **Callaway & Sant'Anna (2021)** — estimación semi-paramétrica de $ATT(g, t)$ cohorte a cohorte; implementado en `did`.

Caso especial

Si los efectos son **homogéneos** entre cohortes y constantes en el tiempo, los tres estimadores — TWFE, SA, CS — coinciden. La diferencia importa cuando hay **heterogeneidad dinámica**.

Sun y Abraham (2021)

La idea: en lugar de estimar un β_k único para cada período relativo k , **interactuar** las dummies de event-time con los indicadores de cohorte $\mathbf{1}\{G_i = g\}$.

Sun y Abraham (2021)

La idea: en lugar de estimar un β_k único para cada período relativo k , **interactuar** las dummies de event-time con los indicadores de cohorte $\mathbf{1}\{G_i = g\}$.

La regresión extendida:

$$Y_{it} = \alpha_i + \lambda_t + \sum_g \sum_{k \neq -1} \delta_{g,k} \cdot \mathbf{1}\{G_i = g\} \cdot D_{it}^k + \varepsilon_{it}$$

Cada $\delta_{g,k}$ es el efecto del tratamiento sobre la cohorte g en el período relativo k .

Sun y Abraham (2021)

La idea: en lugar de estimar un β_k único para cada período relativo k , **interactuar** las dummies de event-time con los indicadores de cohorte $\mathbf{1}\{G_i = g\}$.

La regresión extendida:

$$Y_{it} = \alpha_i + \lambda_t + \sum_g \sum_{k \neq -1} \delta_{g,k} \cdot \mathbf{1}\{G_i = g\} \cdot D_{it}^k + \varepsilon_{it}$$

Cada $\delta_{g,k}$ es el efecto del tratamiento sobre la cohorte g en el período relativo k .

El estimador event-study agregado:

$$\hat{\beta}_k^{SA} = \sum_g \hat{w}_g \hat{\delta}_{g,k}$$

donde $\hat{w}_g$ pondera por el tamaño relativo de la cohorte. **Solo usa nunca-tratados (o no-aún-tratados) como control.**

Sun y Abraham (2021)

La idea: en lugar de estimar un β_k único para cada período relativo k , **interactuar** las dummies de event-time con los indicadores de cohorte $\mathbf{1}\{G_i = g\}$.

La regresión extendida:

$$Y_{it} = \alpha_i + \lambda_t + \sum_g \sum_{k \neq -1} \delta_{g,k} \cdot \mathbf{1}\{G_i = g\} \cdot D_{it}^k + \varepsilon_{it}$$

Cada $\delta_{g,k}$ es el efecto del tratamiento sobre la cohorte g en el período relativo k .

El estimador event-study agregado:

$$\hat{\beta}_k^{SA} = \sum_g \hat{w}_g \hat{\delta}_{g,k}$$

donde $\hat{w}_g$ pondera por el tamaño relativo de la cohorte. **Solo usa nunca-tratados (o no-aún-tratados) como control.**

Implementación en R:

- `feols(y ~ sunab(g, t) | id + t, data = df)`
- `sunab(cohort, period)`: `cohort` = período de primer tratamiento, `period` = período del calendario.
- Graficar: `iplot(mod_sa)`.

Roadmap

1 De DiD a Event Study

- El hilo conductor: Jacobson, LaLonde y Sullivan (1993)
- La especificación event-study

2 Pre-tendencias como prueba del supuesto de paralelas

- Intuición y uso
- Límites del test de pre-tendencias

3 Tratamientos escalonados y el problema TWFE

- La descomposición de Goodman-Bacon (2021)

4 Estimadores robustos modernos

- Sun y Abraham (2021)
- Callaway y Sant'Anna (2021)

5 Hands-on: Event Study en R

Callaway y Sant'Anna (2021)

La idea: estimar $ATT(g, t)$ para cada par (cohorte g , período t) de forma semi-paramétrica, y luego agregar.

Callaway y Sant'Anna (2021)

La idea: estimar $ATT(g, t)$ para cada par (cohorte g , período t) de forma semi-paramétrica, y luego agregar.

El parámetro de interés:

$$ATT(g, t) = \mathbb{E}[Y_t - Y_{g-1} \mid G = g] - \mathbb{E}[Y_t - Y_{g-1} \mid \text{control}]$$

Diferencia entre el cambio en Y del grupo g y el cambio del grupo control, medidos desde el período pre-tratamiento $g - 1$ hasta t .

Callaway y Sant'Anna (2021)

La idea: estimar $ATT(g, t)$ para cada par (cohorte g , período t) de forma semi-paramétrica, y luego agregar.

El parámetro de interés:

$$ATT(g, t) = \mathbb{E}[Y_t - Y_{g-1} \mid G = g] - \mathbb{E}[Y_t - Y_{g-1} \mid \text{control}]$$

Diferencia entre el cambio en Y del grupo g y el cambio del grupo control, medidos desde el período pre-tratamiento $g - 1$ hasta t .

El grupo control puede ser:

- "nevertreated": solo unidades que nunca se tratan.
- "notyettreated": unidades que aún no han sido tratadas en t (más observaciones, mayor poder estadístico).

Callaway y Sant'Anna (2021)

La idea: estimar $ATT(g, t)$ para cada par (cohorte g , período t) de forma semi-paramétrica, y luego agregar.

El parámetro de interés:

$$ATT(g, t) = \mathbb{E}[Y_t - Y_{g-1} \mid G = g] - \mathbb{E}[Y_t - Y_{g-1} \mid \text{control}]$$

Diferencia entre el cambio en Y del grupo g y el cambio del grupo control, medidos desde el período pre-tratamiento $g - 1$ hasta t .

El grupo control puede ser:

- "nevertreated": solo unidades que nunca se tratan.
- "notyettreated": unidades que aún no han sido tratadas en t (más observaciones, mayor poder estadístico).

Agregación a event-time $k = t - g$:

$$\theta^{ES}(k) = \sum_{g: g+k \leq T} w_g \cdot ATT(g, g+k)$$

Implementación en R:

- `att <- att_gt("y","t","id","g", data=df, control="nevertreated")`
- `ggdid(aggte(att, type = "dynamic"))`

¿Cuándo importa la diferencia?

Los estimadores modernos y el TWFE difieren cuando los efectos son **heterogéneos entre cohortes o dinámicos en el tiempo**.

¿Cuándo importa la diferencia?

Los estimadores modernos y el TWFE difieren cuando los efectos son **heterogéneos entre cohortes o dinámicos en el tiempo**.

Cuándo el TWFE es (probablemente) confiable:

- Efecto constante: $ATT(g, t) = \delta$ para todo g y todo $t > g$.
- Adopción escalonada con efectos homogéneos entre cohortes.
- En la práctica: TWFE y SA/CS coinciden — se puede reportar cualquiera como principal con la nota de robustez.

¿Cuándo importa la diferencia?

Los estimadores modernos y el TWFE difieren cuando los efectos son **heterogéneos entre cohortes o dinámicos en el tiempo**.

Cuándo el TWFE es (probablemente) confiable:

- Efecto constante: $ATT(g, t) = \delta$ para todo g y todo $t > g$.
- Adopción escalonada con efectos homogéneos entre cohortes.
- En la práctica: TWFE y SA/CS coinciden — se puede reportar cualquiera como principal con la nota de robustez.

Cuándo el TWFE puede ser engañoso:

- Efectos que crecen o decaen en el tiempo (*dynamic treatment effects*).
- Cohortes con magnitudes de efecto muy distintas.
- Muchas cohortes y fuerte heterogeneidad: el TWFE puede mezclar signos y producir un estimador cercano a cero o de signo incorrecto.

¿Cuándo importa la diferencia?

Los estimadores modernos y el TWFE difieren cuando los efectos son **heterogéneos entre cohortes o dinámicos en el tiempo**.

Cuándo el TWFE es (probablemente) confiable:

- Efecto constante: $ATT(g, t) = \delta$ para todo g y todo $t > g$.
- Adopción escalonada con efectos homogéneos entre cohortes.
- En la práctica: TWFE y SA/CS coinciden — se puede reportar cualquiera como principal con la nota de robustez.

Cuándo el TWFE puede ser engañoso:

- Efectos que crecen o decaen en el tiempo (*dynamic treatment effects*).
- Cohortes con magnitudes de efecto muy distintas.
- Muchas cohortes y fuerte heterogeneidad: el TWFE puede mezclar signos y producir un estimador cercano a cero o de signo incorrecto.

Regla práctica

Siempre estima SA o CS junto con el TWFE. Si divergen notablemente, reporta los estimadores robustos como resultado principal y discute la fuente de heterogeneidad. Si coinciden, el TWFE es suficiente con la nota de robustez.

Roadmap

1 De DiD a Event Study

- El hilo conductor: Jacobson, LaLonde y Sullivan (1993)
- La especificación event-study

2 Pre-tendencias como prueba del supuesto de paralelas

- Intuición y uso
- Límites del test de pre-tendencias

3 Tratamientos escalonados y el problema TWFE

- La descomposición de Goodman-Bacon (2021)

4 Estimadores robustos modernos

- Sun y Abraham (2021)
- Callaway y Sant'Anna (2021)

5 Hands-on: Event Study en R

Datos: panel de trabajadores desplazados

Para el ejercicio replicamos la estructura de Jacobson et al. (1993) con datos simulados.

Estructura del panel:

- id: identificador del trabajador.
- t: año de observación ($t \in \{1974, \dots, 1988\}$).
- g: año de desplazamiento (cohorte de tratamiento); $g = \text{Inf}$ para nunca desplazados.
- y: log-ingresos anuales.
- D: indicador de tratamiento acumulado ($D_{it} = \mathbf{1}\{t \geq g_i\}$).
- k: período relativo ($k = t - g$).

Paquetes:

- `fixest` — `feols()`, `i()`, `sunab()`, `ipplot()`.
- `did` — `att_gt()`, `aggte()`, `ggdid()`.
- `tidyverse` — manipulación y gráficos auxiliares.

Script de la sesión: `event_study_jacobson.R` (disponible en el repositorio del curso).

Qué estimaremos hoy en R

Paso 1 — TWFE simple (event-study):

- `feols(y ~ i(k, ref = -1) | id + t, data = df)`
- Graficar coeficientes $\hat{\beta}_k$ con `iplot()`. ¿Son planos los pre-trends? ¿Cuándo empieza la caída?

Paso 2 — Sun & Abraham:

- `feols(y ~ sunab(g, t) | id + t, data = df)`
- Graficar $\hat{\beta}_k^{SA}$ con `iplot()`. ¿Difiere del TWFE?

Paso 3 — Callaway & Sant'Anna:

- `att <- att_gt("y","t","id","g", data=df, control="nevertreated")`
- `ggdid(aggte(att, type = "dynamic"))` — gráfica $\theta^{ES}(k)$.

Paso 4 — Comparación de los tres estimadores:

- ¿Coinciden cuando los efectos son homogéneos?
- Simular heterogeneidad entre cohortes y verificar la divergencia.

Validación:

- F-test de pre-tendencias: `linearHypothesis()` sobre $\hat{\beta}_k = 0, k < -1$.
- Placebo temporal: reasignar g por un año ficticio para unidades de control.

Cierre y conexión con la próxima semana

Lo que vimos hoy:

- El event study extiende DiD para recuperar la **dinámica del efecto**: leads y lags alrededor del evento.
- Los coeficientes pre-evento ($k < -1$) son una prueba de tendencias paralelas, pero con límites importantes (Roth, 2022).
- Con adopción escalonada, el TWFE mezcla comparaciones limpias y contaminadas: la descomposición de Goodman-Bacon formaliza exactamente qué se está estimando y por qué los pesos pueden ser negativos.
- Los estimadores de Sun & Abraham y Callaway & Sant'Anna resuelven el problema construyendo solo comparaciones con grupos no-aún-tratados o nunca-tratados.

Cierre y conexión con la próxima semana

Lo que vimos hoy:

- El event study extiende DiD para recuperar la **dinámica del efecto**: leads y lags alrededor del evento.
- Los coeficientes pre-evento ($k < -1$) son una prueba de tendencias paralelas, pero con límites importantes (Roth, 2022).
- Con adopción escalonada, el TWFE mezcla comparaciones limpias y contaminadas: la descomposición de Goodman-Bacon formaliza exactamente qué se está estimando y por qué los pesos pueden ser negativos.
- Los estimadores de Sun & Abraham y Callaway & Sant'Anna resuelven el problema construyendo solo comparaciones con grupos no-aún-tratados o nunca-tratados.

La próxima semana — Propensity Score Matching:

- Hasta ahora hemos explotado variación cuasi-aleatoria en el *tiempo*.
- ¿Y si el tratamiento es el resultado de *selección sobre observables*? No hay discontinuidad, no hay instrumento, no hay variación temporal limpia.
- PSM: igualar unidades con la misma probabilidad de ser tratadas ($e(X) = P(D = 1 | X)$) para construir el contrafactual.

Rosenbaum & Rubin (1983) — “The Central Role of the Propensity Score”.

Referencias I — Paper de la semana y event study

Paper de la semana

- Jacobson, L. S., LaLonde, R. J. & Sullivan, D. G. (1993). Earnings Losses of Displaced Workers. *American Economic Review*, 83(4), 685–709.

Event study y pre-tendencias

- Roth, J. (2022). Pre-Test with Caution: Event-Study Estimates After Testing for Parallel Trends. *AER: Insights*, 4(3), 305–322.
- Freyaldenhoven, S., Hansen, C. & Shapiro, J. M. (2019). Pre-event Trends in the Panel Event-Study Design. *American Economic Review*, 109(9), 3307–3338.

Referencias II — Tratamientos escalonados y estimadores robustos

Tratamientos escalonados

- Goodman-Bacon, A. (2021). Difference-in-Differences with Variation in Treatment Timing. *Journal of Econometrics*, 225(2), 254–277.
- de Chaisemartin, C. & D'Haultfœuille, X. (2020). Two-Way Fixed Effects Estimators with Heterogeneous Treatment Effects. *American Economic Review*, 110(9), 2964–2996.

Estimadores robustos

- Sun, L. & Abraham, S. (2021). Estimating Dynamic Treatment Effects in Event Studies with Heterogeneous Treatment Effects. *Journal of Econometrics*, 225(2), 175–199.
- Callaway, B. & Sant'Anna, P. H. C. (2021). Difference-in-Differences with Multiple Time Periods. *Journal of Econometrics*, 225(2), 200–230.
- Roth, J., Sant'Anna, P. H. C., Bilinski, A. & Poe, J. (2023). What's Trending in Difference-in-Differences? *Journal of Econometrics*, 235(2), 2218–2244.